Ministério da Educação
Secretaria de Educação Profissional e Tecnológica
Instituto Federal Catarinense
Campus Videira

GABRIEL NOGUEIRA

AGENTES AUTÔNOMOS BASEADOS EM MODELOS DE LINGUAGEM DE GRANDE ESCALA PARA IDENTIFICAÇÃO E CORREÇÃO DE INCONSISTÊNCIAS FISCAIS EM SISTEMAS ERP

Videira
2026

GABRIEL NOGUEIRA

AGENTES AUTÔNOMOS BASEADOS EM MODELOS DE LINGUAGEM DE GRANDE ESCALA PARA IDENTIFICAÇÃO E CORREÇÃO DE INCONSISTÊNCIAS FISCAIS EM SISTEMAS ERP

Projeto de Trabalho de Conclusão de Curso apresentado ao Curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Campus Videira para obtenção do título de bacharel em Ciência da Computação.
Orientador: Fabricio Bizotto

Videira
2026

RESUMO

A emissão de Nota Fiscal Eletrônica (NF-e) no Brasil está sujeita a um rigoroso conjunto de validações impostas pela Secretaria da Fazenda (SEFAZ). Inconsistências em dados cadastrais de clientes e produtos nos sistemas de gestão empresarial (ERPs), como classificações incorretas de CST, CFOP e NCM, resultam na rejeição sumária de lotes de faturamento, gerando interrupções operacionais e sobrecarga no suporte técnico. Este trabalho propõe o desenvolvimento de um agente autônomo baseado em Modelos de Linguagem de Grande Escala (LLMs), orquestrado pelo framework LangChain, para identificar e corrigir proativamente essas anomalias no banco de dados de um ERP do setor automotivo (Lux Auto). Para garantir a integridade das operações e mitigar o risco de alucinações inerentes aos LLMs, adota-se a arquitetura *Human-in-the-Loop*, na qual as correções formuladas pelo agente, na forma de consultas SQL (*Text-to-SQL*), são apresentadas em uma interface independente desenvolvida em Streamlit para validação humana antes da execução. A avaliação do protótipo será realizada utilizando a família de modelos abertos Llama sobre um conjunto misto de registros reais de rejeição (anonimizados sob conformidade com a LGPD) e casos sintéticos. O projeto almeja atingir uma taxa de detecção superior a 85% e uma taxa de acerto nas correções de 75%, demonstrando a viabilidade pragmática do uso de inteligência artificial generativa na governança de dados fiscais.

Palavras-chave: Inteligência Artificial. Modelos de Linguagem de Grande Escala. *Text-to-SQL*. *Human-in-the-Loop*. Governança de Dados. Nota Fiscal Eletrônica.

ABSTRACT

The issuance of Electronic Invoices (NF-e) in Brazil is subject to a strict set of validations imposed by the State Department of Finance (SEFAZ). Inconsistencies in customer and product registration data within Enterprise Resource Planning (ERP) systems, such as incorrect classifications of tax codes (CST, CFOP, and NCM), result in the summary rejection of billing batches, causing operational disruptions and overwhelming technical support. This work proposes the development of an autonomous agent based on Large Language Models (LLMs), orchestrated by the LangChain framework, to proactively identify and correct these anomalies in the database of an automotive sector ERP (Lux Auto). To ensure operational integrity and mitigate the risk of LLM hallucinations, a Human-in-the-Loop architecture is adopted, in which the corrections formulated by the agent—in the form of SQL queries (Text-to-SQL)—are presented on an independent interface developed with Streamlit for human validation before execution. The prototype evaluation will be conducted using the open-source Llama model family on a mixed dataset of real rejection records (anonymized in compliance with the LGPD) and synthetic cases. The project aims to achieve a detection rate exceeding 85% and a correction accuracy rate of 75%, demonstrating the pragmatic viability of using generative artificial intelligence for tax data governance.

Keywords: Artificial Intelligence. Large Language Models. Text-to-SQL. Human-in-the-Loop. Data Governance. Electronic Invoice.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxo de rejeição de NF-e e geração de demanda de suporte técnico. 9
Figura 2 – Etapas sequenciais do desenvolvimento do trabalho. 20
Figura 3 – Arquitetura do agente autônomo com supervisão *Human-in-the-Loop*. . . . 21

LISTA DE ABREVIATURAS E SIGLAS

API	Application Programming Interface
CBS	Contribuição sobre Bens e Serviços
CEST	Código Especificador de Substituição Tributária
CFOP	Código Fiscal de Operações e Prestações
CNAE	Classificação Nacional de Atividades Econômicas
CNPJ	Cadastro Nacional da Pessoa Jurídica
COFINS	Contribuição para o Financiamento da Seguridade Social
CPF	Cadastro de Pessoas Físicas
CST	Código de Situação Tributária
DDL	Data Definition Language
ERP	Enterprise Resource Planning
HITL	Human-in-the-Loop
IBS	Imposto sobre Bens e Serviços
ICMS	Imposto sobre Circulação de Mercadorias e Serviços
IPI	Imposto sobre Produtos Industrializados
ISS	Imposto Sobre Serviços
LLM	Large Language Model
MOC	Manual de Orientação do Contribuinte
NCM	Nomenclatura Comum do Mercosul
NF-e	Nota Fiscal Eletrônica
PIS	Programa de Integração Social
RAG	Retrieval-Augmented Generation
SEFAZ	Secretaria da Fazenda
SQL	Structured Query Language
VRAM	Video Random Access Memory

SUMÁRIO

1 Introdução 7
1.1 Objetivos 8
1.1.1 Objetivo Geral 8
1.1.2 Objetivos Específicos 8
1.2 Justificativa 8
2 Fundamentação 11
2.1 Sistemas ERP 11
2.1.1 Qualidade de Dados em Sistemas ERP 12
2.2 Nota Fiscal Eletrônica e Legislação Fiscal Brasileira 13
2.3 Modelos de Linguagem de Grande Escala 14
2.4 Agentes Autônomos e Human-in-the-Loop 15
2.5 Streamlit 16
2.6 Integração de LLMs com Bancos de Dados Relacionais 16
2.7 Trabalhos Correlatos 17
3 Metodologia 19
3.1 Arquitetura da Solução Proposta 20
3.2 Orçamento 22
4 Cronograma 23
5 Resultados Esperados 24

REFERÊNCIAS 26

1 INTRODUÇÃO

Nos dias atuais, sistemas de gestão empresarial (ERPs) dependem fortemente da inserção manual de dados cadastrais para o seu pleno funcionamento. Essa dependência operacional gera gargalos significativos, uma vez que a interação humana está sujeita a falhas de digitação ou interpretação (MEHTA, 2025). Tais inconsistências em bancos de dados relacionais dividem-se, em geral, em duas categorias. A primeira envolve erros de preenchimento que não impedem o funcionamento básico do sistema, como a inserção de um número de telefone no campo destinado ao endereço. A segunda, e mais crítica, engloba informações que afetam diretamente o ecossistema de integrações do software. Um exemplo claro ocorre no módulo fiscal: quando o cadastro de um cliente apresenta divergências entre a Inscrição Estadual e o Indicador de Contribuinte, ou há a omissão e preenchimento incorreto de códigos obrigatórios como NCM (Nomenclatura Comum do Mercosul), CST (Código de Situação Tributária) e CFOP (Código Fiscal de Operações e Prestações), a emissão da Nota Fiscal Eletrônica (NF-e) é inviabilizada e sumariamente rejeitada pela Secretaria da Fazenda (SEFAZ) (ENCAT; SEFAZ, 2020).

Essas rejeições paralisam a cadeia de produção das empresas e geram uma sobrecarga imediata no setor de suporte técnico, exigindo intervenção manual para correções que, na maioria das vezes, seguem padrões lógicos e regulatórios bem definidos. Nesse cenário, os Agentes Autônomos baseados em Modelos de Linguagem de Grande Escala (LLMs) surgem como uma solução tecnológica altamente viável (WANG et al., 2024). Ao utilizar o processamento de linguagem natural e a compreensão de regras de negócio predefinidas, esses agentes podem atuar na identificação proativa dessas anomalias e na formulação automática de scripts de correção (ROYCHOWDHURY et al., 2025). Para garantir a segurança e a integridade da operação no banco de dados, a atuação do agente ocorre de forma supervisionada (*Human-in-the-Loop*), onde o script gerado aguarda a validação e aprovação de um operador humano antes de ser executado (CHENG; CHENG, 2026). A automatização dessa etapa de triagem e formulação de solução mitiga gargalos operacionais, reduz custos com atendimento de suporte e otimiza a rotina tanto do cliente final quanto da equipe técnica.

Devido à amplitude de possíveis correções em um ambiente de banco de dados, este projeto delimita seu escopo analítico ao nicho de regras e validações fiscais. Diante deste contexto, o presente trabalho busca responder à seguinte pergunta de pesquisa: É possível integrar um agente autônomo a um banco de dados relacional para mitigar problemas cadastrais

recorrentes, identificando inconsistências fiscais e propondo correções de forma eficiente sob supervisão humana?

1.1 OBJETIVOS

1.1.1 Objetivo Geral

Desenvolver um agente autônomo baseado em Modelos de Linguagem de Grande Escala integrado a um banco de dados relacional de um sistema ERP, capaz de identificar inconsistências fiscais no cadastro de clientes e propor correções de forma supervisionada, visando reduzir a ocorrência de rejeições de NF-e e a demanda de suporte técnico.

1.1.2 Objetivos Específicos

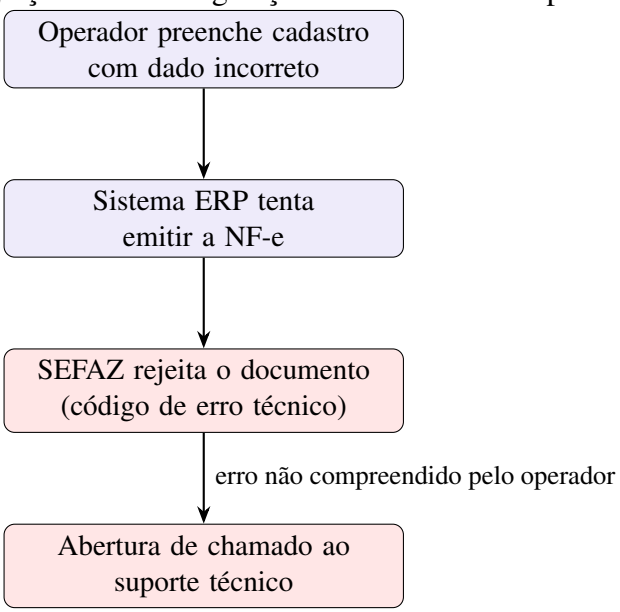
- Mapear as inconsistências fiscais mais recorrentes em cadastros de clientes em sistemas ERP, com foco em campos críticos para a emissão de NF-e;
- Projetar a arquitetura do agente autônomo, definindo o fluxo de identificação de inconsistências, geração de alertas e execução supervisionada de correções;
- Implementar o agente autônomo integrado a um banco de dados relacional, utilizando um Modelo de Linguagem de Grande Escala para interpretação e formulação das correções;
- Validar o agente em ambiente de testes, simulando cenários de inconsistências fiscais com dados fictícios;
- Avaliar a eficácia do agente com base na taxa de acerto das correções propostas e na redução de ocorrências que demandariam intervenção de suporte técnico.

1.2 JUSTIFICATIVA

A gestão fiscal em sistemas ERP representa um dos principais gargalos operacionais em pequenas e médias empresas do setor automotivo. Inconsistências cadastrais, como divergências entre a Inscrição Estadual e o Indicador de Contribuinte, preenchimento incorreto de códigos NCM, CST e CFOP, comprometem diretamente a emissão de NF-e, interrompendo o fluxo de faturamento e gerando demanda recorrente ao suporte técnico. Erros cadastrais de natureza fiscal estão entre as principais causas de chamados de suporte em sistemas ERP, gerando

sobrecarga nas equipes técnicas com ocorrências que poderiam ser resolvidas de forma autônoma (XU et al., 2002). Os padrões recorrentes desses chamados constituem a base empírica do conjunto de casos de teste adotado neste trabalho, conferindo validade externa à avaliação do agente proposto. A Figura 1 sintetiza o fluxo que origina essa demanda.

Figura 1 – Fluxo de rejeição de NF-e e geração de demanda de suporte técnico.



Fonte: O autor (2026).

Embora os próprios sistemas ERP sinalizem esses erros ao usuário, a baixa familiaridade dos operadores com terminologia fiscal faz com que as mensagens de erro sejam frequentemente ignoradas, resultando em chamados de suporte para problemas que já foram identificados pelo sistema mas não compreendidos pelo usuário. Esse comportamento evidencia que a solução não passa apenas por detectar o erro, mas por interpretá-lo e propor uma correção acessível e supervisionada.

Nesse contexto, abordagens baseadas em regras fixas mostram-se insuficientes para cobrir a complexidade do domínio fiscal brasileiro (NAY et al., 2023). A classificação correta de um produto pelo código NCM, por exemplo, exige consulta a fontes externas e conhecimento regulatório específico, como a aplicação do CST 020 para veículos automotores sujeitos à redução de base de cálculo do ICMS. Da mesma forma, a verificação da situação cadastral de uma empresa junto aos órgãos estaduais demanda integração com fontes externas de dados. Essas características tornam os Modelos de Linguagem de Grande Escala uma alternativa tecnicamente adequada, dado sua capacidade de interpretar contexto, consultar informações externas e formular respostas adaptadas a casos ambíguos sob supervisão humana (NATARAJAN et al.,

2025).

2 FUNDAMENTAÇÃO

Neste capítulo, são apresentados os conceitos e tecnologias que embasam o desenvolvimento deste trabalho. Serão abordados o funcionamento dos sistemas ERP e os desafios de qualidade de dados, as exigências da legislação fiscal brasileira para emissão de Notas Fiscais Eletrônicas, os fundamentos dos Modelos de Linguagem de Grande Escala, a abordagem de agentes autônomos com supervisão humana, as ferramentas de desenvolvimento adotadas e, por fim, os trabalhos correlatos identificados na literatura.

2.1 SISTEMAS ERP

Os sistemas de gestão empresarial, conhecidos pela sigla ERP (do inglês *Enterprise Resource Planning*), são plataformas de software integradas que centralizam e automatizam os principais processos organizacionais em um único ambiente (ARORA; ERTURK, 2017). Esses sistemas abrangem módulos como financeiro, fiscal, controle de estoque, vendas e relacionamento com clientes, permitindo que informações fluam entre os departamentos de forma padronizada. Sua adoção por pequenas e médias empresas tem crescido de forma expressiva nas últimas décadas, impulsionada pela necessidade de maior controle operacional e pela exigência de conformidade com normas regulatórias cada vez mais rigorosas (LAUKKANEN; SARPOLA; HALLIKAINEN, 2007; van Everdingen; van Hillegersberg; WAARTS, 2000).

No setor automotivo brasileiro, especificamente em oficinas mecânicas, os sistemas ERP assumem papel estratégico. Dados do Anuário da Indústria de Reparação de Veículos indicam que o Brasil possui mais de 119 mil estabelecimentos do ramo automotivo (SINDIREPA BRASIL, 2023), o que evidencia a dimensão do mercado e a necessidade de eficiência operacional nesses negócios. Nesse contexto, o ERP integra o controle de ordens de serviço, a gestão de peças e insumos, o cadastro de clientes e fornecedores, e a emissão de documentos fiscais em um único fluxo, tornando a consistência dos dados cadastrais um requisito não apenas técnico, mas legal.

Um exemplo prático dessa realidade é o sistema ERP Lux Auto, voltado ao segmento de oficinas mecânicas. Analisando seu funcionamento no dia a dia, observa-se que, embora o sistema ofereça uma interface funcional para usuários experientes, novos clientes frequentemente enfrentam dificuldades nos primeiros meses de uso (CHIMPIRI, 2024). O Lux Auto é abrangente: contempla o registro de produtos, o controle de serviços prestados em veícu-

los, cadastros gerais de pessoas e fornecedores, além de módulos avançados de contas a receber e a pagar. Contudo, é no módulo fiscal que os problemas mais críticos surgem, pois as validações impostas pelos órgãos governamentais são rígidas e intolerantes a erros de formatação ou classificação, transformando o ambiente fiscal no ponto de maior atrito entre o sistema e o usuário final.

2.1.1 Qualidade de Dados em Sistemas ERP

A qualidade dos dados armazenados em sistemas ERP é fator determinante para a confiabilidade dos processos organizacionais (XU et al., 2002). Inconsistências cadastrais, sejam elas provenientes de erros de digitação, falta de padronização estrutural ou desconhecimento técnico dos operadores, comprometem diretamente a integridade das informações e geram um efeito cascata que impacta todos os processos dependentes desses dados (CHIMPIRI, 2024). No contexto fiscal, essas inconsistências assumem caráter crítico: campos como Inscrição Estadual, Indicador de Contribuinte, NCM (Nomenclatura Comum do Mercosul), CST (Código de Situação Tributária) e CFOP (Código Fiscal de Operações e Prestações) são validados por órgãos reguladores no momento da emissão de documentos fiscais eletrônicos (ENCAT; SEFAZ, 2020). A presença de dados incorretos ou em branco nesses campos inviabiliza o faturamento da empresa emissora, gerando demanda urgente e recorrente ao suporte técnico e representando um custo operacional significativo tanto para as desenvolvedoras de ERP quanto para seus clientes (MEHTA, 2025).

Os ERPs atendem negócios dos mais variados perfis, e no nicho de oficinas mecânicas essa discrepância de conhecimento tecnológico fica ainda mais evidente. O sistema precisa atender desde profissionais qualificados em rotinas fiscais até usuários com pouca familiaridade com computação básica. Na experiência documentada com o Lux Auto, identifica-se que a maioria dos gargalos operacionais recai sobre usuários que não possuem discernimento técnico para interpretar mensagens de erro geradas pelo sistema. Esses usuários não conseguem, por conta própria, realizar ajustes em campos como NCM ou Indicador de Contribuinte baseando-se apenas em um código de rejeição devolvido pela SEFAZ. Nesse cenário, a qualidade da informação inserida no momento do cadastro torna-se vital, e mecanismos inteligentes de validação e correção preventiva passam a ser essenciais para manter a operação do negócio ativa (SCHELTER et al., 2018).

2.2 NOTA FISCAL ELETRÔNICA E LEGISLAÇÃO FISCAL BRASILEIRA

A Nota Fiscal Eletrônica (NF-e) é um documento fiscal digital instituído pelo Ajuste SINIEF 07/2005, que substituiu o modelo em papel e conferiu maior agilidade e controle às operações comerciais (BRASIL, 2005). Sua emissão é regulamentada pela Secretaria da Fazenda (SEFAZ) e está condicionada à validação em tempo real por meio de WebServices governamentais, que verificam centenas de regras de negócio antes de autorizar o documento (ENCAT; SEFAZ, 2020).

Entre os principais campos obrigatórios validados pela SEFAZ, destacam-se o Código de Situação Tributária (CST), que define o tratamento do ICMS aplicável à operação; o Código Fiscal de Operações e Prestações (CFOP), que classifica a natureza da operação comercial; e a Nomenclatura Comum do Mercosul (NCM), que identifica a classificação fiscal do produto e determina suas alíquotas tributárias (SEFAZ-PE, 2016). Além desses, o documento exige a chave de acesso composta por 44 dígitos, a descrição detalhada dos produtos (unidade, quantidade, valor unitário e valor total), tributos como IPI, PIS, COFINS e ISS, e os dados completos do emitente e destinatário, incluindo CNPJ ou CPF, razão social, endereço, Inscrição Estadual e regime tributário (ENCAT; SEFAZ, 2020).

Uma única divergência nesses campos, como um destinatário classificado como "Contribuinte Isento" mas que possui Inscrição Estadual ativa no cadastro estadual, resulta na rejeição imediata do lote pela SEFAZ, interrompendo o fluxo de faturamento da empresa emissora (BRASIL, 2005). Com a reforma tributária em curso no Brasil (BRASIL, 2023), que substitui progressivamente os tributos vigentes pelo IBS (Imposto sobre Bens e Serviços) e pela CBS (Contribuição sobre Bens e Serviços), documentos fiscais eletrônicos passarão a exigir novos campos e regras de classificação específicas durante o período de transição. Para sistemas ERP, isso amplifica diretamente o espaço de possíveis inconsistências cadastrais: campos atualmente críticos como NCM, CST e CFOP deverão coexistir com novos identificadores, tornando ainda mais improvável que um sistema baseado em regras fixas consiga acompanhar todas as combinações válidas. Abordagens que combinam LLMs com representações lógicas formais das regras tributárias, traduzindo o texto normativo em programas estruturados e auditáveis em vez de codificá-las diretamente no software, têm sido propostas como forma de manter a confiabilidade do raciocínio fiscal mesmo diante de mudanças regulatórias frequentes (JURAYJ; HOLZENBERGER; Van Durme, 2026).

2.3 MODELOS DE LINGUAGEM DE GRANDE ESCALA

Os Modelos de Linguagem de Grande Escala, conhecidos pela sigla LLM (do inglês *Large Language Model*), são sistemas de inteligência artificial baseados na arquitetura *Transformer*, proposta por Vaswani et al. (2017). Essa arquitetura utiliza mecanismos de autoatenção (*self-attention*) que permitem ao modelo processar sequências de texto de forma paralela, identificando relações contextuais entre palavras independentemente de sua posição na sentença (SHAO et al., 2024). Os LLMs são treinados em volumes massivos de dados textuais, o que lhes confere a capacidade não apenas de gerar texto coerente, mas de interpretar contextos complexos, inferir intenções e manter coerência lógica em domínios específicos (DOUGLAS, 2023).

No domínio fiscal, essa capacidade se mostra especialmente relevante. Diferentemente de abordagens baseadas em regras fixas (*hard-coded*), que falham ao tentar cobrir a totalidade de exceções da legislação tributária brasileira, os LLMs conseguem interpretar situações ambíguas e formular respostas adaptadas ao contexto (NAY et al., 2023). A classificação correta de um produto pelo código NCM, por exemplo, exige a interpretação de descrições textuais e o cruzamento com tabelas regulatórias, tarefa na qual os LLMs têm demonstrado desempenho superior ao de sistemas baseados em regras estáticas (GHOLAMIAN et al., 2024).

Entretanto, o uso de LLMs em ambientes de produção esbarra em uma limitação crítica: as alucinações. Trata-se de respostas incorretas geradas pelo modelo com alto grau de confiança, um fenômeno amplamente documentado na literatura (HUANG et al., 2025). No ambiente fiscal, onde não há tolerância a erros, uma classificação tributária equivocada pode resultar em recolhimento indevido de impostos e em penalidades severas. Por essa razão, a literatura recomenda que aplicações de LLMs em domínios sensíveis não busquem a autonomia total do modelo, mas o utilizem como ferramenta de análise e proposição, sempre subordinada à validação humana (NATARAJAN et al., 2025).

Do ponto de vista de custos, a implantação de um LLM em um sistema de suporte técnico demanda estratégias de otimização. Modelos proprietários, como os oferecidos via API pela OpenAI e Google, cobram por volume de *tokens* processados, e esse custo recorrente pode tornar a operação contínua financeiramente inviável a partir de determinados volumes de uso, o que motiva a comparação entre o custo de API e o custo de uma infraestrutura local (PAN et al., 2025). Uma alternativa amplamente discutida na literatura é a execução local de modelos de código aberto por meio de ferramentas como o Ollama, que permite instalar e rodar

LLMs diretamente na máquina sem dependência de APIs externas (Ollama, 2023). As técnicas de otimização de inferência, atuando nos níveis de dados, modelo e sistema, permitem reduzir significativamente os requisitos computacionais dos LLMs (ZHOU et al., 2024), viabilizando sua execução em hardware de consumo. Entre essas técnicas, destaca-se a quantização, que reduz a precisão numérica dos parâmetros do modelo (tipicamente de 16 *bits* para 4 ou 5 *bits*), seja por meio de treinamento com quantização nativa (LIU et al., 2024), seja por quantização pós-treinamento, como nos formatos Q4 e Q5 do padrão GGUF adotado pelo Ollama (Ollama, 2023), diminuindo o consumo de memória de forma expressiva com perda mínima de qualidade nas respostas (SHAO et al., 2024). Com essa técnica, modelos de 7 a 8 bilhões de parâmetros podem operar com menos de 6 GB de VRAM (Ollama, 2023). Essa abordagem garante, adicionalmente, privacidade total dos dados da empresa, controle sobre o ambiente de execução e custo zero de inferência contínua, viabilizando a adoção da solução por empresas de qualquer porte.

2.4 AGENTES AUTÔNOMOS E HUMAN-IN-THE-LOOP

O avanço dos LLMs permitiu o surgimento de uma nova classe de sistemas de inteligência artificial: os agentes autônomos. Diferentemente de um LLM utilizado de forma isolada (que apenas recebe um texto e gera uma resposta), um agente é um sistema modular no qual o modelo de linguagem atua como motor de raciocínio, recebendo acesso a ferramentas externas para perceber o ambiente e interagir com ele de forma autônoma (WANG et al., 2024). Essas ferramentas podem incluir acesso a bancos de dados, APIs externas, mecanismos de busca e execução de código, ampliando significativamente a capacidade de ação do modelo (QU et al., 2024).

No contexto de correção de bases de dados, um agente autônomo é capaz de: (1) conectar-se a um banco de dados relacional; (2) identificar registros com anomalias com base em regras de domínio; (3) formular uma proposta de correção em linguagem SQL; e (4) apresentar essa proposta ao operador humano para validação (ROYCHOWDHURY et al., 2025). Entretanto, em domínios críticos como o fiscal e o financeiro, a delegação total de decisões a uma inteligência artificial apresenta riscos sistêmicos inaceitáveis (PÖHLER et al., 2025).

Para mitigar esse risco, a literatura recomenda a adoção do paradigma *Human-in-the-Loop* (HITL), no qual o fluxo de automação é intencionalmente interrompido antes de qualquer alteração permanente no banco de dados: o agente elabora o diagnóstico e formula

a proposta de correção, mas aguarda a validação e aprovação de um operador humano antes da execução (CHENG; CHENG, 2026). Essa exigência se alinha a modelos mais amplos de segurança e responsabilização de agentes de IA, que defendem a validação progressiva da autonomia como condição para a confiabilidade do sistema (CHENG; CHENG; SIU, 2025). Essa abordagem também privilegia a acessibilidade, na medida em que o alerta gerado pelo agente pode ser formulado em linguagem simples e direta, sem expor termos técnicos ao usuário final (MADICHARLA, 2025). Para situações mais sensíveis, o fluxo pode ainda incluir uma camada adicional de aprovação por um especialista humano antes da liberação da correção (PÖHLER et al., 2025).

2.5 STREAMLIT

O Streamlit é um *framework* de código aberto em linguagem Python que permite a criação rápida de aplicações web interativas, sendo amplamente utilizado no ecossistema de ciência de dados e inteligência artificial (Streamlit Inc., 2024). Sua principal vantagem reside na capacidade de construir interfaces funcionais conectadas a rotinas complexas de IA sem a necessidade de conhecimento em HTML, CSS ou JavaScript, o que reduz drasticamente o tempo de desenvolvimento de protótipos (Streamlit Inc., 2024). Por operar como uma aplicação independente (*stand-alone*) que se conecta diretamente a um banco de dados, sem exigir alterações no código-fonte do sistema que o origina, o Streamlit é especialmente adequado para a construção de camadas de supervisão desacopladas de sistemas legados (MADICHARLA, 2025; Ruiz Gómez et al., 2025).

2.6 INTEGRAÇÃO DE LLMS COM BANCOS DE DADOS RELACIONAIS

A integração entre Modelos de Linguagem de Grande Escala e bancos de dados relacionais representa uma das áreas mais ativas de pesquisa em sistemas inteligentes aplicados (HONG et al., 2024). O conceito central dessa integração é permitir que um modelo de linguagem interprete instruções em linguagem natural e as converta em consultas SQL executáveis, abordagem conhecida como *Text-to-SQL* (HONG et al., 2024). Frameworks como o LangChain viabilizam essa integração ao fornecer abstrações que gerenciam a conexão entre o modelo de linguagem e fontes de dados externas, incluindo bancos de dados relacionais, documentos e APIs (CHASE, 2022).

O Firebird é um sistema de gerenciamento de banco de dados relacional de código

aberto que surgiu como *fork* do InterBase 6.0 da Borland em 2000, mantendo forte integração com o ecossistema Delphi (Firebird Project, 2024). Essa relação histórica fez com que a maioria dos ERPs desenvolvidos em Delphi adotasse o Firebird como banco de dados padrão. Tipicamente, esse tipo de integração funciona em etapas bem definidas: o modelo recebe o DDL (*Data Definition Language*) do banco de dados, ou seja, a estrutura completa das tabelas, colunas, tipos de dados e relacionamentos (Ruiz Gómez et al., 2025); com esse mapeamento, o agente passa a compreender a organização semântica dos dados e, ao receber uma instrução em linguagem natural, o LangChain converte essa intenção em uma consulta SQL executável (CHASE, 2022). Por questões de segurança, recomenda-se que a camada de integração imponha restrições (*guardrails*) que bloqueiem comandos destrutivos como `DROP` e `DELETE`, restringindo o agente a operações de leitura (`SELECT`) durante a fase de diagnóstico (ROYCHOWDHURY et al., 2025).

Além da conversão de linguagem natural para SQL, o LangChain oferece suporte ao conceito de RAG (*Retrieval-Augmented Generation*), que permite ao modelo consultar fontes externas de conhecimento, como tabelas NCM em formato PDF ou manuais regulatórios, antes de formular sua resposta (LEWIS et al., 2020). Essa capacidade é especialmente útil no domínio fiscal, onde a classificação correta de um produto frequentemente exige a consulta a documentos externos que não estão presentes no banco de dados do ERP (KIM; MIN, 2025).

2.7 TRABALHOS CORRELATOS

A aplicação de agentes baseados em LLMs para manipulação e qualidade de dados em ambientes empresariais é um campo de pesquisa em rápida expansão. A seguir, são apresentados três trabalhos que se relacionam diretamente com a proposta deste TCC.

Ruiz Gómez et al. (2025) apresentam um agente LLM capaz de interagir com um sistema ERP industrial por meio de linguagem natural, traduzindo consultas em instruções SQL executáveis por meio de uma arquitetura dual-agente. O trabalho demonstra a viabilidade técnica da integração entre LLMs e sistemas ERP complexos, utilizando o LangChain como camada de orquestração. A principal contribuição do estudo é comprovar que a abordagem baseada em agentes consegue operar sobre bases de dados reais de produção, aproximando-se diretamente da proposta deste trabalho.

Bendinelli, Dox e Holz (2025) investigam o uso de agentes LLM para limpeza de *datasets* tabulares, demonstrando que esses modelos são capazes de identificar e corrigir en-

tradas incorretas ao explorar informações contextuais de outras colunas do mesmo registro. Os resultados evidenciam que os LLMs apresentam taxas de acerto superiores às de métodos heurísticos tradicionais em tarefas de detecção de inconsistências em dados estruturados, reforçando a base técnica para o módulo de identificação proposto neste trabalho.

Por fim, Kim e Min (2025) propõem o QA-RAG, um sistema que integra IA generativa para automação de processos de conformidade regulatória farmacêutica. O trabalho demonstra que a integração de LLMs com mecanismos de recuperação de documentos permite tratar requisitos regulatórios complexos de forma estruturada, reforçando a eficácia do uso de agentes para garantir a conformidade em domínios rigorosos. Esse resultado reforça a escolha do paradigma *Human-in-the-Loop* adotado neste projeto, evidenciando que a colaboração entre inteligência artificial e supervisão humana é não apenas uma medida de segurança, mas também um fator de melhoria contínua na qualidade do sistema (NATARAJAN et al., 2025).

Em conjunto, os três trabalhos demonstram que a integração de LLMs com sistemas de gerenciamento de dados empresariais é tecnicamente viável e produz resultados superiores aos de abordagens baseadas em regras estáticas. Entretanto, nenhum deles aborda o domínio específico da legislação fiscal brasileira nem considera as particularidades das validações impostas pela SEFAZ no processo de emissão de NF-e. Esta proposta se diferencia por três aspectos: o recorte temático no nicho fiscal-tributário brasileiro, com suas regras específicas de CST, CFOP e NCM; a integração direta com um sistema ERP real do setor automotivo nacional; e o foco na redução de chamados de suporte técnico como métrica de valor prático. Enquanto os trabalhos correlatos validam a abordagem agêntica em contextos genéricos ou internacionais, este trabalho a aplica a um problema regulatório concreto, inserido no contexto do sistema tributário brasileiro.

3 METODOLOGIA

Este trabalho caracteriza-se como uma pesquisa aplicada de abordagem experimental, estruturada na forma de estudo de caso no sistema ERP Lux Auto. Todo o conhecimento prévio e as regras de negócio associadas ao Lux Auto relatados neste trabalho originam-se da experiência profissional do autor no suporte técnico e desenvolvimento do software. O objetivo é desenvolver e validar um agente autônomo capaz de identificar e corrigir inconsistências fiscais em cadastros. Para garantir a validade externa da avaliação, o conjunto de casos de teste será composto por duas fontes complementares: registros reais de rejeição de NF-e extraídos do sistema Lux Auto, devidamente anonimizados e tratados em conformidade estrita com a Lei Geral de Proteção de Dados (LGPD), assegurando que nenhuma informação sensível seja exposta, e cenários sintéticos elaborados para cobrir combinações de inconsistências sub-representadas nos dados históricos. Essa composição evita a circularidade de avaliar o agente exclusivamente com dados criados ad hoc pelo próprio pesquisador, aproximando os resultados de condições reais de operação e aumentando a validade externa do experimento.

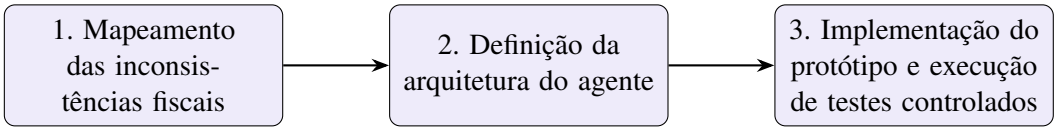
O desenvolvimento será conduzido em etapas sequenciais. A primeira consiste no mapeamento das inconsistências fiscais mais recorrentes no contexto de emissão de NF-e, sendo delimitadas para este trabalho quatro categorias principais: divergência entre Inscrição Estadual e Indicador de Contribuinte, classificação incorreta de NCM, aplicação equivocada de CST e preenchimento incorreto de CFOP. A segunda etapa compreende a definição da arquitetura do agente, composta por um módulo de conexão ao banco de dados via Python, um módulo de análise baseado em Modelo de Linguagem de Grande Escala (priorizando a adoção do modelo de código aberto Llama, em suas versões mais recentes compatíveis com a execução local) orquestrado com LangChain, e uma interface de supervisão humana desenvolvida em Streamlit, permitindo que o operador visualize a inconsistência identificada e aprove ou rejeite a correção proposta antes de sua execução.

A terceira etapa consiste na implementação do protótipo e na execução de testes controlados sobre o conjunto de casos descrito acima. A eficácia do agente será mensurada por duas métricas: (1) **taxa de detecção**, proporção de inconsistências corretamente identificadas em relação ao total de casos presentes no conjunto de teste; e (2) **taxa de acerto das correções**, proporção de propostas conformes à legislação vigente e prontas para execução sem ajuste manual. Estabelecem-se como critérios de sucesso uma taxa de detecção igual ou superior a

85% e uma taxa de acerto das correções de pelo menos 75%. Essas metas são definidas como referência de viabilidade pragmática: como demonstrado por sistemas similares de governança de dados impulsionados por LLMs, que alcançam níveis de aprovação humana consistentes (VEDAT et al., 2025), obter uma precisão em torno de 75% em um domínio complexo (e com a retaguarda do paradigma *Human-in-the-Loop*) já representa uma drástica redução na carga de trabalho manual do suporte técnico, garantindo eficiência sem sacrificar a segurança.

A Figura 2 sintetiza a sequência dessas três etapas.

Figura 2 – Etapas sequenciais do desenvolvimento do trabalho.



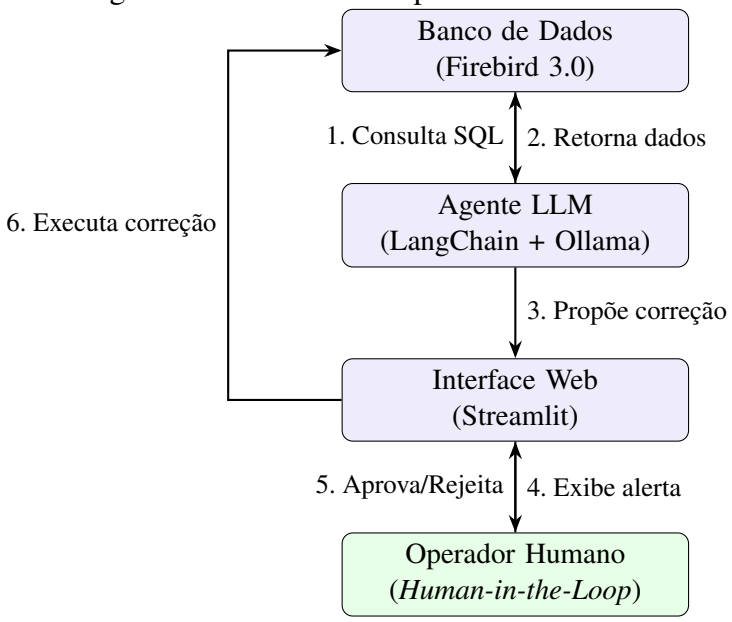
Fonte: O autor (2026).

3.1 ARQUITETURA DA SOLUÇÃO PROPOSTA

Esta seção detalha a arquitetura técnica que materializa a segunda etapa descrita anteriormente, especificando como os módulos de conexão ao banco de dados, análise via LLM e supervisão humana se articulam na prática.

Para mitigar o risco de decisões totalmente autônomas em um domínio crítico como o fiscal, este trabalho adota o paradigma *Human-in-the-Loop* (HITL), no qual o fluxo de automação é intencionalmente interrompido antes de qualquer alteração permanente no banco de dados. O agente elabora o diagnóstico e formula a proposta de correção, mas aguarda a validação e aprovação de um operador humano antes da execução (CHENG; CHENG, 2026). A Figura 3 ilustra esse fluxo.

Figura 3 – Arquitetura do agente autônomo com supervisão *Human-in-the-Loop*.



Fonte: O autor (2026).

Conforme ilustrado na Figura 3, a confirmação humana atua como uma camada de segurança final na arquitetura. Essa abordagem também privilegia a acessibilidade: o alerta gerado pelo agente na interface é formulado em linguagem simples e direta, sem expor termos técnicos ao usuário final (MADICHARLA, 2025). Por exemplo, no caso de um NCM incorreto, a mensagem seguiria o formato: *"Identificamos que o NCM do produto X está desatualizado. Sugerimos atualizá-lo para 1234.56.78, de acordo com a tabela da Receita Federal. Caso discorde, não confirme a alteração."* A aplicação do LLM neste fluxo, portanto, não visa a autonomia total do modelo, mas sua utilização como ferramenta de análise e proposição, sempre subordinada à validação humana (NATARAJAN et al., 2025).

Para situações mais sensíveis, o fluxo pode incluir uma camada adicional de aprovação pelo suporte técnico da desenvolvedora do ERP. Nesse cenário, o agente identifica o problema e notifica o cliente para que acione o suporte; o técnico avalia a situação e, se concordar com a correção sugerida, libera a execução (PÖHLER et al., 2025). Mesmo com essa etapa intermediária, o tempo de resolução é significativamente menor do que o atendimento convencional.

A interface de supervisão é desenvolvida com o *framework* Streamlit. No contexto deste trabalho, a integração direta de funcionalidades de IA dentro do código-fonte do ERP Lux Auto, desenvolvido em Delphi, demandaria um esforço técnico excessivo e ofereceria alto risco à estabilidade do sistema em produção. O Streamlit contorna essa barreira ao operar como uma

aplicação independente (*stand-alone*) que se conecta diretamente ao mesmo banco de dados utilizado pelo ERP, assegurando que o agente leia e analise os dados de forma completamente independente do sistema principal, sem impactar ou modificar o código original do ERP (MADICHARLA, 2025). A premissa central do uso do Streamlit neste projeto é a escalabilidade da solução: como a comunicação ocorre diretamente com o banco de dados relacional, sem necessidade de interagir com o código da aplicação ERP, o agente pode ser adaptado para qualquer sistema que utilize um banco de dados acessível, independentemente da linguagem ou arquitetura em que o ERP foi desenvolvido (Ruiz Gómez et al., 2025).

No ambiente do Lux Auto, o banco de dados utilizado é o Firebird 3.0 (Firebird Project, 2024), escolha natural dado o histórico de forte integração entre esse SGBD e o ecossistema Delphi. A arquitetura de integração implementada funciona em etapas bem definidas. Inicialmente, o modelo recebe o DDL (*Data Definition Language*) do banco de dados, ou seja, a estrutura completa das tabelas, colunas, tipos de dados e relacionamentos (Ruiz Gómez et al., 2025). Com esse mapeamento, o agente passa a compreender a organização semântica dos dados. Em seguida, ao receber uma instrução, como "identificar produtos com NCM zerado", o LangChain converte essa intenção em uma consulta SQL e a submete ao Firebird (CHASE, 2022). Para garantir a segurança da operação, a camada de integração impõe restrições (*guardrails*) que bloqueiam comandos destrutivos como `DROP` e `DELETE`, permitindo que o agente opere apenas em modo de leitura (`SELECT`) durante a fase de diagnóstico (ROYCHOWDHURY et al., 2025). Somente após a aprovação humana na interface Streamlit é que um comando de atualização (`UPDATE`) é executado de forma controlada.

3.2 ORÇAMENTO

O desenvolvimento deste trabalho não prevê custos. As ferramentas utilizadas, como Python, LangChain, Streamlit e Firebird, são de código aberto e gratuitas. Quanto ao uso de modelos de linguagem, será priorizada a utilização de modelos da família Llama executados localmente por meio da ferramenta Ollama, o que elimina custos de API.

4 CRONOGRAMA

O desenvolvimento do trabalho está planejado conforme o cronograma apresentado no Quadro 1, compreendendo o período de julho a dezembro de 2026.

Quadro 1 – Cronograma de execução do TCC

Atividade	**Jul.**	**Ago.**	**Set.**	**Out.**	**Nov.**	**Dez.**
Aprofundamento da fundamentação teórica	X	X				
Mapeamento das inconsistências (logs reais Lux Auto)	X	X				
Refinamento da arquitetura do agente		X	X			
Implementação do protótipo		X	X	X		
Construção do conjunto de testes			X	X		
Execução dos testes controlados e validação				X	X	
Análise e discussão dos resultados					X	
Redação do TCC			X	X	X	
Revisão (normas ABNT) e preparação da defesa					X	X
Entrega final e defesa						X

Fonte: Elaborado pelo autor (2026).

5 RESULTADOS ESPERADOS

Espera-se que o agente autônomo desenvolvido neste trabalho seja capaz de identificar e propor correções para inconsistências fiscais em cadastros de clientes de sistemas ERP, alcançando uma taxa de acerto satisfatória nas categorias mapeadas. Especificamente, os resultados esperados incluem:

- **Taxa de identificação de inconsistências:** O agente deverá ser capaz de detectar corretamente as inconsistências fiscais presentes nos cenários de teste simulados, incluindo divergências entre Inscrição Estadual e Indicador de Contribuinte, classificação incorreta de NCM, aplicação equivocada de CST e preenchimento incorreto de CFOP. Almeja-se uma taxa de detecção igual ou superior a 85% dos casos inseridos no banco de dados de testes;
- **Taxa de acerto nas correções propostas:** Para os casos identificados, o agente deverá formular propostas de correção que estejam em conformidade com a legislação fiscal vigente. Espera-se que pelo menos 75% das correções sugeridas pelo modelo estejam corretas e prontas para execução sem necessidade de ajuste manual pelo operador humano;
- **Redução simulada na demanda de suporte:** Ao automatizar a triagem e a formulação de soluções para problemas cadastrais fiscais, espera-se demonstrar que uma parcela significativa dos chamados que atualmente exigem intervenção do suporte técnico poderia ser resolvida de forma autônoma pelo agente sob supervisão do próprio usuário;
- **Usabilidade da interface de supervisão:** A interface desenvolvida em Streamlit deverá apresentar as propostas de correção em linguagem acessível ao usuário final, permitindo que operadores com diferentes níveis de conhecimento técnico compreendam o que será alterado e decidam de forma informada sobre a aprovação ou rejeição da correção;
- **Viabilidade de execução local:** A solução deverá ser executável em hardware convencional (notebook com 8 GB de VRAM), utilizando modelos de linguagem de código aberto via Ollama, sem dependência de APIs externas e sem custos recorrentes de inferência.

A validação desses resultados será realizada por meio de testes controlados em ambiente simulado, conforme descrito na metodologia, utilizando um banco de dados Firebird 3.0

populado com dados fictícios que reproduzem cenários reais de inconsistências fiscais encontrados na operação do ERP Lux Auto.

REFERÊNCIAS

ARORA, Jitesh Kumar; ERTURK, Emre. **An Exploratory Study on the Implementation and Adoption of ERP Solutions for Businesses**. 2017. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/1701.08329>.

BENDINELLI, Tommaso; DOX, Artur; HOLZ, Christian. **Exploring LLM Agents for Cleaning Tabular Machine Learning Datasets**. 2025. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2503.06664>.

BRASIL. **Ajuste SINIEF 07/2005: Institui a Nota Fiscal Eletrônica e o Documento Auxiliar da Nota Fiscal Eletrônica**. 2005. Acesso em: 01 maio 2026. Disponível em: <https://www.confaz.fazenda.gov.br/legislacao/ajustes/2005/AJ007_05>.

BRASIL. **Emenda Constitucional nº 132, de 20 de dezembro de 2023. Altera o Sistema Tributário Nacional.** 2023. Acesso em: 09 jun. 2026. Disponível em: <https://www.planalto.gov.br/ccivil_03/constituicao/emendas/emc/emc132.htm>.

CHASE, Harrison. **LangChain**. 2022. Framework open-source para desenvolvimento de aplicações com LLMs. Acesso em: 01 maio 2026. Disponível em: <https://github.com/langchain-ai/langchain>.

CHENG, Edward; CHENG, Jeshua. **A Decoupled Human-in-the-Loop System for Controlled Autonomy in Agentic Workflows**. 2026. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2604.23049>.

CHENG, Edward C.; CHENG, Jeshua; SIU, Alice. **Toward Safe and Responsible AI Agents: A Three-Pillar Model for Transparency, Accountability, and Trustworthiness**. 2025. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2601.06223>.

CHIMPIRI, Tirumala Rao. Ensuring data quality in ERP implementations: Key conversion considerations. **International Journal of Advance Research in Computer and Communication Engineering**, v. 13, n. 3, 2024. Acesso em: 01 maio 2026. Disponível em: <https://www.researchgate.net/publication/379352537>.

DOUGLAS, Michael R. **Large Language Models**. 2023. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2307.05782>.

ENCAT; SEFAZ. **Manual de Orientação do Contribuinte: Padrões Técnicos de Comunicação da Nota Fiscal Eletrônica**. 7.0. ed. [S.l.], 2020. Acesso em: 01 maio 2026. Disponível em: <https://www.nfe.fazenda.gov.br>.

Firebird Project. **About Firebird**. 2024. Documentação oficial descrevendo o Firebird como fork open-source do InterBase 6.0. Acesso em: 01 maio 2026. Disponível em: <https://firebirdsql.org/en/about-firebird/>.

GHOLAMIAN, Sina et al. LLM-based robust product classification in commerce and compliance. In: **Proceedings of the 1st Workshop on Customizable NLP: Progress and Challenges in Customizing NLP for a Domain, Application, Group, or Individual (CustomNLP4U)**. Association for Computational Linguistics, 2024. p. 26–36. Acesso em: 09 jun. 2026. Disponível em: <https://doi.org/10.18653/v1/2024.customnlp4u-1.3>.

HONG, Zijin et al. Next-generation database interfaces: A survey of LLM-based text-to-SQL. **IEEE Transactions on Knowledge and Data Engineering**, 2024. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2406.08426>.

HUANG, Lei et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. **ACM Transactions on Information Systems**, v. 43, n. 1, p. 1–38, 2025. Acesso em: 01 maio 2026. Disponível em: <https://doi.org/10.1145/3703155>.

JURAYJ, William; HOLZENBERGER, Nils; Van Durme, Benjamin. Language models and logic programs for trustworthy tax reasoning. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. AAAI Press, 2026. v. 40, n. 45, p. 38688–38698. Acesso em: 01 maio 2026. Disponível em: <https://doi.org/10.1609/aaai.v40i45.41212>.

KIM, Jaewoong; MIN, Moohong. From RAG to QA-RAG: Integrating generative AI for pharmaceutical regulatory compliance process. In: **Proceedings of the 40th ACM/SIGAPP Symposium on Applied Computing**. ACM, 2025. p. 1293–1295. Acesso em: 09 jun. 2026. Disponível em: <https://doi.org/10.1145/3672608.3707749>.

LAUKKANEN, Sanna; SARPOLA, Sami; HALLIKAINEN, Petri. Enterprise size matters: objectives and constraints of ERP adoption. **Journal of Enterprise Information Management**, Emerald, v. 20, n. 3, p. 319–334, 2007. Acesso em: 09 jun. 2026. Disponível em: <https://doi.org/10.1108/17410390710740763>.

LEWIS, Patrick et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: **Advances in Neural Information Processing Systems**. [s.n.], 2020. v. 33. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2005.11401>.

LIU, Zechun et al. LLM-QAT: Data-free quantization aware training for large language models. In: **Findings of the Association for Computational Linguistics: ACL 2024**. Association for Computational Linguistics, 2024. p. 467–484. Acesso em: 09 jun. 2026. Disponível em: <https://doi.org/10.18653/v1/2024.findings-acl.26>.

MADICHARLA, Kalyan Pavan Kumar. Human-in-the-loop LLMOps: Balancing automation and control. **World Journal of Advanced Engineering Technology and Sciences**, v. 15, n. 2, p. 1092–1099, 2025. Acesso em: 01 maio 2026.

MEHTA, Rushabh. Beyond accuracy: Rethinking data quality as a strategic pillar in ERP implementation. **International Journal of Data Science and Machine Learning**, v. 5, n. 1, p. 400–409, 2025. Acesso em: 01 maio 2026.

NATARAJAN, Sriraam et al. Human-in-the-loop or AI-in-the-loop? Automate or collaborate? In: **Proceedings of the AAAI Conference on Artificial Intelligence**. AAAI Press, 2025. v. 39, n. 27, p. 28594–28600. Acesso em: 01 maio 2026. Disponível em: <https://doi.org/10.1609/aaai.v39i27.35083>.

NAY, John J. et al. Large language models as tax attorneys: a case study in legal capabilities emergence. **Philosophical Transactions of the Royal Society A**, The Royal Society, v. 381, n. 2260, 2023. Acesso em: 01 maio 2026. Disponível em: <https://doi.org/10.1098/rsta.2022.0327>.

Ollama. **Ollama: Get up and running with large language models locally**. 2023. Acesso em: 01 maio 2026. Disponível em: <https://ollama.com>.

PAN, Guanzhong et al. **A Cost-Benefit Analysis of On-Premise Large Language Model Deployment: Breaking Even with Commercial LLM Services**. 2025. Acesso em: 18 jun. 2026. Disponível em: <https://arxiv.org/abs/2509.18101>.

PÖHLER, Jan et al. Keeping the human in the loop: are autonomous decisions inevitable? **i-com**, De Gruyter, v. 24, n. 1, p. 9–25, 2025. Acesso em: 01 maio 2026. Disponível em: <https://doi.org/10.1515/icom-2024-0068>.

QU, Changle et al. Tool learning with large language models: A survey. **Frontiers of Computer Science**, 2024. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2405.17935>.

ROYCHOWDHURY, Aparup et al. Design and implementation of an AI agent for natural language-driven database operations. In: **2025 6th International Conference on IoT Based Control Networks and Intelligent Systems (ICICNIS)**. [S.l.: s.n.], 2025. Acesso em: 01 maio 2026.

Ruiz Gómez, Jorge et al. **Chatting with your ERP: A Recipe**. 2025. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2507.23429>.

SCHELTER, Sebastian et al. Automating large-scale data quality verification. **Proceedings of the VLDB Endowment**, v. 11, n. 12, p. 1781–1794, 2018. Acesso em: 01 maio 2026. Disponível em: <https://doi.org/10.14778/3229863.3229867>.

SEFAZ-PE. **Nota Fiscal Eletrônica: Perguntas e Respostas**. [S.l.], 2016. Acesso em: 01 maio 2026. Disponível em: <https://www.sefaz.pe.gov.br/Publicacoes/Manuais>.

SHAO, Minghao et al. **Survey of different Large Language Model Architectures: Trends, Benchmarks, and Challenges**. 2024. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2412.03220>.

SINDIREPA BRASIL. **Anuário da Indústria de Reparação de Veículos do Brasil 2023**. 2023. Dados baseados na RAIS e CNAE 4520-0. Acesso em: 01 maio 2026. Disponível em: <https://www.sindirepabrasil.org.br>.

Streamlit Inc. **Streamlit Documentation**. 2024. Acesso em: 01 maio 2026. Disponível em: <https://docs.streamlit.io>.

van Everdingen, Yvonne; van Hillegersberg, Jos; WAARTS, Eric. Enterprise resource planning: ERP adoption by European midsize companies. **Communications of the ACM**, ACM, v. 43, n. 4, p. 27–31, 2000. Acesso em: 09 jun. 2026. Disponível em: <https://doi.org/10.1145/332051.332064>.

VASWANI, Ashish et al. Attention is all you need. In: **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2017. v. 30, p. 5998–6008. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/1706.03762>.

VEDAT, Sedat Bin et al. **RAG-Driven Data Quality Governance for Enterprise ERP Systems**. 2025. Acesso em: 01 maio 2026. Disponível em: <https://arxiv.org/abs/2511.16700>.

WANG, Lei et al. A survey on large language model based autonomous agents. **Frontiers of Computer Science**, v. 18, n. 6, p. 186345, 2024. Acesso em: 01 maio 2026. Disponível em: <https://doi.org/10.1007/s11704-024-40231-1>.

XU, Huiying et al. Data quality issues in implementing an ERP. **Industrial Management & Data Systems**, Emerald Publishing, v. 102, n. 1, p. 47–58, 2002. Acesso em: 01 maio 2026. Disponível em: <https://doi.org/10.1108/02635570210414668>.

ZHOU, Zixuan et al. **A Survey on Efficient Inference for Large Language Models**. 2024. Acesso em: 09 jun. 2026. Disponível em: <https://arxiv.org/abs/2404.14294>.