Ministério da Educação
Secretaria de Educação Profissional e Tecnológica
Instituto Federal Catarinense
Câmpus Videira

GABRIEL NOGUEIRA

CLASSIFICAÇÃO FISCAL NCM ASSISTIDA POR MODELOS DE LINGUAGEM EXECUTADOS LOCALMENTE, COM SUPERVISÃO HUMANA, EM UM SISTEMA ERP

Videira
2026

GABRIEL NOGUEIRA

CLASSIFICAÇÃO FISCAL NCM ASSISTIDA POR MODELOS DE LINGUAGEM EXECUTADOS LOCALMENTE, COM SUPERVISÃO HUMANA, EM UM SISTEMA ERP

Trabalho de Conclusão de Curso apresentado ao Curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Câmpus Videira para obtenção do título de bacharel em Ciência da Computação.
Orientador: Fabricio Bizotto

Videira
2026

GABRIEL NOGUEIRA

CLASSIFICAÇÃO FISCAL NCM ASSISTIDA POR MODELOS DE LINGUAGEM EXECUTADOS LOCALMENTE, COM SUPERVISÃO HUMANA, EM UM SISTEMA ERP

Este Trabalho de Curso foi julgado adequado para a obtenção do título de Bacharel em Ciência da Computação e aprovado em sua forma final pelo curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Campus Videira.

Videira (SC), dia de mês de ano

Fabricio Bizotto
Instituto Federal Catarinense – Campus Videira

BANCA EXAMINADORA

Fabio Pinheiro
Instituto Federal Catarinense – Campus Videira

Tiago Heineck
Instituto Federal Catarinense – Campus Videira

RESUMO

Inconsistências na classificação fiscal de produtos em sistemas de gestão empresarial (ERPs), como a Nomenclatura Comum do Mercosul (NCM) vazia, inexistente ou de outro produto, levam à rejeição da Nota Fiscal Eletrônica ou à tributação incorreta e geram demanda recorrente ao suporte técnico. Este trabalho desenvolve e avalia um protótipo de classificação fiscal NCM assistida por Modelos de Linguagem de Grande Escala (LLMs) executados localmente, integrado ao banco de dados Firebird do ERP Lux Auto, no qual o modelo apenas sugere e nenhuma alteração é gravada sem aprovação humana. Códigos inválidos são detectados por consulta determinística à tabela oficial. A sugestão combina a expansão de abreviações, uma busca lexical (SQLite FTS5 com BM25, sinônimos e fusão de rankings), uma base de conhecimento com produtos já classificados por duas lojas de autopeças, consultada por vizinhos mais próximos, e duas escolhas do modelo Qwen3 8B restritas por esquema JSON, de modo que o modelo só pode responder com códigos existentes. Códigos válidos são apontados como possivelmente incorretos quando ficam fora das três sugestões e o modelo julga o texto oficial incompatível com o produto. A avaliação usou conjuntos separados de desenvolvimento e de teste, este medido uma única vez. A detecção apontou todos os códigos vazios, malformados, inexistentes e extintos, sem falsos positivos em mais de 41 mil produtos reais; para códigos válidos, porém incorretos, teve acurácia de 86,6% no desenvolvimento e de 88,8% em erros reais de uma loja, em que apontou todos os 40 produtos cadastrados com um código “coringa”, e de 86,0% no teste, com 6,0% de alarmes falsos e 78,0% dos erros plantados apontados. Na sugestão, a versão final acertou o código em primeiro lugar em 48,0% e entre as três opções em 58,0% dos 50 produtos de teste, em 13,7 segundos por produto, contra 28,0% e 46,0% da melhor combinação de busca e base de conhecimento sem modelo de linguagem; nos produtos automotivos, foco do ERP, acertou 83,3% em primeiro lugar. A meta de 75% de acerto foi atingida apenas no recorte automotivo, e a maior parte dos erros restantes decorre da distância entre o nome comercial do produto e o texto oficial da tabela. Os resultados indicam que um LLM pequeno executado localmente é viável como assistente de classificação fiscal, desde que restrito a escolher entre candidatos verificados, apoiado em exemplos reais e subordinado à aprovação humana.

Palavras-chave: Modelos de Linguagem de Grande Escala. Classificação Fiscal. NCM. Geração Aumentada por Recuperação. *Human-in-the-Loop*. ERP.

ABSTRACT

Inconsistencies in the tax classification of products in Enterprise Resource Planning (ERP) systems, such as a Mercosur Common Nomenclature (NCM) code that is empty, nonexistent or belongs to another product, cause Brazilian electronic invoices to be rejected or taxed incorrectly and create recurring demand for technical support. This work develops and evaluates a prototype for NCM classification assisted by locally run Large Language Models (LLMs), integrated with the Firebird database of the Lux Auto ERP, in which the model only suggests and no change is written without human approval. Invalid codes are detected by a deterministic lookup in the official table. Suggestion combines abbreviation expansion, lexical retrieval (SQLite FTS5 with BM25, synonyms and rank fusion), a knowledge base of products already classified by two auto parts stores, queried by nearest neighbors, and two choices by the Qwen3 8B model constrained by a JSON schema, so the model can only answer with existing codes. Valid codes are flagged as possibly incorrect when they fall outside the three suggestions and the model judges the official text incompatible with the product. The evaluation used separate development and test sets, the latter measured only once. Detection flagged every empty, malformed, nonexistent and discontinued code, with no false positives among more than 41 thousand real products; for valid but incorrect codes, it reached 86.6% accuracy in development and 88.8% on real errors from one store, where it flagged all 40 products registered with a "catch-all" code, and 86.0% on the test set, with a 6.0% false alarm rate and 78.0% of the planted errors flagged. For suggestion, the final version ranked the correct code first for 48.0% and among the three options for 58.0% of the 50 test products, in 13.7 seconds per product, against 28.0% and 46.0% for the best combination of retrieval and knowledge base without a language model; for automotive products, the focus of the ERP, it ranked the correct code first for 83.3%. The 75% accuracy target was met only for automotive products, and most remaining errors come from the gap between commercial product names and the official table text. The results indicate that a small, locally run LLM is viable as a tax classification assistant, provided it is restricted to choosing among verified candidates, supported by real examples and subordinate to human approval.

Keywords: Large Language Models. Tax Classification. NCM. Retrieval-Augmented Generation. Human-in-the-Loop. ERP.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxo de rejeição de NF-e e geração de demanda de suporte técnico 15
Figura 2 – Estrutura hierárquica de um código NCM 20
Figura 3 – Etapas do desenvolvimento do trabalho 31
Figura 4 – Arquitetura final do protótipo 38
Figura 5 – Etapas da sugestão de NCM na versão final 40
Figura 6 – Interface de supervisão com as opções sugeridas para um produto 46
Figura 7 – Interface de supervisão com um produto de NCM possivelmente errado . . . 46

LISTA DE QUADROS

Quadro 1 – Comparação entre os trabalhos correlatos e este trabalho 29
Quadro 2 – Ferramentas e versões utilizadas 32
Quadro 3 – Versões do processo de sugestão avaliadas 47

LISTA DE TABELAS

Tabela 1 – Conjuntos de casos utilizados na avaliação da sugestão 33
Tabela 2 – Detecção de NCM inválido por categoria 50
Tabela 3 – Regras de detecção de NCM incorreto nos conjuntos de desenvolvimento . . 51
Tabela 4 – Acerto da opção única por modelo no conjunto dev15 52
Tabela 5 – Versões da primeira fase com o Qwen2.5 7B 53
Tabela 6 – Contribuição de cada recurso na segunda fase (dev + DEV2, 90 produtos) . 53
Tabela 7 – Acerto com e sem o modelo de linguagem 54
Tabela 8 – Resultado no conjunto de teste TESTE2 (50 produtos) 55
Tabela 9 – Erros da versão final no TESTE2, por nível da hierarquia 56
Tabela 10 – Conjunto dev15 69
Tabela 11 – Conjunto dev 69
Tabela 12 – Conjunto teste 71
Tabela 13 – Conjunto DEV2 72
Tabela 14 – Conjunto TESTE2 74
Tabela 15 – Respostas da versão final no conjunto TESTE2 80

LISTA DE ABREVIATURAS E SIGLAS

API	*Application Programming Interface*
BM25	*Best Matching 25* (função de ranqueamento)
CBS	Contribuição sobre Bens e Serviços
CFOP	Código Fiscal de Operações e Prestações
CST	Código de Situação Tributária
ERP	*Enterprise Resource Planning*
FTS	*Full-Text Search*
GECEX	Comitê Executivo de Gestão da Câmara de Comércio Exterior
GPU	*Graphics Processing Unit*
HITL	*Human-in-the-Loop*
HTS	*Harmonized Tariff Schedule*
IBS	Imposto sobre Bens e Serviços
ICMS	Imposto sobre Circulação de Mercadorias e Serviços
JSON	*JavaScript Object Notation*
kNN	*k-Nearest Neighbors* (vizinhos mais próximos)
LGPD	Lei Geral de Proteção de Dados Pessoais
LLM	*Large Language Model*
MOC	Manual de Orientação do Contribuinte
NBS	Nomenclatura Brasileira de Serviços
NCM	Nomenclatura Comum do Mercosul
NF-e	Nota Fiscal Eletrônica
RAG	*Retrieval-Augmented Generation*
RGI	Regras Gerais de Interpretação do Sistema Harmonizado
RRF	*Reciprocal Rank Fusion*

SEFAZ	Secretaria da Fazenda
SH	Sistema Harmonizado de Designação e de Codificação de Mercadorias
SQL	*Structured Query Language*
SVM	*Support Vector Machine*
TEC	Tarifa Externa Comum
VRAM	*Video Random Access Memory*

SUMÁRIO

1 INTRODUÇÃO 13
1.1 Objetivos 14
1.1.1 Objetivo Geral 14
1.1.2 Objetivos Específicos 14
1.2 Justificativa 15
1.3 Estrutura do Trabalho 16
2 FUNDAMENTAÇÃO TEÓRICA 17
2.1 Sistemas ERP 17
2.1.1 Qualidade de Dados em Sistemas ERP 18
2.2 Nota Fiscal Eletrônica e Legislação Fiscal Brasileira 18
2.2.1 Nomenclatura Comum do Mercosul 19
2.3 Modelos de Linguagem de Grande Escala 21
2.3.1 Execução Local e Modelos Abertos 22
2.3.2 Saídas Estruturadas e Decodificação Restrita 22
2.3.3 Engenharia de *Prompt* e Aprendizado com Poucos Exemplos 23
2.4 Agentes e *Human-in-the-Loop* 23
2.5 Recuperação de Informação e Geração Aumentada por Recuperação 24
2.5.1 Busca Lexical e BM25 24
2.5.2 Fusão de Rankings 25
2.5.3 Radicalização, Similaridade e Vizinhos Mais Próximos 25
2.6 Avaliação Experimental de Sistemas de Classificação 26
2.7 Integração de LLMs com Bancos de Dados Relacionais 26
2.8 Trabalhos Correlatos 27
2.8.1 Classificação Automática de NCM e do Sistema Harmonizado 27
2.8.2 LLMs e Dados Empresariais 28
2.8.3 Síntese 29
3 METODOLOGIA 30
3.1 Etapas da Pesquisa 30
3.2 Ambiente Experimental 31
3.3 Fontes de Dados 32

3.4 Conjuntos de Avaliação 33
3.5 Métricas 34
3.6 Protocolo de Avaliação 35
4 DESENVOLVIMENTO DO PROTÓTIPO 37
4.1 Visão Geral da Arquitetura 37
4.2 Base Local da Tabela NCM 38
4.3 Detecção de Produtos com NCM Inválido 39
4.4 Sugestão da Classificação 39
4.4.1 Memória de Classificações 40
4.4.2 Expansão de Abreviações 41
4.4.3 Análise do Produto 41
4.4.4 Busca de Candidatos 41
4.4.5 Escolhas Restritas do Modelo 42
4.5 Base de Conhecimento de Outras Empresas 43
4.6 Verificação de NCM Possivelmente Incorreto 44
4.7 Execução em Segundo Plano e Notificação 45
4.8 Interface de Supervisão 45
4.9 Evolução das Versões 47
5 RESULTADOS E DISCUSSÃO 50
5.1 Detecção de NCM Inválido 50
5.2 Detecção de NCM Possivelmente Incorreto 51
5.3 Comparação entre Modelos de Linguagem 52
5.4 Evolução das Versões no Desenvolvimento 53
5.5 Contribuição do Modelo de Linguagem 54
5.6 Resultado da Versão Final no Conjunto de Teste 55
5.7 Análise dos Erros da Versão Final 55
5.8 Atendimento às Metas do Projeto 56
5.9 Discussão 57
5.9.1 Limitações e Ameaças à Validade 58
6 CONCLUSÃO 60
6.1 Trabalhos Futuros 61
REFERÊNCIAS 63

APÊNDICE A **Conjuntos de Casos** **69**
APÊNDICE B ***Prompts*** **da Versão Final** **77**
APÊNDICE C **Respostas da Versão Final no Conjunto de Teste** **80**

1 INTRODUÇÃO

Nos dias atuais, sistemas de gestão empresarial (ERPs) dependem fortemente da inserção manual de dados cadastrais para o seu pleno funcionamento. Essa dependência operacional gera gargalos significativos, uma vez que a interação humana está sujeita a falhas de digitação ou interpretação (Mehta, 2025). Tais inconsistências em bancos de dados relacionais dividem-se, em geral, em duas categorias. A primeira envolve erros de preenchimento que não impedem o funcionamento básico do sistema, como a inserção de um número de telefone no campo destinado ao endereço. A segunda, e mais crítica, engloba informações que afetam diretamente o ecossistema de integrações do software. Um exemplo claro ocorre no módulo fiscal: quando o cadastro de um cliente apresenta divergências entre a Inscrição Estadual e o Indicador de Contribuinte, ou há a omissão e preenchimento incorreto de códigos obrigatórios como NCM (Nomenclatura Comum do Mercosul), CST (Código de Situação Tributária) e CFOP (Código Fiscal de Operações e Prestações), a emissão da Nota Fiscal Eletrônica (NF-e) é inviabilizada e sumariamente rejeitada pela Secretaria da Fazenda (SEFAZ) (ENCAT; SEFAZ, 2020).

Essas rejeições paralisam o faturamento das empresas e geram uma sobrecarga imediata no setor de suporte técnico, exigindo intervenção manual para correções que, na maioria das vezes, seguem padrões lógicos e regulatórios bem definidos. Nesse cenário, os Modelos de Linguagem de Grande Escala (LLMs) surgem como uma alternativa tecnológica promissora (Wang *et al.*, 2024). Combinados a regras de negócio predefinidas, eles podem ajudar a identificar anomalias e a formular propostas de correção (Roychowdhury *et al.*, 2025). Para garantir a segurança e a integridade da operação no banco de dados, o modelo não age de forma autônoma: ele apenas sugere, e a correção proposta aguarda a validação e a aprovação de um operador humano antes de ser executada, no paradigma conhecido como *Human-in-the-Loop* (Cheng; Cheng, 2026).

Dentre as inconsistências fiscais, a classificação do produto pela NCM se destaca por exigir interpretação. Verificar se um código existe é uma consulta simples; descobrir qual código corresponde a uma descrição como “PARACHOQUE DIANTEIRO GOL” ou “AZULEJO DE BANHEIRO” exige conhecer uma tabela com mais de dez mil itens, organizada hierarquicamente e redigida em linguagem técnica que raramente coincide com o nome comercial do produto (BRASIL. Receita Federal, 2026). Além disso, um código pode existir na tabela e, ainda assim, pertencer a outro produto, erro que nenhuma consulta simples detecta.

Por esses motivos, este trabalho concentra a implementação e a avaliação na NCM do cadastro de produtos, deixando as demais categorias delimitadas no projeto (CST, CFOP e Indicador de Contribuinte) como continuidade natural da arquitetura proposta.

Diante deste contexto, o presente trabalho busca responder à seguinte pergunta de pesquisa: em que medida um modelo de linguagem de pequeno porte, executado localmente e restrito a escolher entre candidatos recuperados da tabela oficial, consegue apontar classificações NCM inválidas ou incorretas no cadastro de produtos de um ERP e sugerir a classificação correta, em tempo compatível com o uso diário e sob supervisão humana?

1.1 OBJETIVOS

1.1.1 Objetivo Geral

Desenvolver e avaliar um protótipo de classificação fiscal NCM assistida por modelos de linguagem executados localmente, integrado ao banco de dados do ERP Lux Auto, que aponte produtos com NCM inválido ou possivelmente incorreto e sugira a classificação a partir da descrição do produto, com aprovação humana obrigatória antes de qualquer alteração no banco de dados.

1.1.2 Objetivos Específicos

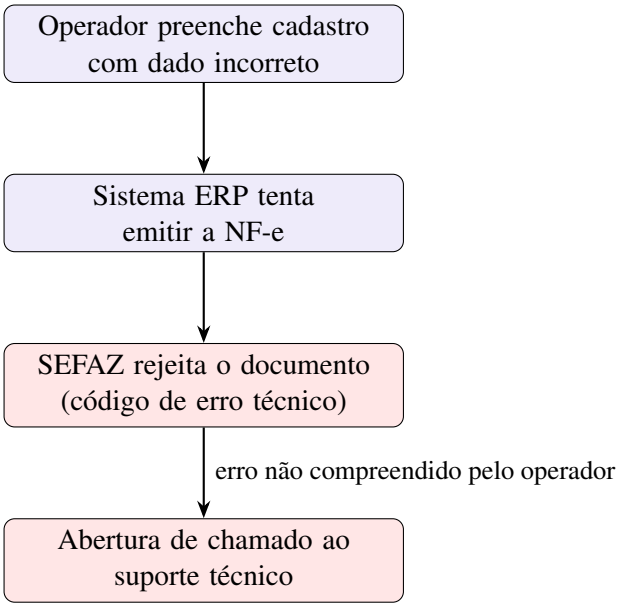
- Delimitar, a partir da experiência do autor no suporte técnico do Lux Auto, as inconsistências fiscais do cadastro que impedem a emissão de NF-e, e justificar a escolha da classificação NCM de produtos como foco da implementação;
- Estruturar a tabela NCM oficial em uma base local consultável, que permita validar códigos e recuperar candidatos a partir de descrições livres sem enviar a tabela inteira ao modelo de linguagem;
- Projetar e implementar o protótipo, com detecção de NCM inválido, detecção de NCM possivelmente incorreto, sugestão de classificação, execução em segundo plano e aprovação por meio de uma interface independente do ERP;
- Construir conjuntos de avaliação separados para desenvolvimento e para teste, com a classificação correta de cada produto conferida na tabela oficial, incluindo códigos inválidos de diferentes tipos e erros de classificação reais extraídos de bases de clientes;

- Avaliar o protótipo quanto à detecção, ao acerto das sugestões e ao tempo de resposta, medindo a contribuição do modelo de linguagem em relação à busca sem modelo e comparando modelos abertos e arquiteturas alternativas.

1.2 JUSTIFICATIVA

A gestão fiscal em sistemas ERP representa um dos principais gargalos operacionais em pequenas e médias empresas do setor automotivo. Inconsistências cadastrais, como divergências entre a Inscrição Estadual e o Indicador de Contribuinte e o preenchimento incorreto de códigos NCM, CST e CFOP, comprometem diretamente a emissão de NF-e, interrompendo o fluxo de faturamento. Problemas de qualidade de dados são reconhecidos como fonte recorrente de dificuldades na operação de ERPs (Xu *et al.*, 2002), e, na experiência do autor no suporte técnico do Lux Auto, erros cadastrais de natureza fiscal estão entre os motivos recorrentes de chamados abertos pelos clientes. Essa observação não se apoia em um levantamento quantitativo do sistema de chamados, que não foi realizado neste trabalho, mas na prática diária de atendimento; por isso, ela é apresentada como delimitação do problema, e não como medida de sua frequência. A Figura 1 sintetiza o fluxo que origina essa demanda.

Figura 1 – Fluxo de rejeição de NF-e e geração de demanda de suporte técnico



Fonte: O autor (2026).

Embora os próprios sistemas ERP sinalizem esses erros ao usuário, a baixa familiaridade dos operadores com terminologia fiscal faz com que as mensagens de erro sejam frequentemente ignoradas, resultando em chamados de suporte para problemas que já foram iden-

tificados pelo sistema, mas não compreendidos pelo usuário. Esse comportamento evidencia que a solução não passa apenas por detectar o erro, mas por interpretá-lo e propor uma correção acessível e supervisionada, de preferência no momento do cadastro, antes que a nota seja emitida.

Nesse contexto, regras fixas resolvem apenas parte do problema. Uma regra consegue dizer que o NCM "00000000" é inválido, mas não consegue dizer que um "PARACHOQUE" deve ser classificado em "8708.10.00 – Para-choques e suas partes": isso exige interpretar a descrição do produto e relacioná-la ao texto da tabela oficial, tarefa em que os LLMs têm demonstrado bom desempenho (Gholamian *et al.*, 2024). Ao mesmo tempo, o risco de alucinação desses modelos (Huang *et al.*, 2025) torna indispensável que a resposta seja verificável e que a decisão final permaneça com um humano (Natarajan *et al.*, 2025). Investigar como equilibrar essas duas necessidades com um modelo pequeno, executado localmente e sem custo de API, e medir quanto o modelo de linguagem acrescenta em relação a uma busca sem ele, é a contribuição prática deste trabalho.

1.3 ESTRUTURA DO TRABALHO

O Capítulo 2 apresenta a fundamentação teórica: sistemas ERP e qualidade de dados, a NF-e e a estrutura da NCM, os LLMs e a engenharia de *prompt*, as técnicas de recuperação de informação e de avaliação empregadas e os trabalhos correlatos, incluindo estudos de classificação automática de NCM e do SH. O Capítulo 3 descreve a metodologia, incluindo o ambiente experimental, os conjuntos de casos e as métricas. O Capítulo 4 detalha a arquitetura e a implementação do protótipo, bem como as versões testadas e descartadas ao longo do desenvolvimento. O Capítulo 5 apresenta e discute os resultados, e o Capítulo 6 traz as conclusões e os trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, são apresentados os conceitos e tecnologias que embasam o desenvolvimento deste trabalho. São abordados o funcionamento dos sistemas ERP e os desafios de qualidade de dados, as exigências da legislação fiscal brasileira para emissão de Notas Fiscais Eletrônicas e a estrutura da NCM, os fundamentos dos Modelos de Linguagem de Grande Escala e da engenharia de *prompt*, a abordagem de agentes com supervisão humana, as técnicas de recuperação de informação empregadas, os conceitos de avaliação experimental adotados, a integração de LLMs com bancos de dados relacionais, apresentada como contraste com a abordagem deste trabalho, e, por fim, os trabalhos correlatos, com ênfase na classificação automática de NCM e do Sistema Harmonizado.

2.1 SISTEMAS ERP

Os sistemas de gestão empresarial, conhecidos pela sigla ERP (do inglês *Enterprise Resource Planning*), são plataformas de software integradas que centralizam e automatizam os principais processos organizacionais em um único ambiente (Arora; Erturk, 2017). Esses sistemas abrangem módulos como financeiro, fiscal, controle de estoque, vendas e relacionamento com clientes, permitindo que informações fluam entre os departamentos de forma padronizada. Sua adoção por pequenas e médias empresas tem crescido de forma expressiva nas últimas décadas, impulsionada pela necessidade de maior controle operacional e pela exigência de conformidade com normas regulatórias cada vez mais rigorosas (Laukkanen; Sarpola; Hallikainen, 2007; van Everdingen; van Hillegersberg; Waarts, 2000).

No setor automotivo brasileiro, especificamente em oficinas mecânicas, os sistemas ERP assumem papel estratégico. Dados do Anuário da Indústria de Reparação de Veículos indicam que o Brasil possui mais de 119 mil estabelecimentos do ramo automotivo (SINDIREPA BRASIL, 2023), o que evidencia a dimensão do mercado e a necessidade de eficiência operacional nesses negócios. Nesse contexto, o ERP integra o controle de ordens de serviço, a gestão de peças e insumos, o cadastro de clientes e fornecedores e a emissão de documentos fiscais em um único fluxo, tornando a consistência dos dados cadastrais um requisito não apenas técnico, mas legal.

Um exemplo prático dessa realidade é o sistema ERP Lux Auto, voltado ao segmento de oficinas mecânicas, desenvolvido em Delphi e com banco de dados Firebird. O sistema

contempla o registro de produtos, o controle de serviços prestados em veículos, cadastros gerais de pessoas e fornecedores, além de módulos de contas a receber e a pagar. Embora ofereça uma interface funcional para usuários experientes, na experiência do autor no suporte técnico, novos clientes frequentemente enfrentam dificuldades nos primeiros meses de uso, e é no módulo fiscal que os problemas mais críticos surgem, pois as validações impostas pelos órgãos governamentais são rígidas e intolerantes a erros de formatação ou classificação.

2.1.1 Qualidade de Dados em Sistemas ERP

A qualidade dos dados armazenados em sistemas ERP é fator determinante para a confiabilidade dos processos organizacionais (Xu *et al.*, 2002). Inconsistências cadastrais, sejam elas provenientes de erros de digitação, falta de padronização ou desconhecimento técnico dos operadores, comprometem a integridade das informações e geram um efeito cascata em todos os processos dependentes desses dados (Chimpiri, 2024). No contexto fiscal, essas inconsistências assumem caráter crítico: campos como Inscrição Estadual, Indicador de Contribuinte, NCM, CST e CFOP são validados por órgãos reguladores no momento da emissão de documentos fiscais eletrônicos (ENCAT; SEFAZ, 2020). A presença de dados incorretos ou em branco nesses campos inviabiliza o faturamento da empresa emissora, gerando demanda urgente e recorrente ao suporte técnico (Mehta, 2025).

Os ERPs atendem negócios dos mais variados perfis, e no nicho de oficinas mecânicas essa discrepância de conhecimento tecnológico fica ainda mais evidente. O sistema precisa atender desde profissionais qualificados em rotinas fiscais até usuários com pouca familiaridade com computação básica. Na experiência do autor com o Lux Auto, a maioria dos gargalos operacionais recai sobre usuários que não conseguem, por conta própria, ajustar campos como NCM ou Indicador de Contribuinte a partir de um código de rejeição devolvido pela SEFAZ. Nesse cenário, mecanismos de validação e correção preventiva, que atuem no momento do cadastro, tornam-se essenciais para manter a operação do negócio ativa (Schelter *et al.*, 2018).

2.2 NOTA FISCAL ELETRÔNICA E LEGISLAÇÃO FISCAL BRASILEIRA

A Nota Fiscal Eletrônica (NF-e) é um documento fiscal digital instituído pelo Ajuste SINIEF 07/2005, que substituiu o modelo em papel e conferiu maior agilidade e controle às operações comerciais (BRASIL, 2005). Sua emissão é regulamentada pela SEFAZ e está condicionada à validação em tempo real por meio de serviços web governamentais, que verificam

centenas de regras de negócio antes de autorizar o documento (ENCAT; SEFAZ, 2020).

Entre os principais campos obrigatórios validados pela SEFAZ, destacam-se o Código de Situação Tributária (CST), que define o tratamento do ICMS aplicável à operação; o Código Fiscal de Operações e Prestações (CFOP), que classifica a natureza da operação comercial; e a Nomenclatura Comum do Mercosul (NCM), que identifica a classificação fiscal do produto e determina suas alíquotas tributárias (SEFAZ-PE, 2016). Além desses, o documento exige a descrição detalhada dos produtos, tributos como IPI, PIS, COFINS e ISS e os dados completos do emitente e do destinatário (ENCAT; SEFAZ, 2020). O Manual de Orientação do Contribuinte define essas validações e associa a cada uma delas um código de rejeição: basta que uma regra não seja atendida, por exemplo um código NCM inexistente na tabela vigente, para que o documento seja rejeitado, interrompendo o fluxo de faturamento da empresa emissora (ENCAT; SEFAZ, 2020).

Com a reforma tributária em curso no Brasil (BRASIL, 2023), que substitui progressivamente os tributos vigentes pelo IBS (Imposto sobre Bens e Serviços) e pela CBS (Contribuição sobre Bens e Serviços), os documentos fiscais eletrônicos passam a exigir novos campos e regras de classificação durante o período de transição. Para sistemas ERP, isso amplia o espaço de possíveis inconsistências cadastrais, tornando ainda mais improvável que um sistema baseado apenas em regras fixas acompanhe todas as combinações válidas. Abordagens que combinam LLMs com representações formais das regras tributárias têm sido propostas como forma de manter a confiabilidade do raciocínio fiscal diante de mudanças regulatórias frequentes (Jurayj; Holzenberger; Van Durme, 2026).

2.2.1 Nomenclatura Comum do Mercosul

A NCM é o sistema de classificação de mercadorias adotado pelos países do Mercosul, utilizado tanto no comércio exterior quanto nas operações internas, como a emissão de NF-e (BRASIL. Receita Federal, 2026). Ela tem por base o Sistema Harmonizado de Designação e de Codificação de Mercadorias (SH), mantido pela Organização Mundial das Aduanas, que padroniza internacionalmente os seis primeiros dígitos do código (WORLD CUSTOMS ORGANIZATION, 2026). A NCM acrescenta dois dígitos próprios, formando um código de oito dígitos organizado de forma hierárquica, como ilustra a Figura 2: os dois primeiros identificam o Capítulo; os quatro primeiros, a Posição; o quinto e o sexto, as Subposições; e o sétimo e o oitavo, o Item e o Subitem. Somente o código completo de oito dígitos é válido para o

cadastro de um produto.

Figura 2 – Estrutura hierárquica de um código NCM

87 Capítulo: Veículos automóveis, tratores, ciclos e outros veículos terrestres, suas partes e acessórios

87.08 Posição: Partes e acessórios dos veículos automóveis das posições 87.01 a 87.05

8708.10.00 Item: Para-choques e suas partes (único nível válido no cadastro)

Fonte: O autor (2026), com base na Tabela NCM vigente.

A tabela vigente utilizada neste trabalho possui 96 capítulos e 10.504 códigos de oito dígitos. Duas características dessa tabela são centrais para o problema estudado. A primeira é que a descrição própria de um item frequentemente só faz sentido junto com os níveis superiores: o item 4011.10.00 é descrito apenas como "Do tipo utilizado em automóveis de passageiros", e é o cabeçalho da posição 40.11 que informa tratar-se de pneumáticos novos de borracha. A segunda é que o texto oficial usa linguagem técnica, distante do nome comercial do produto: "sabonete" aparece como "sabões", "cadeira" como "assentos" e "notebook" como "máquinas automáticas para processamento de dados". Além disso, a classificação segue as Regras Gerais de Interpretação do Sistema Harmonizado (RGI), que integram o texto da Convenção do SH, promulgada no Brasil pelo Decreto nº 97.409/1988 (BRASIL, 1988), e são reproduzidas na NCM vigente, aprovada pela Resolução Gecex nº 272/2021 (BRASIL. Comitê Executivo de Gestão da Câmara de Comércio Exterior, 2021). Pela primeira regra, os títulos das seções e dos capítulos têm valor apenas indicativo, e a classificação é determinada pelos textos das posições e das notas de seção e de capítulo; pela sexta, a mesma lógica se aplica, dentro de uma posição, às subposições. As notas são, portanto, parte da classificação: a Nota 2 da Seção XVII, por exemplo, exclui das "partes e acessórios" de veículos as peças de uso geral, como parafusos, rolamentos e artigos de borracha, que têm posição própria mesmo quando destinadas a automóveis (BRASIL. Comitê Executivo de Gestão da Câmara de Comércio Exterior, 2021).

A tabela também muda ao longo do tempo. A cada atualização, códigos são criados e outros são extintos, e um produto cadastrado com um código extinto passa a ter a nota rejeitada, ainda que o código tenha sido válido quando foi informado. Na atualização em vigor a partir de 1º de setembro de 2022, por exemplo, o código 3923.30.00 foi substituído por 3923.90.10 e 3923.90.90, e o 9403.20.00, por 9403.20.10 e 9403.20.90 (ENCAT, 2022).

Cabe observar que, no Lux Auto, o mesmo campo do cadastro guarda também códigos de serviços, que seguem outra classificação, a Nomenclatura Brasileira de Serviços (NBS). Por isso, a validação da NCM deve se restringir aos itens cadastrados como mercadoria, sob pena de apontar como erro um código de serviço legítimo.

2.3 MODELOS DE LINGUAGEM DE GRANDE ESCALA

Os Modelos de Linguagem de Grande Escala, conhecidos pela sigla LLM (do inglês *Large Language Model*), são sistemas de inteligência artificial baseados na arquitetura *Transformer*, proposta por Vaswani *et al.* (2017). Essa arquitetura utiliza mecanismos de autoatenção (*self-attention*) que permitem ao modelo processar sequências de texto de forma paralela, identificando relações contextuais entre palavras independentemente de sua posição na sentença (Shao *et al.*, 2024). Os LLMs são treinados em volumes massivos de dados textuais, o que lhes confere a capacidade não apenas de gerar texto coerente, mas de interpretar contextos complexos e inferir intenções (Douglas, 2023).

No domínio tributário, essa capacidade tem sido investigada com resultados promissores, mas ainda limitados. Em um estudo sobre a aplicação do direito tributário dos Estados Unidos, Nay *et al.* (2023) observaram que o desempenho dos LLMs melhora a cada nova geração de modelos e, sobretudo, quando o modelo recebe os textos legais pertinentes e exemplos de perguntas e respostas junto com a pergunta, embora ainda sem atingir o nível de especialistas. Embora trate de outra legislação, o resultado indica dois recursos explorados neste trabalho: fornecer ao modelo o texto oficial relevante e orientá-lo com exemplos. A classificação de um produto pelo código NCM, por exemplo, exige a interpretação de descrições textuais e o cruzamento com tabelas regulatórias; em uma tarefa próxima, a classificação de produtos para comércio e conformidade regulatória, LLMs com exemplos fornecidos no contexto superaram abordagens supervisionadas e se mostraram mais robustos a descrições incompletas (Gholamian *et al.*, 2024).

Entretanto, o uso de LLMs em ambientes de produção esbarra em uma limitação crítica: as alucinações, isto é, respostas incorretas geradas pelo modelo com alto grau de confiança (Huang *et al.*, 2025). No ambiente fiscal, uma classificação tributária equivocada pode resultar em recolhimento indevido de impostos e em penalidades. Por essa razão, a literatura recomenda que aplicações de LLMs em domínios sensíveis não busquem a autonomia total do modelo, mas o utilizem como ferramenta de análise e proposição, subordinada à validação

humana (Natarajan *et al.*, 2025).

2.3.1 Execução Local e Modelos Abertos

Modelos proprietários oferecidos via API cobram por volume de *tokens* processados, e esse custo recorrente pode tornar a operação contínua inviável a partir de determinados volumes de uso (Pan *et al.*, 2025). Uma alternativa é a execução local de modelos de código aberto por meio de ferramentas como o Ollama, que permite rodar LLMs diretamente na máquina, sem dependência de serviços externos (Ollama, 2023). Técnicas de otimização de inferência permitem reduzir significativamente os requisitos computacionais desses modelos (Zhou *et al.*, 2024); entre elas, destaca-se a quantização, que reduz a precisão numérica dos parâmetros (tipicamente de 16 para 4 ou 5 *bits*), seja por treinamento com quantização nativa (Liu *et al.*, 2024), seja por quantização pós-treinamento, como nos formatos do padrão GGUF adotado pelo Ollama (Ollama, 2023). Com essa técnica, modelos de 7 a 8 bilhões de parâmetros podem operar com cerca de 6 GB de memória de vídeo (VRAM), como observado neste trabalho, o que viabiliza seu uso em computadores convencionais e mantém os dados da empresa no próprio ambiente.

Três modelos abertos foram utilizados neste trabalho. O Llama 3.1, da Meta, com 8 bilhões de parâmetros, amplamente utilizado como referência em execução local (Grattafiori *et al.*, 2024); o Qwen2.5, da Alibaba, com 7 bilhões de parâmetros, treinado com ênfase em suporte multilíngue e na geração de saídas estruturadas (Qwen Team, 2024); e o Qwen3, sucessor do anterior, cuja versão de 8 bilhões de parâmetros reúne em um mesmo modelo um modo com raciocínio explícito (*thinking*), que escreve etapas intermediárias antes da resposta, e um modo sem raciocínio, mais rápido (Yang *et al.*, 2025). Neste trabalho, o Qwen3 foi usado no modo sem raciocínio, para manter o tempo de resposta compatível com o uso diário.

2.3.2 Saídas Estruturadas e Decodificação Restrita

Um LLM gera texto escolhendo, a cada passo, o próximo *token* a partir de uma distribuição de probabilidades sobre todo o vocabulário. Na decodificação restrita (*constrained decoding* ou *guided generation*), essa escolha é limitada aos *tokens* que mantêm a saída válida segundo uma gramática formal, como uma expressão regular ou um esquema JSON (Willard; Louf, 2023). Na prática, isso garante que a resposta do modelo possa ser lida por um programa e, quando o esquema enumera os valores permitidos para um campo, que o modelo só consiga

responder com um desses valores. O Ollama oferece esse recurso ao aceitar um esquema JSON como formato obrigatório da resposta (Ollama, 2023). Para a classificação fiscal, isso significa que o modelo pode ser impedido, por construção, de inventar um código NCM inexistente: ele só pode escolher entre os códigos apresentados.

2.3.3 Engenharia de *Prompt* e Aprendizado com Poucos Exemplos

O comportamento de um LLM pode ser direcionado sem alterar seus parâmetros, apenas pela forma como a tarefa é descrita no texto de entrada, o *prompt*. A engenharia de *prompt* reúne as técnicas de redação dessas instruções, como definir o papel do modelo, explicitar regras e restringir o formato da resposta (Liu *et al.*, 2023). Uma dessas técnicas é o aprendizado com poucos exemplos (*few-shot*): em vez de treinar o modelo para a tarefa, incluem-se no próprio *prompt* alguns pares de entrada e saída esperada, e o modelo passa a reproduzir o padrão demonstrado (Brown *et al.*, 2020). Os *prompts* do protótipo, reproduzidos no Apêndice B, usam as duas técnicas: um *prompt* de sistema com regras de classificação e exemplos de produtos que não pertencem a nenhum conjunto de avaliação, para que os exemplos não "entreguem" respostas medidas.

2.4 AGENTES E *HUMAN-IN-THE-LOOP*

O avanço dos LLMs permitiu o surgimento de uma nova classe de sistemas: os agentes. Diferentemente de um LLM utilizado de forma isolada, que apenas recebe um texto e gera uma resposta, um agente é um sistema modular no qual o modelo de linguagem atua como motor de raciocínio, recebendo acesso a ferramentas externas para perceber o ambiente e interagir com ele (Wang *et al.*, 2024). Essas ferramentas podem incluir acesso a bancos de dados, APIs, mecanismos de busca e execução de código (Qu *et al.*, 2024).

No contexto de correção de bases de dados, um agente é capaz de: (1) conectar-se a um banco de dados relacional; (2) identificar registros com anomalias com base em regras de domínio; (3) formular uma proposta de correção; e (4) apresentar essa proposta ao operador humano para validação (Roychowdhury *et al.*, 2025). Entretanto, em domínios críticos como o fiscal e o financeiro, a delegação total de decisões a uma inteligência artificial apresenta riscos sistêmicos inaceitáveis (Pöhler *et al.*, 2025).

Para mitigar esse risco, a literatura recomenda a adoção do paradigma *Human-in-the-Loop* (HITL), no qual o fluxo de automação é intencionalmente interrompido antes de

qualquer alteração permanente no banco de dados: o agente elabora o diagnóstico e formula a proposta de correção, mas aguarda a aprovação de um operador humano antes da execução (Cheng; Cheng, 2026). Essa exigência se alinha a modelos mais amplos de segurança e responsabilização de agentes de IA, que defendem a validação progressiva da autonomia como condição para a confiabilidade do sistema (Cheng; Cheng; Siu, 2025). A abordagem também privilegia a acessibilidade, na medida em que a proposta pode ser apresentada em linguagem simples, sem expor termos técnicos ao usuário final (Madicharla, 2025).

2.5 RECUPERAÇÃO DE INFORMAÇÃO E GERAÇÃO AUMENTADA POR RECUPERAÇÃO

Um LLM não conhece de forma confiável o conteúdo atualizado de uma tabela regulatória com milhares de linhas, e a tabela inteira não cabe no contexto de um modelo pequeno. A Geração Aumentada por Recuperação (RAG, do inglês *Retrieval-Augmented Generation*) contorna esse limite: antes de gerar a resposta, um componente de busca recupera de uma base externa apenas os trechos relevantes para a pergunta, que são então entregues ao modelo junto com a instrução (Lewis *et al.*, 2020). Essa capacidade é especialmente útil em domínios regulatórios, nos quais a resposta correta depende de documentos que não fazem parte do treinamento do modelo (Kim; Min, 2025).

2.5.1 Busca Lexical e BM25

A forma mais tradicional de recuperação é a busca lexical, que localiza documentos que contêm as palavras da consulta por meio de um índice invertido. Para ordenar os resultados, a função de ranqueamento BM25 dá a cada documento uma pontuação que cresce com a quantidade de palavras da consulta presentes nele e com a raridade dessas palavras na coleção, compensando o tamanho do documento (Robertson; Zaragoza, 2009). Assim, termos raros, como “para-choques”, pesam mais do que termos comuns, como “outros”. O SQLite implementa essa função em sua extensão de busca textual FTS5, que permite ainda atribuir pesos diferentes a cada coluna indexada e normalizar acentos (SQLite, 2024).

A principal limitação da busca lexical é depender de palavras em comum entre a consulta e o documento. Para reduzir esse problema, é possível expandir a consulta com sinônimos obtidos de uma base lexical como a WordNet, que organiza palavras em conjuntos de sinônimos (Miller, 1995). Para o português, a OpenWordNet-PT oferece uma base desse

tipo (Paiva; Rademaker; Melo, 2012), acessível em Python pela biblioteca NLTK (Bird; Klein; Loper, 2009).

2.5.2 Fusão de Rankings

Quando a mesma necessidade de informação é expressa de mais de uma forma, por exemplo pela descrição original de um produto e por uma reescrita em linguagem técnica, cada consulta produz uma lista ordenada diferente. A fusão por posição recíproca (RRF, do inglês *Reciprocal Rank Fusion*) combina essas listas somando, para cada documento d, o inverso de sua posição em cada lista $r \in R$ (Cormack; Clarke; Büttcher, 2009):

$$\mathrm{RRF}(d) = \sum_{r \in R} \frac{1}{k + r(d)} \tag{2.1}$$

em que $r(d)$ é a posição de d na lista r e k é uma constante (tipicamente 60) que atenua a diferença entre as primeiras posições. O método não exige que as pontuações das listas sejam comparáveis entre si e é simples de implementar.

2.5.3 Radicalização, Similaridade e Vizinhos Mais Próximos

Palavras flexionadas, como “pastilha” e “pastilhas” ou “freio” e “freios”, só coincidem em uma busca lexical se forem reduzidas a uma forma comum. A radicalização (*stemming*) faz essa redução por regras de remoção de sufixos, sem consultar um dicionário; o projeto Snowball define algoritmos desse tipo para várias línguas, entre elas o português (Porter, 2001), disponíveis em Python pela biblioteca NLTK (Bird; Klein; Loper, 2009).

Quando se comparam duas descrições curtas como conjuntos de palavras A e B, uma medida simples de semelhança é o coeficiente de Jaccard, a razão entre o número de palavras em comum e o número total de palavras distintas dos dois conjuntos, $|A \cap B| / |A \cup B|$, que vale 1 para conjuntos iguais e 0 para conjuntos sem palavras em comum (Manning; Raghavan; Schütze, 2008).

Essas medidas permitem classificar por analogia. Na classificação pelos vizinhos mais próximos (kNN, do inglês *k-Nearest Neighbors*), um item novo recebe a classe mais frequente entre os k exemplos já rotulados mais parecidos com ele, sem que nenhum modelo seja treinado: o “conhecimento” é a própria coleção de exemplos (Cover; Hart, 1967). É comum ponderar o voto de cada vizinho pela sua proximidade, de modo que os mais parecidos pe-

sem mais. No contexto deste trabalho, os exemplos rotulados são produtos cujo NCM já foi informado por empresas reais, e a semelhança é dada pela própria busca lexical.

2.6 AVALIAÇÃO EXPERIMENTAL DE SISTEMAS DE CLASSIFICAÇÃO

Um sistema ajustado a partir da observação de seus próprios erros tende a se adaptar às particularidades dos casos observados, e não apenas ao problema geral, fenômeno conhecido como superajuste (*overfitting*). Por isso, o desempenho medido nos mesmos casos usados para os ajustes é uma estimativa otimista do desempenho em casos novos. A prática recomendada é separar os dados em um conjunto usado para treinar e escolher entre alternativas e um conjunto de teste, mantido à parte e utilizado somente para medir o sistema já escolhido; se o conjunto de teste for usado repetidamente para escolher entre alternativas, ele passa a fazer parte do ajuste e perde o papel de estimativa independente (Hastie; Tibshirani; Friedman, 2009). O mesmo princípio vale quando o "ajuste" não é um treinamento de parâmetros, mas a modificação de *prompts*, regras e da busca, como neste trabalho.

Em problemas com muitas classes possíveis, como a NCM, é comum medir não apenas se a primeira resposta está correta, mas se a resposta correta aparece entre as k primeiras (acerto *top-k*), o que representa melhor um sistema que apresenta opções a um operador. Já em tarefas de detecção, a taxa de acerto sobre os casos com problema precisa ser acompanhada da taxa de alarmes falsos, isto é, da proporção de casos corretos indevidamente apontados, pois um detector que aponta tudo acerta todos os casos com problema, mas não tem utilidade prática (Manning; Raghavan; Schütze, 2008).

2.7 INTEGRAÇÃO DE LLMS COM BANCOS DE DADOS RELACIONAIS

Esta seção apresenta a forma mais difundida de integração entre LLMs e bancos de dados, que era a abordagem prevista no projeto deste trabalho. Ela é mantida aqui como contraste com a abordagem adotada, em que o modelo não gera consultas nem tem acesso ao banco (Capítulo 4).

A integração entre LLMs e bancos de dados relacionais é uma das áreas mais ativas de pesquisa em sistemas inteligentes aplicados (Hong *et al.*, 2024). A abordagem mais difundida, conhecida como *Text-to-SQL*, permite que o modelo interprete instruções em linguagem natural e as converta em consultas SQL executáveis. Tipicamente, o modelo recebe a estrutura do banco (DDL, do inglês *Data Definition Language*) e, a partir dela, gera a consulta correspon-

dente a uma pergunta do usuário (Ruiz Gómez *et al.*, 2025). Frameworks como o LangChain fornecem abstrações para essa integração, gerenciando a conexão entre o modelo, as fontes de dados e as ferramentas disponíveis ao agente (Chase, 2022).

O Firebird é um sistema de gerenciamento de banco de dados relacional de código aberto que surgiu como *fork* do InterBase 6.0 da Borland em 2000, mantendo forte integração com o ecossistema Delphi (Firebird Project, 2024); por isso, é o banco adotado por muitos ERPs desenvolvidos nessa linguagem, entre eles o Lux Auto. Por questões de segurança, recomenda-se que a camada de integração imponha restrições (*guardrails*) que bloqueiem comandos destrutivos como `DROP` e `DELETE`, restringindo o agente a operações de leitura durante a fase de diagnóstico (Roychowdhury *et al.*, 2025).

2.8 TRABALHOS CORRELATOS

Os trabalhos correlatos são apresentados em dois grupos: estudos de classificação automática de mercadorias na NCM e no Sistema Harmonizado, que tratam do mesmo problema de classificação, e estudos de integração de LLMs com dados empresariais e documentos regulatórios, que tratam do contexto de aplicação.

2.8.1 Classificação Automática de NCM e do Sistema Harmonizado

No Brasil, a classificação automática de NCM a partir da descrição do produto tem sido abordada com aprendizado de máquina supervisionado sobre grandes volumes de notas fiscais. Batista, Bagatini e Frozza (2018) desenvolveram um classificador Naïve Bayes treinado com descrições de itens de notas fiscais ao consumidor dos capítulos 22 e 90 da NCM, com acurácia de 98% no conjunto mais simples e de 90% e 83% nos conjuntos de dificuldade média e alta. Pinheiro, Siqueira e Amaris (2022) utilizaram cerca de 340 mil descrições distintas de NF-e para treinar classificadores SVM e Naive Bayes em cascata, um para cada nível do código, obtendo 89% de acurácia nos dois primeiros dígitos e 76% no código completo de oito dígitos. Os autores observam que a atribuição manual do código é suscetível a erros pela diversidade de produtos e pela interpretação das regras.

Para o Sistema Harmonizado, Lee *et al.* (2021), em parceria com o serviço aduaneiro da Coreia do Sul, propuseram um modelo baseado em um modelo de linguagem pré-treinado que sugere a posição e as subposições de uma mercadoria e recupera do manual do SH as sentenças que sustentam a sugestão, alcançando 95,5% de acerto entre as três primeiras

sugestões em 265 subposições, avaliado sobre 129.084 casos históricos. Com LLMs, Yuvraj e Devarakonda (2025) construíram um conjunto de avaliação a partir de decisões oficiais de classificação da aduana dos Estados Unidos e ajustaram um modelo de 70 bilhões de parâmetros, que acertou 40% dos códigos completos de dez dígitos e 57,5% dos códigos de seis dígitos, resultado superior ao de modelos comerciais de grande porte usados sem ajuste. Mais recentemente, Zhang *et al.* (2026) propuseram um fluxo determinístico para a classificação no SH chinês, no qual o fluxo de controle é fixo e as chamadas ao LLM ficam restritas a etapas específicas, apoiadas em regras e textos da tarifa organizados previamente, com 75,0% de acerto em primeiro lugar e 91,5% entre os três primeiros no nível de quatro dígitos.

Esses trabalhos mostram que o problema é difícil mesmo para modelos grandes e que os melhores resultados combinam o modelo com recuperação de textos oficiais ou com fluxos controlados pelo programa. Os classificadores supervisionados, por sua vez, dependem de centenas de milhares de exemplos rotulados, nem sempre disponíveis para uma empresa de software de pequeno porte.

2.8.2 LLMs e Dados Empresariais

Ruiz Gómez *et al.* (2025) apresentam um agente LLM capaz de interagir com um sistema ERP industrial por meio de linguagem natural, traduzindo consultas em instruções SQL executáveis por meio de uma arquitetura com dois agentes. O trabalho demonstra a viabilidade técnica da integração entre LLMs e sistemas ERP complexos, utilizando o LangChain como camada de orquestração, e comprova que a abordagem consegue operar sobre bases de dados reais de produção.

Bendinelli, Dox e Holz (2025) investigam o uso de agentes LLM para limpeza de *datasets* tabulares, demonstrando que esses modelos são capazes de identificar e corrigir entradas incorretas ao explorar informações contextuais de outras colunas do mesmo registro, com taxas de acerto superiores às de métodos heurísticos tradicionais.

Gholamian *et al.* (2024) investigam a classificação de produtos com LLMs em cenários de comércio e de conformidade regulatória, com atenção à robustez dos modelos diante de descrições de produtos incompletas ou ruidosas, característica também presente nos cadastros de ERP.

Por fim, Kim e Min (2025) propõem o QA-RAG, um sistema que integra IA generativa e recuperação de documentos para automação de processos de conformidade regulatória

farmacêutica. O trabalho demonstra que a recuperação de trechos relevantes de documentos regulatórios, entregues ao modelo no momento da resposta, permite tratar requisitos complexos de forma estruturada, mesmo princípio que este trabalho aplica à tabela NCM.

2.8.3 Síntese

O Quadro 1 compara os trabalhos correlatos com a proposta deste TCC. Em conjunto, eles demonstram que a classificação automática de mercadorias e a integração de LLMs com dados empresariais e documentos regulatórios são tecnicamente viáveis. Entretanto, os estudos de NCM não utilizam LLMs nem tratam da detecção de códigos válidos, porém incorretos, já cadastrados; os estudos com LLMs no SH usam modelos grandes ou serviços remotos; e nenhum deles opera integrado a um ERP brasileiro com aprovação humana obrigatória. Esta proposta se diferencia por quatro aspectos: o recorte na NCM do cadastro de produtos, incluindo a detecção de códigos incorretos; a integração direta com um sistema ERP real do setor automotivo nacional; a execução inteiramente local, com um modelo pequeno, em hardware convencional; e a medição explícita da contribuição do modelo de linguagem em relação à busca sem ele.

Quadro 1 – Comparação entre os trabalhos correlatos e este trabalho

Trabalho	**Técnica**	**Classificação**	**Usa LLM**	**Integrado a ERP**
Batista, Bagatini e Frozza (2018)	Naïve Bayes	NCM	Não	Não
Pinheiro, Siqueira e Amaris (2022)	SVM e Naive Bayes em cascata	NCM	Não	Não
Lee *et al.* (2021)	Modelo de linguagem pré-treinado e recuperação de sentenças do manual	SH	Não	Não
Yuvraj e Devarakonda (2025)	LLM de 70 bilhões de parâmetros ajustado	HTS (EUA)	Sim	Não
Zhang *et al.* (2026)	Fluxo determinístico com etapas restritas de LLM	SH (China)	Sim	Não
Ruiz Gómez *et al.* (2025)	LLM e *Text-to-SQL*	–	Sim	Sim
Este trabalho	Busca, vizinhos mais próximos e escolha restrita por LLM pequeno local, com aprovação humana	NCM	Sim	Sim

Fonte: O autor (2026).

3 METODOLOGIA

Quanto à natureza, este trabalho caracteriza-se como uma pesquisa aplicada, pois busca gerar conhecimento para a solução de um problema prático e delimitado; quanto à abordagem, é quantitativa, pois os resultados são expressos por métricas numéricas; e, quanto aos procedimentos, combina a pesquisa experimental, na qual se definem as variáveis capazes de influenciar o objeto de estudo e se observam, de forma controlada, os efeitos de cada uma, com o estudo de caso, por se concentrar em um único sistema, o ERP Lux Auto (Gil, 2022). As variáveis manipuladas são o modelo de linguagem, a arquitetura do processo de sugestão e os recursos auxiliares ativados; as variáveis observadas são o acerto das sugestões, o acerto das detecções e o tempo de resposta. Seguindo a recomendação de Wazlawick (2014) para a pesquisa em Ciência da Computação, a contribuição do protótipo não é apenas apresentada, mas medida por comparação objetiva com alternativas, incluindo uma linha de base sem modelo de linguagem.

O conhecimento prévio sobre o sistema e suas regras de negócio relatado neste trabalho origina-se da experiência profissional do autor no suporte técnico e no desenvolvimento do software. O código-fonte do protótipo, os conjuntos de avaliação, os *scripts* de avaliação e os arquivos com os resultados de cada execução estão disponíveis em um repositório público[1], exceto as bases de clientes e os resultados que contêm descrições de seus produtos, que não podem ser publicados.

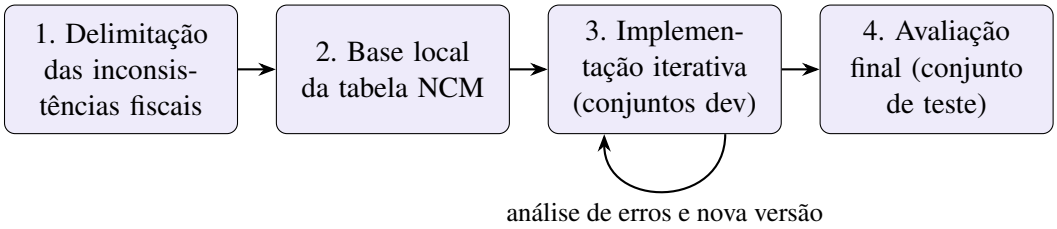
3.1 ETAPAS DA PESQUISA

O trabalho foi conduzido em quatro etapas, sintetizadas na Figura 3. A primeira consistiu na delimitação, a partir da experiência do autor no suporte técnico do Lux Auto, das inconsistências fiscais do cadastro que levam à rejeição de NF-e. Foram consideradas quatro categorias: divergência entre Inscrição Estadual e Indicador de Contribuinte, classificação incorreta de NCM, aplicação equivocada de CST e preenchimento incorreto de CFOP. Essa delimitação não se baseou em um levantamento quantitativo dos chamados, que não foi realizado. Dentre as categorias, a classificação NCM foi escolhida como foco da implementação por ser a que mais depende de interpretação de texto e, portanto, a que melhor permite avaliar a contribuição de um LLM; as demais são discutidas como trabalhos futuros.

[1] Disponível em: https://github.com/Nogssz/tcc-ncm-llm.

A segunda etapa compreendeu a construção de uma base local com a tabela NCM vigente, a partir do arquivo oficial em PDF, de forma que a validação de códigos e a busca de candidatos não dependessem do modelo de linguagem. A terceira etapa consistiu no projeto e na implementação do protótipo, conduzidos de forma iterativa: cada versão foi avaliada nos conjuntos de desenvolvimento, e os erros observados orientaram a versão seguinte. A quarta etapa foi a avaliação da versão final em um conjunto de teste reservado, medido uma única vez.

Figura 3 – Etapas do desenvolvimento do trabalho



Fonte: O autor (2026).

3.2 AMBIENTE EXPERIMENTAL

Todos os experimentos foram executados localmente, em um notebook com processador AMD Ryzen AI 7 350, 31 GB de memória RAM e placa de vídeo NVIDIA GeForce RTX 5060 Laptop com 8 GB de VRAM, sob o sistema operacional Windows 11. O protótipo foi desenvolvido em Python 3.13, e os modelos de linguagem foram servidos pelo Ollama, com quantização de 4 *bits* (formato Q4_K_M), temperatura zero e janela de contexto de 8.192 *tokens*. O Quadro 2 resume as ferramentas utilizadas.

Quadro 2 – Ferramentas e versões utilizadas

Ferramenta	**Versão**	**Uso no trabalho**
Python	3.13	Linguagem do protótipo
Ollama	0.34.2	Execução local dos modelos de linguagem
Qwen3 8B	Q4_K_M	Modelo de linguagem da versão final, sem raciocínio explícito
Qwen2.5 7B e Llama 3.1 8B	Q4_K_M	Modelos de linguagem comparados
LangChain (langchain-ollama)	1.1.0	Comunicação com o Ollama e saída estruturada
Firebird / firebird-driver	3.0 / 2.0.3	Banco de dados do ERP e acesso via Python
SQLite (FTS5)	3.50.4	Base local da tabela NCM, base de conhecimento e busca textual
NLTK	3.9.4	Sinônimos (OpenWordNet-PT) e radicais (Snowball) em português
pdfplumber	0.11.10	Extração da tabela NCM do PDF oficial
Streamlit	1.64.0	Interface de supervisão humana

Fonte: O autor (2026).

A interface de supervisão foi construída com o Streamlit, um *framework* de código aberto em Python para a criação de aplicações web interativas sem necessidade de HTML, CSS ou JavaScript (Streamlit Inc., 2024). Ele foi escolhido por permitir uma aplicação independente, que se conecta ao banco de dados do ERP sem exigir alterações no código-fonte do sistema principal, característica adequada a camadas de supervisão desacopladas de sistemas legados (Madicharla, 2025; Ruiz Gómez *et al.*, 2025).

3.3 FONTES DE DADOS

Foram utilizadas três fontes de dados. A primeira é uma instalação de desenvolvimento do Lux Auto, com a mesma estrutura das instalações dos clientes, na qual foram cadastrados os produtos dos primeiros conjuntos de teste com o NCM “00000000”, simulando o operador que salva o cadastro sem saber a classificação. A segunda é a tabela NCM oficial vigente, extraída para uma base local (Capítulo 4).

A terceira fonte são as bases de produtos de duas empresas do setor de autopeças que utilizam o Lux Auto, cedidas para este trabalho e identificadas aqui apenas como Loja A e Loja B. Delas foram lidos, somente para leitura, a descrição, o NCM e o indicador de serviço da tabela de produtos; nenhum dado de clientes, fornecedores, notas ou valores foi acessado, e nenhum dado pessoal foi tratado. A Loja A possui 5.177 mercadorias com NCM válido, e a Loja B, 36.429. Essas bases não fazem parte do repositório público. Elas foram usadas de duas

formas: como base de conhecimento, isto é, exemplos de produtos já classificados por empresas reais (Capítulo 4); e como fonte de erros reais de classificação, pois a Loja B utiliza o código 8708.10.00 (para-choques) em 3.407 produtos, dos quais apenas 104 são para-choques.

3.4 CONJUNTOS DE AVALIAÇÃO

Para medir o desempenho sem superestimá-lo, os casos foram divididos em conjuntos com papéis diferentes, seguindo a separação entre desenvolvimento e teste descrita na seção 2.6. Os conjuntos de desenvolvimento são usados durante a construção do sistema, e os erros observados neles orientam ajustes de *prompt*, de busca e de arquitetura; por isso, o resultado medido neles tende a ser otimista. O conjunto de teste é reservado para a medição final e não orienta nenhum ajuste. A Tabela 1 apresenta os conjuntos da avaliação da sugestão, e o Apêndice A lista os produtos de cada um.

Tabela 1 – Conjuntos de casos utilizados na avaliação da sugestão

Conjunto	**Produtos**	**Composição**	**Papel na pesquisa**
dev15	15	Peças automotivas e um azulejo	Primeiros ajustes e comparação entre modelos
dev	41	14 setores, 13 produtos automotivos	Desenvolvimento da primeira fase
teste	33	17 setores, 4 produtos automotivos	Comparação das arquiteturas da primeira fase
DEV2	49	Sorteados de 99 produtos novos	Desenvolvimento da segunda fase, junto com o dev
TESTE2	50	Sorteados dos mesmos 99 produtos; 18 automotivos	Teste final, medido uma única vez

Fonte: O autor (2026).

Os conjuntos foram construídos em duas fases. Na primeira, o conjunto teste foi medido uma vez para cada arquitetura candidata e usado para escolher entre elas, o que o tornou parte do ajuste. Por isso, na segunda fase, foram criados 99 produtos novos, sem repetição em relação aos conjuntos anteriores e com cerca de um terço de produtos automotivos, divididos por sorteio estratificado por setor, com semente fixa, em DEV2 (49 produtos) e TESTE2 (50 produtos). O TESTE2 foi congelado antes de qualquer alteração no sistema, com o registro de um *hash* do seu conteúdo, e o *script* de avaliação só aceita medi-lo com uma opção explícita de execução final. Durante o desenvolvimento, apenas o resultado agregado de uma medição de referência do sistema antigo foi observado nele. As decisões da segunda fase foram tomadas sobre a união dos conjuntos dev e DEV2 (90 produtos), para reduzir o efeito de casos isolados.

Para cada produto, a classificação correta foi conferida pelo autor na tabela NCM oficial. Quando a descrição admite mais de um código (por exemplo, um tênis pode ser de borracha ou de outro material, ou um suco de uva pode ter valor Brix diferente), todos os códigos plausíveis foram aceitos como corretos. As descrições foram escritas como um operador as digitaria no ERP, em letras maiúsculas, com abreviações, unidades e, em alguns casos, erros de digitação reais (“GELADERA”, “FURADERA”, “AZULEIJO”).

A detecção foi avaliada em três tipos de casos. Para os códigos inválidos, foram construídos casos rotulados de cinco categorias, no formato em que o ERP armazena o código: vazio, composto só de zeros, malformado (com sete ou nove dígitos, letras ou separadores), bem formado mas inexistente na tabela, e extinto em atualização da tabela (3923.30.00 e 9403.20.00, Seção 2.2.1). Os falsos positivos foram medidos nos 158 códigos válidos distintos dos conjuntos de avaliação, dez deles também com espaços em volta, como às vezes vêm do banco, e em todas as mercadorias das duas bases de clientes. Para os códigos válidos, porém incorretos, cada produto do DEV2 e do TESTE2 foi apresentado duas vezes: uma com o NCM correto e outra com um NCM errado de um de três tipos, sorteado com semente fixa: o código de outro produto do conjunto (troca), outro código do mesmo capítulo (capítulo) e outro item da mesma posição (vizinho), este o mais difícil de perceber. Por fim, para os erros reais, foram sorteados 40 produtos da Loja B cadastrados com 8708.10.00 sem serem para-choques e 40 produtos da mesma loja com outros códigos, presumidos corretos; nesse caso, a base de conhecimento consultada foi apenas a da Loja A, para que a resposta não viesse da própria loja.

3.5 MÉTRICAS

A avaliação considera duas dimensões principais, detecção e sugestão, complementadas por métricas que ajudam a localizar a origem dos erros:

- **Taxa de detecção**: proporção dos produtos com NCM inválido ou incorreto que foram apontados pelo sistema;
- **Taxa de alarme falso**: proporção dos produtos com NCM correto que foram apontados indevidamente;
- **Acurácia da detecção**: proporção de casos, com e sem erro, em que o sistema decidiu corretamente;

- **Acerto em 1º lugar**: proporção dos produtos em que a primeira opção sugerida é um código correto;
- **Acerto entre as 3 opções** (*top-3*): proporção dos produtos em que um código correto aparece entre as três opções apresentadas ao operador. Como a decisão final é humana, essa é a métrica que melhor representa a utilidade prática do sistema;
- **Capítulo correto**: proporção dos produtos em que o capítulo escolhido pelo modelo contém a resposta, o que permite separar erros de "que tipo de produto é este" de erros de escolha do item;
- **Cobertura da busca**: proporção dos produtos em que o código correto está entre os candidatos entregues ao modelo, o que separa erros de recuperação de erros de escolha;
- **Tempo médio por produto**: tempo de ponta a ponta para gerar as sugestões de um produto.

O projeto definiu como critérios de sucesso uma taxa de detecção de pelo menos 85% e uma taxa de acerto das correções de pelo menos 75%, mas não definiu uma meta de tempo. Para avaliar a eficiência mencionada na pergunta de pesquisa, adotou-se um limite de 30 segundos por produto. O valor decorre do modo de uso do protótipo: as sugestões são geradas em segundo plano, e, com 30 segundos por produto, um computador convencional processa cerca de mil produtos em uma noite de oito horas, volume compatível com a revisão inicial do cadastro de uma loja ou com os cadastros novos de vários dias. Como esse limite foi definido após as medições, ele deve ser lido como critério de viabilidade de uso, e não como hipótese testada. Cada execução da avaliação registra, para cada produto, as opções sugeridas, a resposta esperada, o capítulo escolhido, a interpretação feita pelo modelo e o tempo gasto, em arquivos disponíveis no repositório, de forma que os resultados possam ser auditados e reproduzidos.

3.6 PROTOCOLO DE AVALIAÇÃO

Na avaliação, o sistema recebe somente a descrição do produto, exatamente como cadastrada, e, na detecção, também o NCM cadastrado. A memória de produtos parecidos do próprio ERP, descrita no Capítulo 4, permanece ativa, mas é configurada para ignorar cadastros com descrição idêntica à do produto avaliado, evitando que um produto já corrigido "entregue" a própria resposta. Os modelos são executados com temperatura zero, o que torna as respostas praticamente determinísticas. Todas as versões comparadas foram medidas nos mesmos con-

juntos, na mesma máquina. Para isolar a contribuição do modelo de linguagem, as mesmas medições foram repetidas sem nenhuma chamada ao modelo, com a busca lexical sozinha e com a base de conhecimento sozinha.

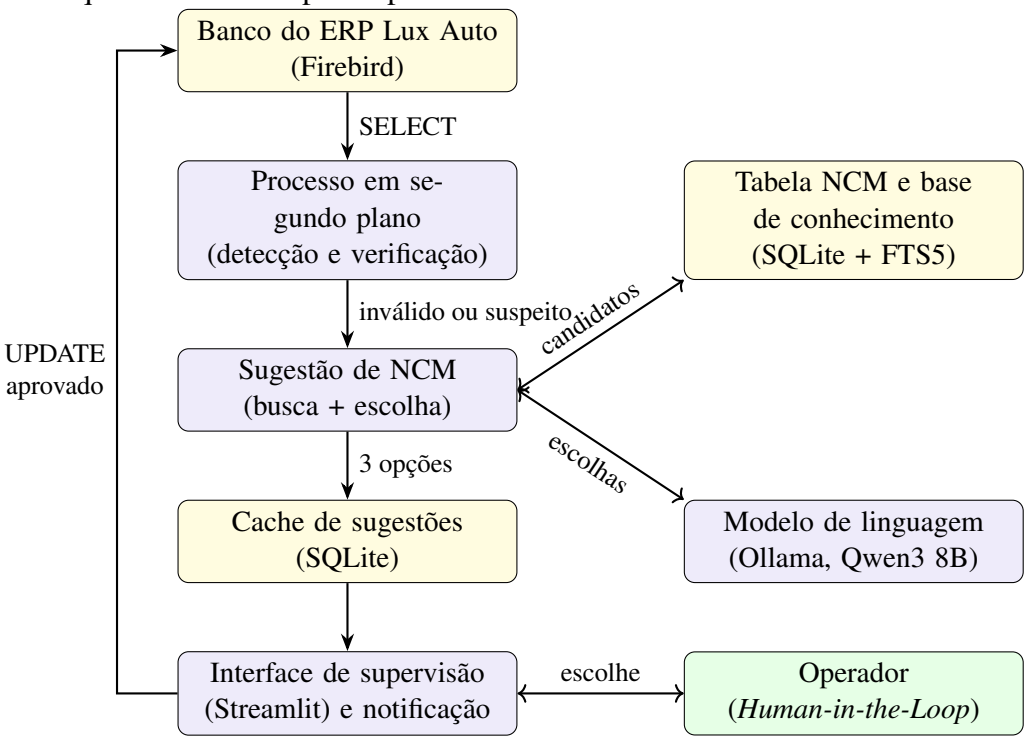
4 DESENVOLVIMENTO DO PROTÓTIPO

Este capítulo descreve a arquitetura e a implementação do protótipo. Primeiro, apresenta-se a visão geral da solução final; em seguida, cada componente é detalhado: a base local da tabela NCM, a detecção de produtos com NCM inválido, o processo de sugestão, a base de conhecimento formada por produtos de outras empresas, a verificação de produtos com NCM possivelmente incorreto, a execução em segundo plano e a interface de supervisão. Ao final, descreve-se a evolução das versões testadas ao longo do trabalho, incluindo as que foram descartadas e os motivos.

4.1 VISÃO GERAL DA ARQUITETURA

A Figura 4 apresenta a arquitetura final. O protótipo é uma aplicação independente do ERP, que se conecta ao mesmo banco de dados Firebird e não exige nenhuma alteração no código-fonte do Lux Auto. Um processo em segundo plano consulta periodicamente o banco e identifica produtos com NCM inválido; em lotes menores, também verifica produtos com NCM válido, em busca de códigos que existem, mas parecem pertencer a outro tipo de produto. Para cada produto, o processo de sugestão consulta a base local com a tabela NCM, a base de conhecimento com produtos já classificados por outras empresas e o modelo de linguagem, executado pelo Ollama, e grava as três opções mais prováveis em um cache local. O operador é avisado por uma notificação do Windows e, na interface Streamlit, escolhe uma das opções; somente então o NCM é gravado no cadastro do produto.

Figura 4 – Arquitetura final do protótipo



Fonte: O autor (2026).

Em relação à arquitetura prevista no projeto, a principal mudança é o papel do modelo de linguagem. No projeto, o agente receberia a estrutura do banco e geraria consultas SQL a partir de instruções em linguagem natural (*Text-to-SQL*). Na solução final, todas as consultas SQL são fixas e parametrizadas, escritas no código, e o modelo não tem acesso ao banco: ele recebe apenas a descrição do produto e uma lista de códigos candidatos, e sua resposta é restrita, por esquema JSON, a escolher entre esses códigos. A seção 4.9 explica como se chegou a essa decisão. O fluxo de aprovação humana previsto no projeto foi mantido integralmente.

4.2 BASE LOCAL DA TABELA NCM

A tabela NCM vigente foi obtida em formato PDF, com 505 páginas, e extraída para um banco SQLite com a biblioteca pdfplumber, resultando em 15.141 linhas, que abrangem todos os níveis da hierarquia, dos capítulos aos itens. Durante a extração, observou-se que, em parte das linhas, uma camada de texto sobreposta no PDF fazia os caracteres da data de vigência se intercalarem com o final da descrição. Como a ordem relativa dos caracteres de cada campo se preserva nessa intercalação, um script de reparo separou os dígitos que formam a data do restante do texto e reconstruiu a descrição. Algumas descrições ainda apresentam pequenos defeitos herdados da extração, como palavras emendadas.

Essa base resolveu um problema prático observado no início do trabalho: tentar fornecer a tabela inteira a um modelo de linguagem excede qualquer janela de contexto viável. Com a base local, a validação de um código passa a ser uma consulta direta, e o modelo recebe apenas algumas dezenas de candidatos relevantes, no espírito da RAG descrita na seção 2.5.

Para a busca, foi construído um índice de texto completo (FTS5) somente sobre os 10.504 códigos de oito dígitos, já que apenas eles são válidos no cadastro. Como a descrição de um item frequentemente só faz sentido com os níveis superiores (seção 2.2.1), cada item foi indexado com três colunas: o texto próprio do item; o texto de todos os seus ancestrais (capítulo, posição e subposições); e uma versão do texto sem hífens. A primeira coluna recebe peso maior no BM25 (5,0, contra 1,0 dos ancestrais e 0,5 da versão sem hífen), de modo que um item cujo próprio texto corresponde à busca fique à frente de um item que só corresponde pelo cabeçalho. A coluna sem hífen permite que descrições digitadas sem hífen, como “PARACHOQUE”, encontrem “para-choques”. O índice ignora acentos, o que torna a busca tolerante a descrições digitadas sem acentuação.

4.3 DETECÇÃO DE PRODUTOS COM NCM INVÁLIDO

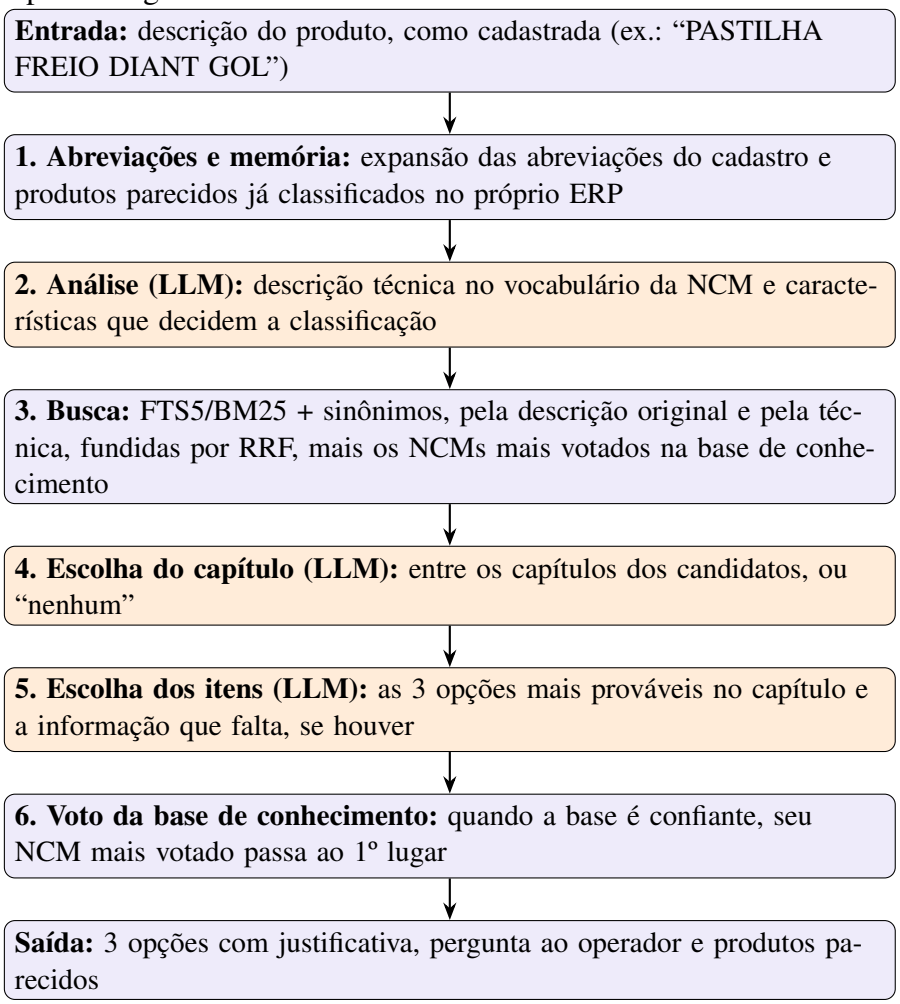
A detecção não utiliza o modelo de linguagem. Uma consulta somente leitura obtém todos os produtos cadastrados como mercadoria (campo `SERVICO = 'N'`), excluindo os serviços, cujo campo NCM guarda um código NBS (seção 2.2.1). Para cada produto, o código cadastrado é normalizado (o ERP grava os oito dígitos sem pontuação) e considerado inválido quando está vazio, não possui oito dígitos ou não existe na tabela vigente. Por ser uma regra determinística, a detecção não está sujeita a alucinação e executa em milissegundos.

Essa regra detecta códigos vazios, malformados, inexistentes ou extintos em atualizações da tabela, que são os que causam rejeição imediata da NF-e por código inválido. Ela não detecta um produto cadastrado com um código válido, porém de outro produto, por exemplo um parafuso classificado como pneu; esse tipo de erro exige comparar a descrição do produto com o texto do código cadastrado e é tratado pela verificação descrita na seção 4.6.

4.4 SUGESTÃO DA CLASSIFICAÇÃO

O processo de sugestão recebe a descrição do produto e devolve até três códigos NCM, do mais para o menos provável, cada um com uma justificativa curta. A Figura 5 resume suas etapas, detalhadas a seguir.

Figura 5 – Etapas da sugestão de NCM na versão final



Fonte: O autor (2026). Em laranja, as etapas que consultam o modelo de linguagem.

4.4.1 Memória de Classificações

Em uma oficina, um produto novo quase sempre se parece com algum já cadastrado, como "PASTILHA FREIO DIANT GOL" e "PASTILHA FREIO TRAS PALIO". O NCM que a empresa já usa para o produto parecido é a pista mais forte disponível, pois reflete como aquela empresa classifica seus produtos. Por isso, a primeira etapa procura, entre os produtos do próprio ERP que já possuem NCM válido, aqueles com descrição semelhante. A semelhança entre os conjuntos de palavras A e B das duas descrições, sem acentos e sem palavras genéricas, é calculada como a média entre o coeficiente de Jaccard (seção 2.5.3) e a sobreposição relativa ao menor conjunto (Manning; Raghavan; Schütze, 2008):

$$\mathrm{sim}(A, B) = \frac{1}{2}\,\frac{|A \cap B|}{|A \cup B|} + \frac{1}{2}\,\frac{|A \cap B|}{\min(|A|, |B|)} \tag{4.1}$$

O segundo termo foi incluído porque o Jaccard sozinho penaliza o caso mais co-

mum em cadastros, em que uma descrição está contida na outra (“PARACHOQUE” e “PARACHOQUE DIANTEIRO GOL”). Produtos com semelhança a partir de 0,4 são considerados parecidos. O código do mais parecido é inserido no topo da lista de candidatos, e até três produtos parecidos são informados ao modelo como indício a ser conferido. Como as aprovações feitas na interface gravam o NCM no próprio cadastro, essa memória cresce com o uso, sem exigir nenhuma tabela adicional.

4.4.2 Expansão de Abreviações

As descrições digitadas no ERP são, com frequência, abreviadas: “PIVO SUSP INF DIANT” é um pivô da suspensão inferior dianteira. Nos primeiros testes da segunda fase, abreviações levaram o modelo a interpretações absurdas, como “SUSP INF” lida como “medicamento para infusão”. Por isso, antes de qualquer outra etapa, as abreviações mais comuns do setor são expandidas por uma tabela com 85 entradas (por exemplo, “DIANT” para “dianteiro”, “JG” para “jogo” e “ROLAM” para “rolamento”). Abreviações ambíguas, como “PC” (peça ou computador) e “DIA”, foram mantidas fora da tabela. A descrição expandida é mostrada ao modelo ao lado da original, que é preservada para a busca.

4.4.3 Análise do Produto

A tabela NCM raramente usa o nome comercial do produto. A segunda etapa pede ao modelo de linguagem que reescreva a descrição com o nome técnico usado pela NCM, em no máximo oito palavras e sem embalagem, medidas ou marca, e que liste as características que decidem a classificação, como material, função, aplicação e se o produto é completo ou uma peça. Quando algo importante não pode ser inferido da descrição, o modelo deve indicá-lo como “não informado”. O *prompt*, reproduzido no Apêndice B, traz três exemplos de produtos que não fazem parte de nenhum conjunto de avaliação.

4.4.4 Busca de Candidatos

A busca é executada duas vezes, uma com a descrição original e outra com a descrição técnica, e as duas listas são combinadas por fusão de rankings (RRF, Equação 2.1, com $k = 60$), resultando em até 40 candidatos. A esses candidatos somam-se, no topo da lista, os NCMs mais votados na base de conhecimento (seção 4.5), quando houver. A descrição original preserva termos que o modelo pode descartar indevidamente; a técnica traz o vocabulário da tabela.

Antes de consultar o índice, cada descrição passa por um tratamento: extraem-se apenas as palavras com três letras ou mais, o que também descarta números e medidas como “195/65” e “500ML”; removem-se palavras genéricas que aparecem em milhares de itens, como “tipo”, “uso”, “embalagem” e “unidade”; e cada palavra é buscada como prefixo, entre aspas, o que neutraliza caracteres e palavras reservadas da sintaxe de busca. A busca por prefixo cobre a maioria dos plurais, mas não os irregulares, como “farol” e “faróis”; para esses casos, o plural é gerado por regras simples de sufixo e acrescentado à consulta.

Quando uma palavra da descrição não encontra nenhum item na tabela, seus sinônimos são obtidos da OpenWordNet-PT, por meio da NLTK, e buscados em uma consulta separada, que ocupa uma pequena reserva de posições na lista. A consulta é separada porque, nos testes, misturar sinônimos de palavras comuns na consulta principal gerava ruído excessivo. Uma pequena lista manual complementa a WordNet em casos observados, como “azulejo”, cujo termo oficial é “ladrilho”.

4.4.5 Escolhas Restritas do Modelo

Com os candidatos em mãos, o modelo de linguagem faz duas escolhas curtas. Na primeira, os candidatos são agrupados por capítulo e apresentados em ordem de relevância, cada capítulo com seu título e alguns itens resumidos, e o modelo indica a qual capítulo o produto pertence ou responde “NENHUM”, se nenhum for do mesmo tipo de produto. Na segunda, o modelo recebe apenas os itens do capítulo escolhido, com o caminho completo de cada um, e devolve os três mais prováveis, em ordem, com uma justificativa curta, além da informação que falta para decidir, se houver. Essa informação é apresentada ao operador como uma pergunta, por exemplo “O valor Brix do suco de uva é superior ou igual a 30?”.

As duas respostas são restritas por esquema JSON (seção 2.5): o campo do capítulo só aceita os capítulos apresentados, e o campo de código só aceita os códigos apresentados. Assim, o modelo não consegue inventar um código inexistente nem escapar do formato esperado. O esquema da segunda escolha é ilustrado a seguir, com a lista de códigos abreviada:

```
{"type": "object",
 "properties": {
   "opcoes": {"type": "array", "minItems": 1, "maxItems": 3,
     "items": {"type": "object",
       "properties": {
```

```
          "justificativa": {"type": "string"},
          "codigo": {"type": "string",
                     "enum": ["8708.30.11", "8708.30.19", ...]}},
        "required": ["justificativa", "codigo"]}},
    "informacao_que_falta": {"type": "string"}},
 "required": ["opcoes", "informacao_que_falta"]}
```

O *prompt* de sistema que acompanha as duas escolhas (Apêndice B) orienta o modelo a pensar no que o produto é de fato antes de escolher, a não se deixar levar por palavras soltas como a cor, a evitar itens "Outros" por insegurança e, como desempate, a preferir a aplicação automotiva quando a descrição não diz o tipo de veículo, já que o ERP atende oficinas mecânicas. Na segunda fase, acrescentou-se ao *prompt* a Nota 2 da Seção XVII (seção 2.2.1): no conjunto de desenvolvimento, peças de uso geral, como rolamentos, mangueiras e palhetas, eram classificadas como "partes e acessórios" de veículos (posição 87.08), e a regra lista as posições próprias dessas peças. Trata-se de uma regra oficial da tabela, e não de um ajuste caso a caso.

Dois tratamentos adicionais se mostraram necessários. O primeiro é a tradução de referências cruzadas: o texto oficial cita outras posições apenas pelo número, como em "partes e acessórios dos veículos das posições 87.11 a 87.13", e o modelo não tem como saber que essas posições são motocicletas, bicicletas e cadeiras de rodas. Sem essa informação, pastilhas de freio de carro eram classificadas como peças de bicicleta; por isso, o nome curto de cada posição citada é acrescentado ao texto. O segundo é a validação da resposta: os modelos Qwen eventualmente inserem palavras em chinês no meio de respostas em português, e esses trechos são removidos; além disso, se a resposta vier fora do formato, a pergunta é repetida uma vez. Se o modelo devolver menos de três opções, a lista é completada com os próximos itens do capítulo na ordem da busca, identificados como alternativas sem análise do modelo.

4.5 BASE DE CONHECIMENTO DE OUTRAS EMPRESAS

A memória de classificações depende de o próprio ERP já ter produtos parecidos classificados, o que não ocorre em uma instalação nova. Para suprir essa falta, foi construída uma base de conhecimento com os produtos já classificados por outras empresas do mesmo setor, a partir das bases cedidas por duas lojas de autopeças (Capítulo 3). Não se trata de treinar o modelo de linguagem, o que exigiria mais memória de vídeo do que a disponível, mas de uma

classificação por vizinhos mais próximos (seção 2.5.3): para um produto novo, buscam-se os dez produtos mais parecidos já classificados, e cada um vota no seu NCM com peso $1/(1+i)$, em que i é sua posição na lista, a partir de zero.

A semelhança é dada pela busca BM25 sobre os radicais das palavras da descrição, obtidos pelo algoritmo Snowball para o português, depois da expansão de abreviações. Antes da indexação, remove-se o prefixo com a marca e o código do fabricante, frequente nas descrições do setor ("VIEMAR 680077 - ARTICULADOR AXIAL DIRECAO"), que identifica o fabricante, e não o tipo de produto.

Uma base de exemplos herda os erros de quem a produziu. Na Loja B, o código 8708.10.00 (para-choques) aparece em 3.407 produtos, dos quais apenas 104 são para-choques; os demais são molas, freios, cabos e rolamentos, cadastrados com um código "coringa". Por isso, produtos com esse código cuja descrição não menciona para-choque são excluídos da base. A mesma situação foi aproveitada como caso real para avaliar a detecção de NCM incorreto (Capítulo 5).

A base é usada de três formas no processo de sugestão: os NCMs mais votados entram no topo da lista de candidatos; até seis produtos parecidos são mostrados ao modelo como indício; e, depois da escolha do modelo, se o NCM mais votado tiver voto de pelo menos 2,0 e o vizinho mais próximo for bastante parecido, esse NCM passa ao primeiro lugar, com a justificativa de que outras lojas classificam produtos parecidos dessa forma. Os limiares foram definidos no conjunto de desenvolvimento.

4.6 VERIFICAÇÃO DE NCM POSSIVELMENTE INCORRETO

Um código válido pode pertencer a outro produto. Para apontar esses casos, o protótipo verifica produtos com NCM válido combinando dois sinais. O primeiro é a própria sugestão: o processo da seção 4.4 é executado para o produto, como se ele não tivesse NCM, e verifica-se se o código cadastrado está entre as três opções sugeridas. O segundo é um veredito do modelo sobre o código cadastrado: o modelo recebe a descrição do produto e o texto oficial completo do código, do capítulo ao item, e responde, com resposta restrita por esquema JSON, se o texto descreve esse tipo de produto ("compatível"), outro tipo de produto ("incompatível") ou se depende de uma informação ausente ("dúvida").

O produto é apontado como possivelmente incorreto somente quando os dois sinais concordam: o código cadastrado está fora das três opções sugeridas e o modelo o considera

incompatível. Outras combinações foram avaliadas, como uma comparação lado a lado entre o código cadastrado e as opções sugeridas, apresentadas em ordem aleatória, e o voto da base de conhecimento; a regra final foi escolhida no conjunto de desenvolvimento por apresentar a melhor combinação entre detecção e alarmes falsos (Capítulo 5). Para não confundir uma suspeita com um erro, a interface apresenta a decisão como “NCM possivelmente errado”, com o motivo e as opções sugeridas, e a decisão final é sempre do operador.

4.7 EXECUÇÃO EM SEGUNDO PLANO E NOTIFICAÇÃO

Para que a sugestão já esteja pronta quando o operador a procurar, um processo em segundo plano consulta o banco a cada 20 segundos, identifica produtos com NCM inválido ainda sem sugestão e executa o processo de sugestão para cada um. Em seguida, verifica um pequeno lote de produtos com NCM válido, dos cadastrados mais recentemente para os mais antigos, de modo que a verificação de um cadastro inteiro avance aos poucos sem atrasar as sugestões dos produtos com NCM inválido. O resultado é gravado em um cache SQLite local, separado do banco do ERP, cuja chave é o par código do produto e descrição: se o operador corrigir a descrição no ERP, a sugestão antiga deixa de valer e é recalculada. Ao concluir cada produto, o processo pode exibir uma notificação do Windows com a primeira opção sugerida.

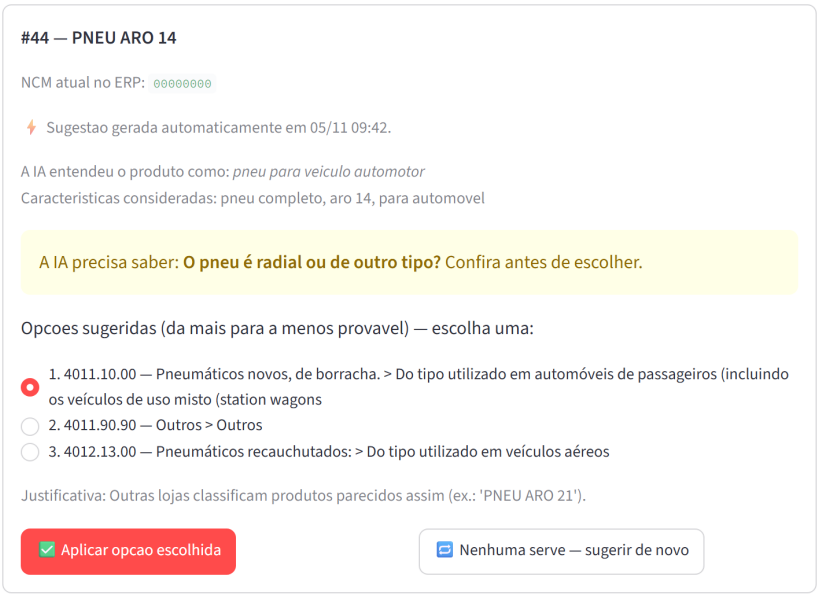
Optou-se pela consulta periódica (*polling*) em vez de um gatilho (*trigger*) no banco porque um gatilho exigiria alterar a estrutura do banco do ERP em cada cliente, contrariando a premissa de não modificar o sistema principal. O custo é um atraso de até 20 segundos para o produto ser notado, além do tempo de sugestão.

4.8 INTERFACE DE SUPERVISÃO

A interface, desenvolvida em Streamlit, lista os produtos com NCM inválido e, para cada um, exibe as opções sugeridas, como ilustra a Figura 6. Acima das opções, são apresentadas a interpretação feita pelo modelo, as características consideradas, os produtos parecidos já cadastrados e, quando houver, a pergunta sobre a informação que falta. O operador escolhe uma das três opções e confirma; somente nesse momento o sistema executa a atualização do cadastro. Se nenhuma opção servir, o operador pode descartar a sugestão e pedir uma nova. Uma segunda seção da interface lista os produtos com NCM possivelmente errado, com o código cadastrado, o motivo da suspeita e as opções sugeridas; o operador pode trocar o código por uma das opções ou indicar que o código atual está correto, e, nesse caso, o produto deixa de ser

apontado (Figura 7).

Figura 6 – Interface de supervisão com as opções sugeridas para um produto

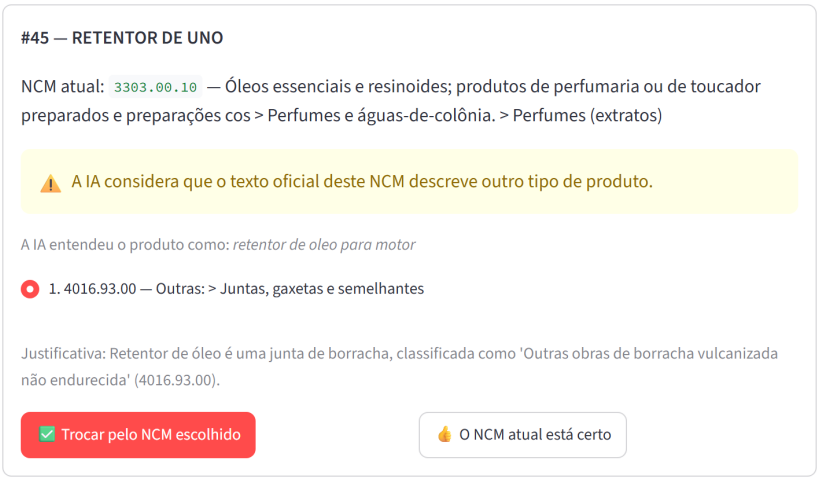


Fonte: O autor (2026).

O exemplo da Figura 6 foi gerado pela versão final, para um produto da instalação de desenvolvimento. A primeira opção veio do voto da base de conhecimento, como indica a justificativa, e a pergunta aponta uma informação que a descrição não traz. A terceira opção, de pneumáticos recauchutados para veículos aéreos, não faz sentido para o produto. É justamente para esse tipo de caso que a aprovação humana existe: o operador confere as opções e, se nenhuma servir, pede uma nova sugestão ou classifica o produto manualmente.

A Figura 7 mostra um produto apontado pela verificação na mesma instalação: um retentor cadastrado com o código de perfumes (3303.00.10).

Figura 7 – Interface de supervisão com um produto de NCM possivelmente errado



Fonte: O autor (2026).

A camada de acesso ao banco impõe duas restrições. Toda consulta de leitura passa por uma função que só aceita comandos `SELECT`. A gravação passa por outra função, que só aceita comandos `UPDATE` com parâmetros, e é chamada apenas pelo botão de aprovação da interface, com um comando fixo: `UPDATE PRODUTO SET NCM = ? WHERE CODIGO = ?`. Como o código gravado é sempre um dos códigos existentes na tabela, apresentados ao operador, não há como o sistema gravar um código inventado. Por controlar alterações no banco de produção, a interface é servida apenas para o próprio computador (*localhost*).

4.9 EVOLUÇÃO DAS VERSÕES

A arquitetura final resultou de uma sequência de versões, cada uma motivada pelos erros da anterior. O Quadro 3 resume essa evolução; os resultados quantitativos são apresentados no Capítulo 5.

Quadro 3 – Versões do processo de sugestão avaliadas

Versão	**Funcionamento**	**Situação**
Agente com ferramentas	LLM decide quais ferramentas chamar (busca na tabela, listagem de subcódigos, consulta ao banco) e em que ordem	Descartada: lenta, instável e com alucinações
Busca com *embeddings*	Busca semântica por vetores somada à busca lexical	Descartada: não aproximou o vocabulário comercial do técnico
Busca e escolha	Busca lexical e duas escolhas restritas do LLM; primeiro com uma opção, depois com três	Base da versão final
Navegação hierárquica	LLM navega capítulo, posição e item vendo a lista completa de cada nível	Descartada: mais lenta e menos precisa
Busca e escolha revisada (1ª fase)	Busca e escolha, com análise do produto, pergunta ao operador, memória e nova tentativa	Base da segunda fase
Dicas de posição e hipóteses	LLM sugere posições prováveis e interpretações alternativas, buscadas também	Descartadas: pioraram ou não alteraram o acerto
Final (2ª fase)	Busca e escolha revisada, com Qwen3 8B, expansão de abreviações, Nota 2 da Seção XVII e base de conhecimento	Adotada

Fonte: O autor (2026).

A primeira versão seguiu o projeto: um agente LangChain com o Llama 3.1 8B, que recebia ferramentas para consultar o banco do ERP e a tabela NCM e decidia, em várias rodadas,

quais chamar. Na prática, cada classificação exigia de três a cinco chamadas sequenciais ao modelo, o que tornava a resposta lenta e expunha a instabilidade do servidor local sob uso repetido. Mais grave, o modelo nem sempre usava as ferramentas como instruído: em um dos testes, classificou um azulejo de banheiro como "tubo de escape", código que não tinha relação com nenhum resultado de busca. Esse comportamento levou à decisão de inverter o controle: o programa executa a busca de forma determinística e o modelo apenas escolhe, com a resposta restrita aos candidatos.

Em paralelo, testou-se a busca semântica com dois modelos de *embeddings* (nomic-embed-text e paraphrase-multilingual-mpnet-base-v2), para encontrar itens sem palavras em comum com a descrição. Os vetores não aproximaram de forma útil o vocabulário comercial do técnico ("azulejo" de "ladrilho", "bateria" de "acumulador"), e o uso de um segundo modelo obrigava o Ollama a alternar modelos na memória de vídeo a cada sugestão, o que travava o servidor. A expansão por sinônimos da WordNet, mais simples, foi adotada no lugar.

A versão de busca e escolha inicialmente devolvia uma única opção. A análise de erros mostrou que, quando o modelo errava, a resposta certa costumava estar entre os primeiros candidatos do mesmo capítulo (leite integral e desnatado, pilha AA e C), o que motivou a apresentação de três opções ao operador.

A navegação hierárquica foi testada para eliminar a dependência da busca: em vez de escolher entre candidatos, o modelo via a lista completa dos 96 capítulos, depois todas as posições do capítulo escolhido e, por fim, todos os itens das posições escolhidas, como faria um classificador humano seguindo as Regras Gerais de Interpretação. Apesar de acertar o capítulo com frequência, essa versão errou mais na escolha final e foi mais lenta, como mostra o Capítulo 5. A primeira fase terminou com o retorno à busca e escolha, incorporando as melhorias que funcionam independentemente da forma de navegação: a análise do produto com características, a pergunta ao operador, a memória de classificações e a nova tentativa em caso de resposta fora do formato.

A segunda fase partiu dessa versão e foi conduzida sobre os conjuntos de desenvolvimento dev e DEV2. A análise dos erros no DEV2 mostrou três problemas principais: abreviações mal interpretadas, peças de uso geral classificadas como partes de veículos e o código correto ausente dos candidatos. Os dois primeiros motivaram a expansão de abreviações e a inclusão da Nota 2 da Seção XVII. Para o terceiro, foram testadas duas formas de dar ao modelo mais candidatos: pedir a ele as posições de quatro dígitos mais prováveis, cujos itens eram

acrescentados à lista, e pedir interpretações alternativas do produto, buscadas também. Ambas pioraram ou não alteraram o acerto e foram descartadas. O modelo Qwen3 8B, disponível nessa fase, substituiu o Qwen2.5 7B por interpretar melhor os produtos (“água sanitária” passou a ser reconhecida como produto de desinfecção, e “serrote”, como ferramenta de corte de madeira). Por fim, a base de conhecimento das duas lojas permitiu tratar a falta de candidatos e a escolha fina nos produtos automotivos, que são o foco do ERP.

5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados em duas partes. A primeira trata da detecção: de códigos inválidos, por consulta à tabela, e de códigos válidos, porém incorretos, com o auxílio do modelo de linguagem. A segunda trata da sugestão: a comparação entre modelos e entre versões no desenvolvimento, a contribuição do modelo de linguagem em relação à busca sem ele, o resultado da versão final no conjunto de teste e a análise dos erros. Ao final, os resultados são confrontados com as metas do projeto e discutidos, incluindo as limitações da avaliação.

5.1 DETECÇÃO DE NCM INVÁLIDO

A Tabela 2 apresenta o resultado da detecção nos casos rotulados por categoria. Todos os 25 códigos inválidos foram apontados, e nenhum dos 168 códigos válidos foi apontado indevidamente.

Tabela 2 – Detecção de NCM inválido por categoria

Categoria	**Exemplos (formato do ERP)**	**Apontados**
Vazio	vazio, só espaços	3/3
Só zeros	00000000, 0	4/4
Malformado	8708100, 870810000, 87O81000	8/8
Bem formado e inexistente	87081099, 99999999	8/8
Extinto em atualização da tabela	39233000, 94032000	2/2
Válido (falso positivo)	códigos dos conjuntos de avaliação	0/168

Fonte: O autor (2026).

Nas bases reais das duas lojas, a detecção encontrou 14 mercadorias com código só de zeros e 2 com código de nove dígitos na Loja A, e 54 com código só de zeros e 5 com o campo vazio na Loja B. Nenhuma das 41.606 mercadorias com código válido foi apontada. Esses resultados eram esperados, pois a detecção é uma consulta determinística à tabela oficial; seu valor está em cobrir todas as formas de código inválido, inclusive os extintos, sem custo de modelo de linguagem e sem falsos positivos. Após a restrição aos itens cadastrados como mercadoria, nenhum serviço com código NBS foi apontado como erro; antes dessa restrição, um código NBS válido havia sido indicado incorretamente como NCM inexistente, o que motivou o ajuste.

Os números também mostram o limite dessa verificação: nas bases reais, os códigos inválidos são raros (75 em mais de 41 mil mercadorias), enquanto o erro real mais frequente encontrado, o código "coringa" da Loja B, é um código válido e passaria despercebido por ela.

5.2 DETECÇÃO DE NCM POSSIVELMENTE INCORRETO

A Tabela 3 apresenta as regras de decisão avaliadas no DEV2, com os erros plantados, e nos casos reais da Loja B. A regra adotada foi escolhida no DEV2. Dos 98 casos previstos no DEV2, um (o produto "BOBINA DE IGNICAO" com NCM errado) não foi medido por falha de execução, o que resulta em 97 casos.

Tabela 3 – Regras de detecção de NCM incorreto nos conjuntos de desenvolvimento

	DEV2 (97 casos)		**Loja B (80 casos)**	
Regra	**Acurácia**	**Alarme falso**	**Acurácia**	**Alarme falso**
Fora das 3 opções sugeridas	84,5%	30,6%	81,2%	37,5%
Modelo considera incompatível	85,6%	18,4%	85,0%	30,0%
Fora das 3 opções e (incompatível ou comparação contra)	88,7%	20,4%	85,0%	30,0%
Fora das 3 opções e incompatível (adotada)	**86,6%**	**16,3%**	**88,8%**	**22,5%**

Fonte: O autor (2026). Alarme falso: produtos com NCM correto apontados como suspeitos.

No DEV2, a regra adotada apontou todos os erros de troca (19/19) e de capítulo (16/16), mas apenas 8 dos 13 erros de vizinho, em que o código errado é outro item da mesma posição, como 8204.12.00 no lugar de 8204.11.00. Esse é o erro mais difícil, pois os dois textos oficiais diferem em um detalhe que a descrição muitas vezes não informa. A regra com a comparação lado a lado detectou mais erros de vizinho (12/13), mas com mais alarmes falsos, e foi preterida. O voto da base de conhecimento não melhorou nenhuma regra: as combinações com ele empataram com as combinações sem ele.

Nos casos reais da Loja B, a regra adotada apontou os 40 produtos cadastrados com o código "coringa" de para-choques, como emblemas, correias, retentores e juntas de motor. Entre os 40 produtos presumidos corretos, 9 foram apontados. A inspeção desses alarmes mostrou que ao menos dois parecem ser erros reais da loja, e não do sistema: um coxim de radiador classificado como parte de caixa de câmbio (8708.40.90) e um cilindro auxiliar de embreagem classificado como parte de freio (8708.30.90), quando a NCM possui item próprio para embreagens (8708.93.00). Outros alarmes decorreram de abreviações não expandidas, como "PRF SXTV" (parafuso sextavado).

No TESTE2, com 50 produtos com o NCM correto e 50 com erros plantados, a regra adotada foi medida uma única vez e obteve acurácia de 86,0%, com alarme falso de 6,0% (3 dos 50 produtos corretos). Foram apontados 39 dos 50 erros (78,0%): todos os erros de troca (20/20), 14 dos 15 erros de capítulo e apenas 5 dos 15 erros de vizinho, o que confirma a dificuldade observada no desenvolvimento. Entre as regras não adotadas, a que inclui a comparação lado a lado teria apontado mais erros de vizinho (10/15), com acurácia de 88,0% e alarme falso de 14,0%; a escolha, feita no desenvolvimento, não foi alterada após a medição. A regra adotada privilegia, portanto, poucos alarmes falsos, o que é desejável em uma verificação que percorre todo o cadastro, em troca de deixar passar parte dos erros mais sutis.

O tempo da verificação ficou entre 17 e 25 segundos por produto, pois inclui a sugestão completa e uma pergunta adicional ao modelo.

5.3 COMPARAÇÃO ENTRE MODELOS DE LINGUAGEM

A comparação inicial entre modelos foi feita no conjunto dev15, nas primeiras versões da arquitetura de busca e escolha, quando o sistema ainda devolvia uma única opção. A Tabela 4 apresenta o acerto de cada modelo na mesma versão do processo.

Tabela 4 – Acerto da opção única por modelo no conjunto dev15

Versão do processo	**Llama 3.1 8B**	**Qwen2.5 7B**
Busca e escolha, versão inicial	9/15 (60,0%)	11/15 (73,3%)
Busca e escolha, após ajustes no conjunto dev15	10/15 (66,7%)	13/15 (86,7%)

Fonte: O autor (2026).

O Qwen2.5 7B superou o Llama 3.1 8B nas duas versões, com tempo semelhante, e foi adotado na primeira fase. Na inspeção das respostas, ele demonstrou melhor compreensão das descrições em português e seguiu com mais consistência as regras do *prompt*. Esses números, contudo, são otimistas: quando a versão que atingiu 86,7% no dev15 foi medida pela primeira vez no conjunto teste, acertou a opção única em apenas 14 de 33 produtos (42,4%), diferença que ilustra o superajuste discutido na seção 2.6.

Na segunda fase, com o processo final e os mesmos recursos (expansão de abreviações e Nota 2 da Seção XVII), o Qwen3 8B acertou 52,2% em primeiro lugar e 67,8% entre as três opções nos 90 produtos de desenvolvimento, contra 47,2% e 59,6% do Qwen2.5 7B, com 14,5 segundos por produto. O Qwen3 foi usado sem o modo de raciocínio explícito, para manter o tempo compatível com o uso diário; o efeito desse modo sobre o acerto não foi avaliado.

5.4 EVOLUÇÃO DAS VERSÕES NO DESENVOLVIMENTO

A Tabela 5 resume a primeira fase, com o Qwen2.5 7B. A versão revisada de busca e escolha foi adotada por não piorar em nenhum conjunto e por acrescentar a análise do produto, a pergunta ao operador e a memória; a navegação hierárquica, que acertava mais o capítulo, acumulou erros nos níveis seguintes e foi mais lenta.

Tabela 5 – Versões da primeira fase com o Qwen2.5 7B

	dev (41 produtos)			**teste (33 produtos)**		
Versão	**1º lugar**	**Top-3**	**Tempo**	**1º lugar**	**Top-3**	**Tempo**
Busca e escolha	53,7%	61,0%	14,5 s	48,5%	63,6%	≈14 s
Navegação hierárquica	46,3%	63,4%	22,1 s	36,4%	54,5%	65,0 s
Busca e escolha revisada	58,5%	70,7%	12,9 s	48,5%	63,6%	13,2 s

Fonte: O autor (2026). Top-3: código correto entre as três opções apresentadas.

A Tabela 6 mostra a contribuição de cada recurso da segunda fase nos 90 produtos de desenvolvimento (dev e DEV2). A linha de partida soma os resultados da versão revisada da primeira fase nos dois conjuntos.

Tabela 6 – Contribuição de cada recurso na segunda fase (dev + DEV2, 90 produtos)

Configuração	**1º lugar**	**Top-3**
Versão revisada da 1ª fase (Qwen2.5 7B)	51,1%	63,3%
Qwen3 8B + expansão de abreviações	52,2%	64,4%
+ Nota 2 da Seção XVII	52,2%	67,8%
+ base de conhecimento (candidatos e exemplos ao modelo)	63,3%	72,2%
+ NCM mais votado em 1º lugar quando a base é confiante (**final**)	**64,4%**	**75,6%**

Fonte: O autor (2026).

O maior ganho veio da base de conhecimento, e ele se concentrou nos produtos automotivos: nos 31 produtos automotivos do desenvolvimento, o acerto passou de 58% para 90% em primeiro lugar e de 71% para 97% entre as três opções, enquanto nos 59 produtos de outros setores ficou praticamente igual, já que as duas lojas vendem autopeças. As tentativas descartadas na segunda fase são descritas no Capítulo 4.

A base de conhecimento também foi avaliada sozinha, sem modelo de linguagem, dentro das próprias lojas, consultando 80% dos produtos para classificar os outros 20%. Na Loja A, o NCM mais votado estava correto em 66,5% dos casos e entre os três mais votados em 80,2%; na Loja B, em 64,7% e 83,4%. Quando uma loja consultava apenas a outra, o acerto caía

para 46,3% e 65,5% (Loja A consultando a Loja B) e 31,1% e 47,0% (Loja B consultando a Loja A). O conhecimento mais valioso, portanto, é o da própria empresa, o que reforça o papel da memória de classificações à medida que o operador aprova sugestões.

5.5 CONTRIBUIÇÃO DO MODELO DE LINGUAGEM

Para isolar a contribuição do LLM, as mesmas medições foram feitas sem nenhuma chamada ao modelo: com a busca lexical sozinha (BM25 com sinônimos e fusão RRF da descrição original e da expandida), com a base de conhecimento sozinha e com as duas combinadas, completando as três opções do voto da base com os primeiros resultados da busca. A Tabela 7 compara essas linhas de base com a versão final.

Tabela 7 – Acerto com e sem o modelo de linguagem

	dev + DEV2 (90)		**TESTE2 (50)**	
Método	**1º lugar**	**Top-3**	**1º lugar**	**Top-3**
Busca lexical, sem LLM	32,2%	54,4%	20,0%	30,0%
Base de conhecimento, sem LLM	25,6%	34,4%	26,0%	36,0%
Base de conhecimento + busca, sem LLM	35,6%	51,1%	28,0%	46,0%
Versão final, com LLM	**64,4%**	**75,6%**	**48,0%**	**58,0%**

Fonte: O autor (2026).

No conjunto de teste, a versão final acertou em primeiro lugar 48,0% dos produtos, contra 20,0% da busca sozinha e 28,0% da melhor combinação sem modelo: como a versão final também consulta a base de conhecimento, a comparação justa é com esta última, em relação à qual o LLM acrescentou 20 pontos percentuais em primeiro lugar e 12 pontos entre as três opções. A diferença tem duas origens. A primeira é a escolha: a busca devolve dezenas de candidatos, muitos de palavras coincidentes, e o modelo identifica entre eles o que corresponde ao produto. A segunda é a análise do produto: a descrição técnica gerada pelo modelo leva a busca a itens que a descrição original não alcança; com ela e com a base de conhecimento, o código correto esteve entre os candidatos entregues ao modelo em 78,0% dos produtos de teste, contra 62,0% entre os 40 primeiros resultados da busca sozinha. A busca e a base de conhecimento continuam indispensáveis, pois limitam as respostas a códigos existentes e trazem os candidatos, mas o ganho de 20 pontos em primeiro lugar mostra que a escolha feita pelo modelo alcança um acerto que elas, sozinhas, não alcançam.

5.6 RESULTADO DA VERSÃO FINAL NO CONJUNTO DE TESTE

A versão final foi medida uma única vez no TESTE2, depois de todas as decisões de desenvolvimento. A Tabela 8 apresenta o resultado, ao lado da medição de referência da versão da primeira fase, feita antes de qualquer alteração. As respostas para cada produto estão no Apêndice C.

Tabela 8 – Resultado no conjunto de teste TESTE2 (50 produtos)

Métrica	**Versão da 1ª fase**	**Versão final**
Acerto em 1º lugar	32,0%	48,0%
Acerto entre as 3 opções	48,0%	58,0%
Código correto entre os candidatos da busca	64,0%	78,0%
Capítulo correto	–	72,0%
Tempo médio por produto	13,4 s	13,7 s

Fonte: O autor (2026).

O resultado no teste é inferior ao do desenvolvimento (64,4% e 75,6%), diferença esperada, pois os recursos da segunda fase foram escolhidos observando os erros dos conjuntos de desenvolvimento. Ainda assim, a versão final melhorou em 16 pontos percentuais o acerto em primeiro lugar e em 10 pontos o acerto entre as três opções em relação à versão da primeira fase, sem aumento de tempo.

O resultado varia fortemente com o setor do produto. Nos 18 produtos automotivos do TESTE2, a versão final acertou 15 em primeiro lugar (83,3%), e os mesmos 15 entre as três opções; nos 32 produtos de outros setores, acertou 9 em primeiro lugar (28,1%) e 14 entre as três opções (43,8%). A base de conhecimento, formada apenas por autopeças, explica boa parte dessa diferença, e o resultado automotivo é o mais representativo do uso real do Lux Auto, voltado a oficinas mecânicas.

5.7 ANÁLISE DOS ERROS DA VERSÃO FINAL

Na versão final, o código correto ficou fora das três opções em 21 dos 50 produtos de teste. A Tabela 9 classifica esses erros pelo nível da hierarquia em que ocorreram.

Tabela 9 – Erros da versão final no TESTE2, por nível da hierarquia

Tipo de erro	**Casos**	**Produtos**
Item errado na posição correta	6	bronzina de biela, multímetro, bola de basquete, aspirador de pó, frango congelado, teclado USB
Posição errada no capítulo correto	1	sal refinado
Capítulo errado	14	calota, jaqueta de couro, mesa de jantar, fogão, colchão, mochila, *pendrive*, aparelho de barbear, vestido, fita isolante, esmalte, amaciante, lençol, *mouse*
Total	**21**	

Fonte: O autor (2026).

Diferentemente da primeira fase, em que metade dos erros ocorria no último nível, a maior parte dos erros restantes é de capítulo, e em 11 dos 21 casos o código correto nem chegou aos candidatos da busca. São produtos cujo nome comercial está longe do texto oficial ou cuja classificação depende de uma regra da tabela, e não do nome: a jaqueta de couro foi classificada como vestuário de tecido, pois a NCM a classifica entre as obras de couro (42.03); a mesa de jantar, como utensílio de madeira para mesa, e não como móvel; o *pendrive*, como unidade de memória de computador (84.71), quando a NCM o classifica entre os suportes de armazenamento (85.23); o *mouse*, como aparelho elétrico genérico, e não como periférico de computador; e a fita isolante, como fita de tecido com borracha, e não como fita de plástico (39.19). Nesses casos, a descrição técnica gerada pelo modelo descreveu corretamente o produto, mas não com os termos que levariam a busca à posição certa.

Entre os produtos automotivos, os três erros foram a bronzina de biela, cujo código correto não chegou aos candidatos; a calota, classificada como pneu porque a interpretação do modelo a associou a rodas; e o multímetro, em que o modelo escolheu o item vizinho da mesma posição, que se distingue pela presença de dispositivo registrador. Nos 5 produtos em que o código correto apareceu em segundo lugar, como a banana e o desinfetante, a distinção é entre itens da mesma posição, e a decisão do operador, com o produto em mãos, resolve o caso.

5.8 ATENDIMENTO ÀS METAS DO PROJETO

O projeto estabeleceu como critérios de sucesso uma taxa de detecção de pelo menos 85% e uma taxa de acerto das correções de pelo menos 75%; a meta de tempo de até 30 segundos por produto foi adotada depois, como critério de viabilidade. Para os códigos inválidos, objeto da meta de detecção do projeto, ela foi atingida: todos foram detectados, sem falsos

positivos. Para os códigos válidos, porém incorretos, que o projeto não previa, o resultado depende do tipo de erro: todos os 40 erros reais da Loja B foram apontados, mas, no conjunto de teste, foram apontados 78,0% dos erros plantados, abaixo dos 85%, por causa dos erros entre itens vizinhos de uma mesma posição; a acurácia, considerando também os produtos corretos, foi de 86,0%, com apenas 6,0% de alarmes falsos. A meta de tempo também foi atingida nas medições de avaliação, com 13,7 segundos por sugestão e até 25 segundos por verificação.

A meta de acerto das correções foi atingida apenas no recorte automotivo. No conjunto de teste completo, o código correto esteve em primeiro lugar em 48,0% dos produtos e entre as três opções em 58,0%, abaixo dos 75%. Nos produtos automotivos, que correspondem ao uso real do ERP, o acerto foi de 83,3% em primeiro lugar, acima da meta, mas com apenas 18 produtos, o que torna esse número menos preciso.

Esses números devem ser lidos à luz do fluxo com supervisão humana. Nenhuma sugestão continha código inexistente, já que as respostas são restritas aos códigos da tabela, e nenhum código é gravado sem aprovação. O sistema, portanto, não substitui o conhecimento fiscal do operador ou do suporte, mas reduz o esforço de classificação, impede que o erro mais grave, o código inexistente ou extinto, chegue à emissão da nota e aponta códigos válidos que provavelmente pertencem a outro produto.

5.9 DISCUSSÃO

Quatro observações gerais emergem dos experimentos. A primeira é que restringir o papel do modelo foi mais eficaz do que ampliar sua autonomia. O agente com ferramentas, mais próximo da proposta original, produziu códigos sem relação com a busca e exigia várias chamadas por produto; a arquitetura de busca e escolha, em que o programa controla o fluxo e o modelo apenas escolhe entre candidatos verificados, eliminou a possibilidade de código inventado e reduziu o tempo e a instabilidade. Esse resultado converge com a recomendação da literatura de usar o LLM como ferramenta de proposição subordinada a mecanismos de verificação e à decisão humana (Natarajan *et al.*, 2025; Huang *et al.*, 2025) e com a arquitetura proposta por Zhang *et al.* (2026) para o SH, em que o fluxo também é fixo e o modelo atua em etapas restritas.

A segunda é que, mesmo restrito, o modelo contribui de forma substancial para o acerto: no teste, a busca combinada com a base de conhecimento, sem modelo, acertou 28% em primeiro lugar; com ele, 48%. O papel do modelo não é conhecer a tabela, que ele recebe pronta,

mas interpretar a descrição comercial e escolher entre textos técnicos parecidos, justamente a parte que regras e buscas lexicais não resolvem.

A terceira é que exemplos reais valem mais do que ajustes no *prompt*. As alterações de *prompt* e de busca da segunda fase trouxeram ganhos de poucos pontos, enquanto a base de conhecimento elevou o acerto automotivo de 58% para 90% no desenvolvimento e resultou em 83% no teste. Esse resultado aproxima o protótipo dos classificadores supervisionados de NCM (Batista; Bagatini; Frozza, 2018; Pinheiro; Siqueira; Amaris, 2022), que dependem de grandes volumes de exemplos, mas sem treinamento: basta inserir produtos classificados na base. Ao mesmo tempo, o caso da Loja B mostra que exemplos reais trazem erros reais, e que filtrá-los e apontá-los é parte do problema.

A quarta é metodológica: o resultado de 86,7% no conjunto usado para os primeiros ajustes caiu para 42,4% em casos novos, e, na segunda fase, o resultado de 75,6% no desenvolvimento correspondeu a 58,0% no teste. Sem a separação entre desenvolvimento e teste, o trabalho teria relatado um desempenho substancialmente maior do que o real.

5.9.1 Limitações e Ameaças à Validade

Os resultados devem ser interpretados considerando as seguintes limitações:

- **Tamanho dos conjuntos**: com 50 produtos de teste, cada produto equivale a 2 pontos percentuais, e, no recorte automotivo, a cerca de 6 pontos; diferenças pequenas entre versões não são estatisticamente conclusivas;
- **Gabarito**: a classificação correta foi conferida pelo autor na tabela oficial, e não por um classificador fiscal certificado; em produtos ambíguos, foram aceitos todos os códigos plausíveis;
- **Erros plantados e presumidos**: na detecção de NCM incorreto, os erros do DEV2 e do TESTE2 foram plantados por sorteio, e os produtos considerados corretos da Loja B não foram conferidos um a um, de modo que parte dos alarmes falsos pode corresponder a erros reais;
- **Representatividade das bases**: as duas lojas são do setor de autopeças, o que explica a diferença de desempenho entre setores; a base de conhecimento não representa empresas de outros ramos;

• **Dados fictícios na sugestão**: os produtos dos conjuntos de sugestão foram escritos para os testes, e não extraídos de clientes; descrições reais tendem a ser mais abreviadas e ruidosas;

• **Infraestrutura**: os tempos foram medidos em uma única máquina, e o servidor local de modelos apresentou instabilidades ao longo do trabalho, que podem ter afetado algumas das medições de tempo; além disso, em uma execução do protótipo realizada após a avaliação, com o processo em segundo plano lendo o ERP, cinco de dez verificações levaram mais de 30 segundos (até 42 segundos), o que indica que o tempo em uso real pode superar o medido.

6 CONCLUSÃO

Este trabalho investigou em que medida um modelo de linguagem de pequeno porte, executado localmente e restrito a escolher entre candidatos recuperados da tabela oficial, consegue apontar classificações NCM inválidas ou incorretas no cadastro de produtos de um ERP e sugerir a classificação correta, em tempo compatível com o uso diário e sob supervisão humana. Para responder a essa pergunta, foi desenvolvido e avaliado um protótipo integrado ao ERP Lux Auto, executado inteiramente em um computador convencional, sem custo de API e sem alterações no código ou na estrutura do ERP.

A resposta obtida é positiva para a detecção de códigos inválidos e parcial para a detecção de códigos incorretos e para a sugestão. A detecção de códigos inválidos foi resolvida de forma determinística, sem modelo de linguagem: todos os códigos vazios, malformados, inexistentes e extintos dos casos de avaliação foram apontados, sem nenhum falso positivo entre mais de 41 mil mercadorias reais. A detecção de códigos válidos, porém incorretos, que depende do modelo, teve acurácia de 86,6% no desenvolvimento e de 88,8% nos erros reais de uma loja, na qual apontou todos os 40 produtos cadastrados com um código “coringa”; no conjunto de teste, a acurácia foi de 86,0%, com 6,0% de alarmes falsos, mas apenas 78,0% dos erros plantados foram apontados, pois erros entre itens vizinhos de uma mesma posição continuam difíceis de perceber. Na sugestão, a versão final acertou o código em primeiro lugar em 48,0% dos produtos de teste e entre as três opções em 58,0%, em cerca de 14 segundos por produto, abaixo da meta de 75% no conjunto completo, mas com 83,3% de acerto em primeiro lugar nos produtos automotivos, foco do ERP. Em todos os casos, nenhuma sugestão continha código inexistente, e nenhum código foi gravado sem aprovação humana.

Os objetivos específicos foram atendidos da seguinte forma: as inconsistências fiscais foram delimitadas a partir da experiência no suporte técnico, e a NCM foi escolhida como foco; a tabela NCM foi estruturada em uma base local com busca textual; o protótipo foi implementado com detecção de códigos inválidos e de códigos possivelmente incorretos, sugestão, execução em segundo plano, notificação e aprovação humana; foram construídos conjuntos separados de desenvolvimento e de teste, incluindo códigos inválidos de diferentes tipos e erros reais de classificação; e o protótipo foi avaliado quanto à detecção, ao acerto e ao tempo, com comparação entre três modelos, entre arquiteturas e contra linhas de base sem modelo de linguagem.

As principais contribuições do trabalho são: uma arquitetura de busca seguida de escolha restrita, na qual o modelo de linguagem não acessa o banco nem pode responder com códigos inexistentes; a medição da contribuição do modelo, que elevou o acerto em primeiro lugar de 28,0% para 48,0% em relação à melhor combinação de busca e base de conhecimento sem ele; o uso de produtos já classificados por outras empresas como base de conhecimento, sem treinamento, que elevou substancialmente o acerto no setor automotivo; um método de verificação de códigos válidos que encontrou um erro real e sistemático no cadastro de uma loja; e um protocolo de avaliação com conjunto de teste congelado e medido uma única vez, que mostrou o quanto a avaliação nos próprios casos de ajuste superestima o desempenho.

6.1 TRABALHOS FUTUROS

A partir dos resultados e das limitações observadas, sugerem-se as seguintes continuidades:

- **Demais categorias fiscais**: estender a arquitetura ao CST, ao CFOP e à relação entre Inscrição Estadual e Indicador de Contribuinte, cuja detecção pode, em boa parte, seguir regras determinísticas semelhantes às da NCM;
- **Bases de outros setores**: ampliar a base de conhecimento com empresas de outros ramos, que hoje concentram a maior parte dos erros, e medir o ganho em cada setor;
- **Avaliação com gabarito profissional**: medir o sistema em produtos reais de clientes com o gabarito conferido por um profissional de classificação fiscal, o que permitiria também conferir os alarmes da detecção de NCM incorreto;
- **Vocabulário técnico e notas explicativas**: construir, a partir das aprovações dos operadores, um dicionário de correspondências entre nomes comerciais e termos da NCM, e incorporar à busca as Notas Explicativas do Sistema Harmonizado, atacando os erros de capítulo, que são a maior parte dos erros restantes;
- **Abreviações aprendidas**: ampliar a tabela de abreviações com as encontradas nas bases reais, que causaram parte dos alarmes falsos da detecção;
- **Modelos maiores ou ajustados**: avaliar modelos maiores, quando o hardware permitir, o modo de raciocínio explícito do Qwen3 ou um modelo pequeno ajustado com exemplos de classificação, comparando ganho de acerto e custo de execução;

- **Integração com o ERP**: substituir a consulta periódica por um aviso no próprio ERP no momento do cadastro, caso a desenvolvedora opte por essa integração.

REFERÊNCIAS

ARORA, Jitesh Kumar; ERTURK, Emre. **An Exploratory Study on the Implementation and Adoption of ERP Solutions for Businesses**. 2017. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/1701.08329.

BATISTA, Rodrigo de Abreu; BAGATINI, Daniela D. S.; FROZZA, Rejane. Classificação automática de códigos NCM utilizando o algoritmo naïve bayes. **iSys: Revista Brasileira de Sistemas de Informação**, v. 11, n. 2, p. 4–29, 2018. Acesso em: 01 nov. 2026. Disponível em: https://seer.unirio.br/isys/article/view/6401.

BENDINELLI, Tommaso; DOX, Artur; HOLZ, Christian. **Exploring LLM Agents for Cleaning Tabular Machine Learning Datasets**. 2025. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2503.06664.

BIRD, Steven; KLEIN, Ewan; LOPER, Edward. **Natural Language Processing with Python**. Sebastopol: O'Reilly Media, 2009.

BRASIL. **Decreto nº 97.409, de 23 de dezembro de 1988: Promulga a Convenção Internacional sobre o Sistema Harmonizado de Designação e de Codificação de Mercadorias**. 1988. Acesso em: 01 nov. 2026. Disponível em: https://www.planalto.gov.br/ccivil_03/decreto/1980-1989/d97409.htm.

____. **Ajuste SINIEF 07/2005: Institui a Nota Fiscal Eletrônica e o Documento Auxiliar da Nota Fiscal Eletrônica**. 2005. Acesso em: 01 maio 2026. Disponível em: https://www.confaz.fazenda.gov.br/legislacao/ajustes/2005/AJ007_05.

BRASIL. **Emenda Constitucional nº 132, de 20 de dezembro de 2023. Altera o Sistema Tributário Nacional.** 2023. Acesso em: 09 jun. 2026. Disponível em: https://www.planalto.gov.br/ccivil_03/constituicao/emendas/emc/emc132.htm.

BRASIL. Comitê Executivo de Gestão da Câmara de Comércio Exterior. **Resolução Gecex nº 272, de 19 de novembro de 2021: Atualiza a Nomenclatura Comum do Mercosul (NCM) e a Tarifa Externa Comum (TEC)**. 2021. Acesso em: 01 nov. 2026. Disponível em: https://www.gov.br/mdic/pt-br/assuntos/camex/estrategia-comercial/tarifa-externa-comum.

BRASIL. Receita Federal. **Nomenclatura Comum do Mercosul (NCM)**. 2026. Acesso em: 06 out. 2026. Disponível em: https://www.gov.br/receitafederal/pt-br/assuntos/aduana-e-comercio-exterior/classificacao-fiscal-de-mercadorias/ncm.

BROWN, Tom B. *et al.* Language models are few-shot learners. *In*: **Advances in Neural Information Processing Systems**. [s.n.], 2020. v. 33, p. 1877–1901. Acesso em: 01 nov. 2026. Disponível em: https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfcb4967418bfb8ac142f64a-Abstract.html.

CHASE, Harrison. **LangChain**. 2022. Framework open-source para desenvolvimento de aplicações com LLMs. Acesso em: 01 maio 2026. Disponível em: https://github.com/langchain-ai/langchain.

CHENG, Edward; CHENG, Jeshua. **A Decoupled Human-in-the-Loop System for Controlled Autonomy in Agentic Workflows**. 2026. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2604.23049.

CHENG, Edward C.; CHENG, Jeshua; SIU, Alice. **Toward Safe and Responsible AI Agents: A Three-Pillar Model for Transparency, Accountability, and Trustworthiness**. 2025. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2601.06223.

CHIMPIRI, Tirumala Rao. Ensuring data quality in ERP implementations: Key conversion considerations. **International Journal of Advance Research in Computer and Communication Engineering**, v. 13, n. 3, 2024. Acesso em: 01 maio 2026. Disponível em: https://www.researchgate.net/publication/379352537.

CORMACK, Gordon V.; CLARKE, Charles L. A.; BÜTTCHER, Stefan. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. *In*: **Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval**. ACM, 2009. p. 758–759. Acesso em: 06 out. 2026. DOI: 10.1145/1571941.1572114. Disponível em: https://doi.org/10.1145/1571941.1572114.

COVER, Thomas M.; HART, Peter E. Nearest neighbor pattern classification. **IEEE Transactions on Information Theory**, v. 13, n. 1, p. 21–27, 1967. DOI: 10.1109/TIT.1967.1053964.

DOUGLAS, Michael R. **Large Language Models**. 2023. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2307.05782.

ENCAT. **Nota Técnica 2016.003, versão 3.20: Nova tabela de NCM e unidade tributável de comércio exterior, vigente a partir de 01/09/2022**. 2022. Acesso em: 01 nov. 2026. Disponível em: https://www.nfe.fazenda.gov.br.

ENCAT; SEFAZ. **Manual de Orientação do Contribuinte: Padrões Técnicos de Comunicação da Nota Fiscal Eletrônica**. 7.0. ed. [S.l.], 2020. Acesso em: 01 maio 2026. Disponível em: https://www.nfe.fazenda.gov.br.

Firebird Project. **About Firebird**. 2024. Documentação oficial descrevendo o Firebird como fork open-source do InterBase 6.0. Acesso em: 01 maio 2026. Disponível em: https://firebirdsql.org/en/about-firebird/.

GHOLAMIAN, Sina *et al.* LLM-based robust product classification in commerce and compliance. *In*: **Proceedings of the 1st Workshop on Customizable NLP: Progress and Challenges in Customizing NLP for a Domain, Application, Group, or Individual (CustomNLP4U)**. Association for Computational Linguistics, 2024. p. 26–36. Acesso em: 09 jun. 2026. DOI: 10.18653/v1/2024.customnlp4u-1.3. Disponível em: https://doi.org/10.18653/v1/2024.customnlp4u-1.3.

GIL, Antonio Carlos. **Como elaborar projetos de pesquisa**. 7. ed. Barueri: Atlas, 2022.

GRATTAFIORI, Aaron *et al.* **The Llama 3 Herd of Models**. 2024. Acesso em: 06 out. 2026. Disponível em: https://arxiv.org/abs/2407.21783.

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. New York: Springer, 2009.

HONG, Zijin *et al.* Next-generation database interfaces: A survey of LLM-based text-to-SQL. **IEEE Transactions on Knowledge and Data Engineering**, 2024. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2406.08426.

HUANG, Lei *et al.* A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. **ACM Transactions on Information Systems**, v. 43, n. 1, p. 1–38, 2025. Acesso em: 01 maio 2026. Disponível em: https://doi.org/10.1145/3703155.

JURAYJ, William; HOLZENBERGER, Nils; Van Durme, Benjamin. Language models and logic programs for trustworthy tax reasoning. *In*: **Proceedings of the AAAI Conference on Artificial Intelligence**. AAAI Press, 2026. v. 40, n. 45, p. 38688–38698. Acesso em: 01 maio 2026. DOI: 10.1609/aaai.v40i45.41212. Disponível em: https://doi.org/10.1609/aaai.v40i45.41212.

KIM, Jaewoong; MIN, Moohong. From RAG to QA-RAG: Integrating generative AI for pharmaceutical regulatory compliance process. *In*: **Proceedings of the 40th ACM/SIGAPP Symposium on Applied Computing**. ACM, 2025. p. 1293–1295. Acesso em: 09 jun. 2026. DOI: 10.1145/3672608.3707749. Disponível em: https://doi.org/10.1145/3672608.3707749.

LAUKKANEN, Sanna; SARPOLA, Sami; HALLIKAINEN, Petri. Enterprise size matters: objectives and constraints of ERP adoption. **Journal of Enterprise Information Management**, Emerald, v. 20, n. 3, p. 319–334, 2007. Acesso em: 09 jun. 2026. DOI: 10.1108/17410390710740763. Disponível em: https://doi.org/10.1108/17410390710740763.

LEE, Eunji *et al.* **Classification of Goods Using Text Descriptions With Sentences Retrieval**. 2021. Acesso em: 01 nov. 2026. Disponível em: https://arxiv.org/abs/2111.01663.

LEWIS, Patrick *et al.* Retrieval-augmented generation for knowledge-intensive NLP tasks. *In*: **Advances in Neural Information Processing Systems**. [s.n.], 2020. v. 33. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2005.11401.

LIU, Pengfei *et al.* Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. **ACM Computing Surveys**, v. 55, n. 9, p. 1–35, 2023. Acesso em: 01 nov. 2026. DOI: 10.1145/3560815. Disponível em: https://doi.org/10.1145/3560815.

LIU, Zechun *et al.* LLM-QAT: Data-free quantization aware training for large language models. *In*: **Findings of the Association for Computational Linguistics: ACL 2024**. Association for Computational Linguistics, 2024. p. 467–484. Acesso em: 09 jun. 2026. DOI: 10.18653/v1/2024.findings-acl.26. Disponível em: https://doi.org/10.18653/v1/2024.findings-acl.26.

MADICHARLA, Kalyan Pavan Kumar. Human-in-the-loop LLMOps: Balancing automation and control. **World Journal of Advanced Engineering Technology and Sciences**, v. 15, n. 2, p. 1092–1099, 2025. Acesso em: 01 maio 2026.

MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. **Introduction to Information Retrieval**. Cambridge: Cambridge University Press, 2008.

MEHTA, Rushabh. Beyond accuracy: Rethinking data quality as a strategic pillar in ERP implementation. **International Journal of Data Science and Machine Learning**, v. 5, n. 1, p. 400–409, 2025. Acesso em: 01 maio 2026.

MILLER, George A. WordNet: a lexical database for English. **Communications of the ACM**, v. 38, n. 11, p. 39–41, 1995. Acesso em: 06 out. 2026. DOI: 10.1145/219717.219748. Disponível em: https://doi.org/10.1145/219717.219748.

NATARAJAN, Sriraam *et al.* Human-in-the-loop or AI-in-the-loop? Automate or collaborate? *In*: **Proceedings of the AAAI Conference on Artificial Intelligence**. AAAI Press, 2025. v. 39, n. 27, p. 28594–28600. Acesso em: 01 maio 2026. DOI: 10.1609/aaai.v39i27.35083. Disponível em: https://doi.org/10.1609/aaai.v39i27.35083.

NAY, John J. *et al.* Large language models as tax attorneys: a case study in legal capabilities emergence. **Philosophical Transactions of the Royal Society A**, The Royal Society, v. 381, n. 2260, 2023. Acesso em: 01 maio 2026. Disponível em: https://doi.org/10.1098/rsta.2022.0327.

Ollama. **Ollama: Get up and running with large language models locally**. 2023. Acesso em: 01 maio 2026. Disponível em: https://ollama.com.

PAIVA, Valeria de; RADEMAKER, Alexandre; MELO, Gerard de. OpenWordNet-PT: An open Brazilian wordnet for reasoning. *In*: **Proceedings of COLING 2012: Demonstration Papers**. Mumbai: [s.n.], 2012. p. 353–360. Acesso em: 06 out. 2026. Disponível em: https://aclanthology.org/C12-3044.

PAN, Guanzhong *et al.* **A Cost-Benefit Analysis of On-Premise Large Language Model Deployment: Breaking Even with Commercial LLM Services**. 2025. Acesso em: 18 jun. 2026. Disponível em: https://arxiv.org/abs/2509.18101.

PINHEIRO, Pedro; SIQUEIRA, Luan; AMARIS, Marcos. A four-step cascade methodology to classify MCN codes using NLP techniques. *In*: **Anais do XIX Encontro Nacional de Inteligência Artificial e Computacional (ENIAC)**. Campinas: Sociedade Brasileira de Computação, 2022. Acesso em: 01 nov. 2026. Disponível em: https://sol.sbc.org.br/index.php/eniac/article/view/22798.

PÖHLER, Jan *et al.* Keeping the human in the loop: are autonomous decisions inevitable? **i-com**, De Gruyter, v. 24, n. 1, p. 9–25, 2025. Acesso em: 01 maio 2026. Disponível em: https://doi.org/10.1515/icom-2024-0068.

PORTER, Martin F. **Snowball: A language for stemming algorithms**. 2001. Acesso em: 01 nov. 2026. Disponível em: https://snowballstem.org/texts/introduction.html.

QU, Changle *et al.* Tool learning with large language models: A survey. **Frontiers of Computer Science**, 2024. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2405.17935.

Qwen Team. **Qwen2.5 Technical Report**. 2024. Acesso em: 06 out. 2026. Disponível em: https://arxiv.org/abs/2412.15115.

ROBERTSON, Stephen; ZARAGOZA, Hugo. The probabilistic relevance framework: BM25 and beyond. **Foundations and Trends in Information Retrieval**, v. 3, n. 4, p. 333–389, 2009. Acesso em: 06 out. 2026. DOI: 10.1561/1500000019. Disponível em: https://doi.org/10.1561/1500000019.

ROYCHOWDHURY, Aparup *et al.* Design and implementation of an AI agent for natural language-driven database operations. *In*: **2025 6th International Conference on IoT Based Control Networks and Intelligent Systems (ICICNIS)**. [S.l.: s.n.], 2025. Acesso em: 01 maio 2026.

Ruiz Gómez, Jorge *et al.* **Chatting with your ERP: A Recipe**. 2025. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2507.23429.

SCHELTER, Sebastian *et al.* Automating large-scale data quality verification. **Proceedings of the VLDB Endowment**, v. 11, n. 12, p. 1781–1794, 2018. Acesso em: 01 maio 2026. Disponível em: https://doi.org/10.14778/3229863.3229867.

SEFAZ-PE. **Nota Fiscal Eletrônica: Perguntas e Respostas**. [S.l.], 2016. Acesso em: 01 maio 2026. Disponível em: https://www.sefaz.pe.gov.br/Publicacoes/Manuais.

SHAO, Minghao *et al.* **Survey of different Large Language Model Architectures: Trends, Benchmarks, and Challenges**. 2024. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/2412.03220.

SINDIREPA BRASIL. **Anuário da Indústria de Reparação de Veículos do Brasil 2023**. 2023. Dados baseados na RAIS e CNAE 4520-0. Acesso em: 01 maio 2026. Disponível em: https://www.sindirepabrasil.org.br.

SQLite. **SQLite FTS5 Extension**. 2024. Acesso em: 06 out. 2026. Disponível em: https://www.sqlite.org/fts5.html.

Streamlit Inc. **Streamlit Documentation**. 2024. Acesso em: 01 maio 2026. Disponível em: https://docs.streamlit.io.

van Everdingen, Yvonne; van Hillegersberg, Jos; WAARTS, Eric. Enterprise resource planning: ERP adoption by European midsize companies. **Communications of the ACM**, ACM, v. 43, n. 4, p. 27–31, 2000. Acesso em: 09 jun. 2026. DOI: 10.1145/332051.332064. Disponível em: https://doi.org/10.1145/332051.332064.

VASWANI, Ashish *et al.* Attention is all you need. *In*: **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2017. v. 30, p. 5998–6008. Acesso em: 01 maio 2026. Disponível em: https://arxiv.org/abs/1706.03762.

WANG, Lei *et al.* A survey on large language model based autonomous agents. **Frontiers of Computer Science**, v. 18, n. 6, p. 186345, 2024. Acesso em: 01 maio 2026. Disponível em: https://doi.org/10.1007/s11704-024-40231-1.

WAZLAWICK, Raul Sidnei. **Metodologia de pesquisa para ciência da computação**. 2. ed. Rio de Janeiro: Elsevier, 2014.

WILLARD, Brandon T.; LOUF, Rémi. **Efficient Guided Generation for Large Language Models**. 2023. Acesso em: 06 out. 2026. Disponível em: https://arxiv.org/abs/2307.09702.

WORLD CUSTOMS ORGANIZATION. **What is the Harmonized System (HS)?** 2026. Acesso em: 06 out. 2026. Disponível em: https://www.wcoomd.org/en/topics/nomenclature/overview/what-is-the-harmonized-system.aspx.

XU, Huiying *et al.* Data quality issues in implementing an ERP. **Industrial Management & Data Systems**, Emerald Publishing, v. 102, n. 1, p. 47–58, 2002. Acesso em: 01 maio 2026. Disponível em: https://doi.org/10.1108/02635570210414668.

YANG, An *et al.* **Qwen3 Technical Report**. 2025. Acesso em: 01 nov. 2026. Disponível em: https://arxiv.org/abs/2505.09388.

YUVRAJ, Pritish; DEVARAKONDA, Siva. **ATLAS: Benchmarking and Adapting LLMs for Global Trade via Harmonized Tariff Code Classification**. 2025. Acesso em: 01 nov. 2026. Disponível em: https://arxiv.org/abs/2509.18400.

ZHANG, Yu *et al.* **A Deterministic Agentic Workflow for HS Tariff Classification: Multi-Dimensional Rule Reasoning with Interpretable Decisions**. 2026. Acesso em: 01 nov. 2026. Disponível em: https://arxiv.org/abs/2605.14857.

ZHOU, Zixuan *et al.* **A Survey on Efficient Inference for Large Language Models**. 2024. Acesso em: 09 jun. 2026. Disponível em: https://arxiv.org/abs/2404.14294.

APÊNDICE A – CONJUNTOS DE CASOS

Este apêndice lista os produtos dos conjuntos utilizados na avaliação da sugestão, com as descrições exatamente como foram fornecidas ao sistema e os códigos NCM aceitos como corretos. Os conjuntos dev15, dev e teste foram usados nas primeiras versões; o DEV2 e o TESTE2 foram sorteados, com semente fixa, de um mesmo grupo de 99 produtos novos, e o TESTE2 foi medido uma única vez, com a versão final.

Tabela 10 – Conjunto dev15

Nº	Descrição	NCM aceito(s)
1	vela de ignição	8511.10.00
2	amortecedor	8708.80.00
3	retrovisor	7009.10.00
4	radiador para automóvel	8708.91.00
5	para-choque	8708.10.00
6	PARACHOQUE	8708.10.00
7	farol	8512.20.11
8	embreagem	8708.93.00
9	pneu novo para carro de passeio	4011.10.00
10	correia dentada	4010.35.00, 4010.36.00
11	pastilha de freio	8708.30.19, 8708.30.11, 8708.30.90
12	disco de freio	8708.30.19, 8708.30.11, 8708.30.90
13	óleo lubrificante para motor	2710.19.31, 2710.19.32
14	bateria de chumbo para automóvel	8507.10.10, 8507.10.90
15	AZULEIJO DE BANHEIRO AZUL	6907.23.00, 6907.21.00, 6907.22.00

Tabela 11 – Conjunto dev

Nº	Descrição cadastrada	NCM aceito(s)	Setor
1	BOMBA D AGUA MOTOR	8413.30.90	automotivo
2	ALTERNADOR 12V	8511.50.10	automotivo
3	MOTOR DE ARRANQUE	8511.40.00	automotivo
4	PARABRISA DIANTEIRO	7007.21.00, 8708.22.00	automotivo

Nº	Descrição cadastrada	NCM aceito(s)	Setor
5	JUNTA DO CABECOTE	8484.10.00	automotivo
6	FILTRO DE OLEO	8421.23.00	automotivo
7	CABO DE VELA	8544.30.00	automotivo
8	EXTINTOR DE INCENDIO PO QUIMICO	8424.10.00	automotivo
9	BUZINA 12V	8512.30.00	automotivo
10	PNEU ARO 17 MOTO	4011.40.00	automotivo
11	CAMARA DE AR BICICLETA	4013.20.00	automotivo
12	FLUIDO DE FREIO DOT 4	3819.00.00	automotivo
13	ADITIVO PARA RADIADOR	3820.00.00	automotivo
14	ACUCAR REFINADO 1KG	1701.99.00	alimentos
15	OLEO DE SOJA 900ML	1507.90.11	alimentos
16	MACARRAO ESPAGUETE 500G	1902.19.00, 1902.11.00	alimentos
17	BISCOITO RECHEADO CHOCOLATE	1905.31.00	alimentos
18	SUCO DE UVA INTEGRAL 1L	2009.61.00, 2009.69.00	bebidas
19	AGUA MINERAL SEM GAS 500ML	2201.10.00	bebidas
20	VINHO TINTO SECO 750ML	2204.21.00	bebidas
21	PERFUME 100ML	3303.00.10	higiene
22	PAPEL TOALHA 2 ROLOS	4818.20.00	higiene
23	ESCOVA DE DENTES	9603.21.00	higiene
24	FRALDA DESCARTAVEL INFANTIL	9619.00.00	higiene
25	MEIA DE ALGODAO	6115.95.00	vestuario
26	CUECA BOXER ALGODAO	6107.11.00	vestuario
27	CHINELO DE BORRACHA	6402.20.00	calcados
28	FONE DE OUVIDO BLUETOOTH	8518.30.00	eletronicos
29	MICROONDAS 30L	8516.50.00	eletrodomesticos
30	LIQUIDIFICADOR 600W	8509.40.10	eletrodomesticos
31	VENTILADOR DE MESA	8414.51.10	eletrodomesticos
32	CHAVE DE FENDA	8205.40.00	ferramentas
33	ALICATE UNIVERSAL	8203.20.10	ferramentas
34	TRENA 5M	9017.80.10	ferramentas
35	TIJOLO CERAMICO 8 FUROS	6904.10.00	construcao
36	CANO PVC 100MM	3917.23.00	construcao

Nº	Descrição cadastrada	NCM aceito(s)	Setor
37	FIO ELETRICO 2,5MM	8544.49.00	construcao
38	LAPIS PRETO	9609.10.00	papelaria
39	SOFA 3 LUGARES	9401.61.00, 9401.71.00	moveis
40	BICICLETA ARO 29	8712.00.10	esporte
41	RACAO PARA CAES 15KG	2309.10.00	pet

Tabela 12 – Conjunto teste

Nº	Descrição cadastrada	NCM aceito(s)	Setor
1	ARROZ BRANCO TIPO 1 5KG	1006.30.21	alimentos
2	CAFE TORRADO E MOIDO 500G	0901.21.00	alimentos
3	REFRIGERANTE COLA 2L	2202.10.00	bebidas
4	CERVEJA LATA 350ML	2203.00.00	bebidas
5	LEITE UHT INTEGRAL 1L	0401.20.10	alimentos
6	CHOCOLATE AO LEITE BARRA 90G	1806.32.10	alimentos
7	DETERGENTE LIQUIDO LAVA LOUCAS 500ML	3402.50.00	limpeza
8	SABONETE EM BARRA 90G	3401.11.90	higiene
9	SHAMPOO ANTICASPA 350ML	3305.10.00	higiene
10	CREME DENTAL 90G	3306.10.00	higiene
11	PAPEL HIGIENICO FOLHA DUPLA 12 ROLOS	4818.10.00	higiene
12	CAMISETA ALGODAO MASCULINA	6109.10.00	vestuario
13	CALCA JEANS FEMININA	6204.62.00	vestuario
14	TENIS ESPORTIVO	6404.11.00, 6402.19.00	calcados
15	TOALHA DE BANHO ALGODAO	6302.60.00	cama mesa banho
16	CELULAR SMARTPHONE 128GB	8517.13.00	eletronicos
17	NOTEBOOK 15 POLEGADAS	8471.30.12, 8471.30.19	eletronicos
18	GELADERA FROST FREE DUPLEX	8418.10.00	eletrodomesticos
19	LAMPADA LED 9W	8539.52.00	eletricos
20	PILHA ALCALINA AA	8506.10.19	eletricos

Nº	Descrição cadastrada	NCM aceito(s)	Setor
21	MARTELO DE UNHA CABO MADEIRA	8205.20.00	ferramentas
22	FURADERA ELETRICA 500W	8467.21.00	ferramentas
23	CIMENTO PORTLAND 50KG	2523.29.10	construcao
24	TINTA ACRILICA PAREDE 18L	3209.10.10	construcao
25	PARAFUSO SEXTAVADO ACO M8	7318.15.00	ferragens
26	CADERNO ESPIRAL 96 FOLHAS	4820.20.00	papelaria
27	CANETA ESFEROGRAFICA AZUL	9608.10.00	papelaria
28	CADEIRA DE ESCRITORIO GIRATORIA	9401.31.00, 9401.39.00	moveis
29	BOLA DE FUTEBOL	9506.62.00	esporte
30	FILTRO DE AR DO MOTOR	8421.31.00	automotivo
31	OLEO MOTOR 5W30 1L	2710.19.32	automotivo
32	LAMPADA FAROL H4 12V	8539.21.10	automotivo
33	BATERIA 60AH 12V	8507.10.90	automotivo

Tabela 13 – Conjunto DEV2

Nº	Descrição cadastrada	NCM aceito(s)	Setor
1	PORCA SEXTAVADA M10	7318.16.00	automotivo
2	FUSIVEL LAMINA 10A	8536.10.00	automotivo
3	MANG SUP RADIADOR	4009.31.00, 4009.32.10, 4009.32.90, 8708.91.00	automotivo
4	SILENCIOSO TRASEIRO ESCAPAMENTO	8708.92.00	automotivo
5	BOBINA DE IGNICAO	8511.30.20	automotivo
6	MACACO HIDRAULICO GARRAFA 2T	8425.42.00	automotivo
7	RELE AUXILIAR 12V 4 TERMINAIS	8536.41.00	automotivo
8	JOGO DE ANEIS DE SEGMENTO	8409.91.16	automotivo
9	ROLAM RODA DIANT	8482.10.10, 8482.10.90	automotivo
10	PALHETA LIMPADOR PARABRISA 20 POL	8512.90.00	automotivo

Nº	Descrição cadastrada	NCM aceito(s)	Setor
11	PISTAO MOTOR STD	8409.91.20	automotivo
12	ALICATE DE PRESSAO	8203.20.90	automotivo
13	CIL MESTRE FREIO	8708.30.90	automotivo
14	CORREIA DO ALTERNADOR	4010.31.00, 4010.32.00, 4010.33.00, 4010.34.00	automotivo
15	PIVO SUSP INF	8708.80.00	automotivo
16	BIELETA BARRA ESTABILIZADORA	8708.80.00	automotivo
17	TERMINAL DE DIRECAO LD	8708.94.90, 8708.80.00	automotivo
18	PASTILHA DE FREIO DIANTEIRA CERAMICA	8708.30.19	automotivo
19	ABSORVENTE HIGIENICO	9619.00.00	higiene
20	OVOS BRANCOS DUZIA	0407.21.00	alimentos
21	KETCHUP 400G	2103.20.10	alimentos
22	BATEDEIRA	8509.40.20	eletrodomesticos
23	FARINHA DE TRIGO 1KG	1101.00.10	alimentos
24	AGUA SANITARIA 1L	2828.90.11	limpeza
25	LIXA DAGUA 220	6805.20.00	construcao
26	SERROTE	8202.10.00	ferramentas
27	PATINHO BOVINO KG	0201.30.00, 0202.30.00	alimentos
28	ACHOCOLATADO EM PO 400G	1806.10.00, 1806.90.00	alimentos
29	CAFE SOLUVEL 100G	2101.11.10	alimentos
30	SARDINHA EM LATA 125G	1604.13.10	alimentos
31	SABAO EM PO 1KG	3402.50.00	limpeza
32	SERRA CIRCULAR	8467.22.00	ferramentas
33	PROTETOR SOLAR FPS 50	3304.99.90	higiene
34	VARA DE PESCA	9507.10.00	esporte
35	BOTA DE SEGURANCA BICO DE ACO	6403.40.00	calcados
36	MAIONESE 500G	2103.90.11	alimentos
37	MANTEIGA COM SAL 200G	0405.10.00	alimentos
38	BORRACHA ESCOLAR	4016.92.00	papelaria
39	CHAVE INGLESA	8204.12.00	ferramentas
40	IOGURTE NATURAL 170G	0403.20.00	alimentos

Nº	Descrição cadastrada	NCM aceito(s)	Setor
41	AR CONDICIONADO SPLIT 12000 BTUS	8415.10.11	eletrodomesticos
42	TRAVESSEIRO	9404.90.00	cama mesa banho
43	FEIJAO CARIOCA 1KG	0713.33.99	alimentos
44	ARMARIO DE ACO 2 PORTAS	9403.20.90, 9403.10.00	moveis
45	TORNEIRA DE PIA	8481.80.19	construcao
46	CAIXA DE SOM BLUETOOTH	8518.22.00, 8518.21.00	eletronicos
47	VODKA 1L	2208.60.00	bebidas
48	CHUVEIRO ELETRICO	8516.10.00	eletrodomesticos
49	DISJUNTOR 20A	8536.20.00	construcao

Tabela 14 – Conjunto TESTE2

Nº	Descrição cadastrada	NCM aceito(s)	Setor
1	PNEU 175/70 R14	4011.10.00	automotivo
2	FILTRO AR COND CABINE	8421.39.90	automotivo
3	BRONZINA DE BIELA	8483.30.90, 8409.91.90	automotivo
4	CALOTA ARO 14	8708.70.90	automotivo
5	LAMPADA PINGO 12V 5W	8539.29.10	automotivo
6	TAPETE AUTOMOTIVO BORRACHA JOGO	4016.91.00	automotivo
7	FILTRO DE COMBUSTIVEL	8421.23.00	automotivo
8	CHAVE DE RODA CRUZ	8204.11.00	automotivo
9	TAMPA DO RADIADOR	8708.91.00	automotivo
10	RETENTOR VIRABREQUIM	4016.93.00	automotivo
11	PARAFUSO DE RODA	7318.15.00	automotivo
12	MULTIMETRO DIGITAL	9030.31.00	automotivo
13	CERA AUTOMOTIVA PASTA	3405.30.00	automotivo
14	BOMBA COMBUSTIVEL ELETRICA FLEX	8413.30.10	automotivo
15	SOQUETE ENCAIXE 1/2 10MM	8204.20.00	automotivo

Nº	Descrição cadastrada	NCM aceito(s)	Setor
16	CHAVE COMBINADA 13MM	8204.11.00	automotivo
17	ARRUELA LISA ACO 10MM	7318.22.00	automotivo
18	SONDA LAMBDA	9027.10.00	automotivo
19	JAQUETA DE COURO	4203.10.00	vestuario
20	ENERGETICO LATA 250ML	2202.10.00, 2202.99.00	bebidas
21	PREGO 17X27 1KG	7317.00.90	construcao
22	CARREGADOR DE CELULAR USB	8504.40.10, 8504.40.90	eletronicos
23	MESA DE JANTAR MADEIRA	9403.60.00	moveis
24	FOGAO 4 BOCAS	7321.11.00	eletrodomesticos
25	BANANA PRATA KG	0803.90.00	alimentos
26	COLCHAO DE ESPUMA SOLTEIRO	9404.21.00	moveis
27	MOCHILA ESCOLAR	4202.92.00	papelaria
28	PENDRIVE 32GB	8523.51.10, 8523.51.90	eletronicos
29	APARELHO DE BARBEAR DESCARTAVEL	8212.10.20	higiene
30	BOLA DE BASQUETE	9506.62.00	esporte
31	VESTIDO MALHA ALGODAO	6104.42.00	vestuario
32	FITA ISOLANTE	3919.10.20	construcao
33	BONECA DE PLASTICO	9503.00.22	brinquedos
34	ESMALTE DE UNHA	3304.30.00	higiene
35	ARGAMASSA 20KG	3824.50.00	construcao
36	SAL REFINADO 1KG	2501.00.20	alimentos
37	AMACIANTE ROUPA 2L	3809.91.90	limpeza
38	IMPRESSORA MULTIFUNCIONAL JATO DE TINTA	8443.31.11, 8443.31.19	eletronicos
39	TELHA FIBROCIMENTO	6811.82.00	construcao
40	ASPIRADOR DE PO	8508.11.00	eletrodomesticos
41	FERRO DE PASSAR	8516.40.00	eletrodomesticos
42	FRANGO INTEIRO CONGELADO	0207.12.10, 0207.12.20	alimentos
43	LENCOL CASAL ALGODAO	6302.21.00, 6302.31.00	cama mesa banho
44	TOMADA 2P+T	8536.69.90	construcao
45	DESINFETANTE 2L	3808.94.19	limpeza

Nº	Descrição cadastrada	NCM aceito(s)	Setor
46	MOUSE SEM FIO	8471.60.53	eletronicos
47	TECLADO USB	8471.60.52	eletronicos
48	QUEIJO MUSSARELA FATIADO	0406.10.10	alimentos
49	DESODORANTE AEROSOL MASC 150ML	3307.20.10, 3307.20.90	higiene
50	MAQUINA DE LAVAR ROUPAS	8450.11.00	eletrodomesticos

APÊNDICE B – *PROMPTS* DA VERSÃO FINAL

Os *prompts* são reproduzidos sem acentuação, como no código-fonte do protótipo. Os exemplos citados neles não pertencem a nenhum conjunto de avaliação.

PROMPT DA ANÁLISE DO PRODUTO

```
Voce conhece a Nomenclatura Comum do Mercosul (NCM). Para a
descricao de produto recebida (pode ter erro de digitacao),
responda:

- descricao_tecnica: o nome tecnico/formal que a NCM usa para esse
tipo de mercadoria. No maximo 8 palavras. Sem embalagem, volume,
peso, medidas, potencia, cor ou marca.
- caracteristicas: ate 15 palavras com o que decide a
classificacao: material, funcao, aplicacao (ex.: para automovel),
estado (novo, refinado, cru...), se e produto completo ou peca. Se
algo importante nao da para saber pela descricao, diga "nao
informado: ...".

Responda SEMPRE em portugues do Brasil, nunca em outro idioma.

Exemplos:
'TV LED 50 POLEGADAS' -> descricao_tecnica 'aparelho receptor de
televisao'; caracteristicas 'aparelho eletronico completo, tela de
LED, uso domestico'
'GUARDA ROUPA MDF' -> descricao_tecnica 'movel de madeira para
quarto de dormir'; caracteristicas 'movel completo, madeira
aglomerada (MDF), uso domestico'
'SUCO DE LARANJA 1L' -> descricao_tecnica 'suco de laranja nao
fermentado'; caracteristicas 'bebida nao alcoolica, fruta, pronto
para beber; nao informado: valor Brix'
```

PROMPT DE SISTEMA DAS ESCOLHAS DE CAPÍTULO E ITENS

```
Voce e um especialista em classificacao fiscal de mercadorias na
```

NCM (Nomenclatura Comum do Mercosul) da Receita Federal.

A descricao do produto vem do jeito que foi digitada no cadastro de um ERP: pode estar em maiusculas, sem hifen, abreviada ou com erro de digitacao (ex.: PARACHOQUE = para-choque de carro; AZULEIJO = azulejo). Os candidatos vem de uma busca automatica e CONTEM RUIDO: alguns nao tem nada a ver com o produto.

Regras:
1. Pense no que o produto E de fato (material, funcao) antes de escolher. Uma cor ou palavra solta no nome nao muda o que o produto e (um azulejo azul continua sendo ceramica, nunca peixe).
2. Se um candidato nomeia diretamente o produto (ex.: 'Para-choques e suas partes' para um parachoque), escolha ele.
3. Nao escolha um item 'Outros'/'Outras' so porque ficou em duvida: todo 'Outros' pertence a uma posicao especifica (ex.: 'Outros' de tijolos refratarios). Escolha primeiro a posicao que descreve o produto e so depois o item dentro dela.
4. Responda SOMENTE com codigos/capitulos da lista. Na escolha do capitulo, use NENHUM apenas se nenhum candidato for sequer do mesmo tipo de produto.
5. Contexto do negocio: o ERP e de uma oficina mecanica de automoveis. Quando a descricao nao diz o tipo de veiculo e o mesmo produto existir para automovel e para moto/bicicleta/trator/trem, prefira o de automovel. Isso vale so para desempatar -- um produto que claramente nao e peca de carro (ex.: azulejo) continua sendo classificado pelo que ele e.
6. Cada justificativa deve ser curta e em linguagem simples. Se a escolha exata depender de uma informacao que a descricao nao tem (ex.: tipo de ceramica, absorcao de agua), diga qual informacao falta -- e justamente por isso as outras opcoes existem.

7. Pecas de uso geral NAO sao classificadas como "partes e acessorios" de veiculos (87.08), mesmo quando sao de carro (Nota 2

da Secao XVII). Elas tem posicao propria: rolamentos (84.82); parafusos, porcas e arruelas (73.18); molas (73.20); juntas, retentores e outros artigos de borracha (40.16); mangueiras de borracha (40.09); correias (40.10); pneus (40.11); filtros (84.21); bombas (84.13); pecas de motor (84.09); lampadas (85.39); reles, fusiveis e interruptores (85.36); velas, bobinas, alternadores e motores de arranque (85.11); farois, buzinas e limpadores de para-brisa, com suas partes (85.12); vidros (70.07); espelhos (70.09); fios e cabos eletricos (85.44); ferramentas (Cap. 82). Use a 87.08 so para partes proprias de veiculo que nao tenham posicao especifica (para-choques, freios, suspensao, radiadores, silenciosos, direcao, rodas).

PROMPT DE SISTEMA DA VERIFICAÇÃO DO NCM CADASTRADO

Voce e um especialista em classificacao fiscal de mercadorias na NCM (Nomenclatura Comum do Mercosul). Voce revisa cadastros de produtos de um ERP de oficina mecanica para encontrar NCM errado.

A descricao do produto vem como foi digitada no cadastro: pode estar abreviada ou com erro de digitacao. Julgue pelo que o produto E (material, funcao, aplicacao), nao por palavras soltas.

Responda SEMPRE em portugues do Brasil, nunca em outro idioma.

APÊNDICE C – RESPOSTAS DA VERSÃO FINAL NO CONJUNTO DE TESTE

Este apêndice apresenta, para cada produto do TESTE2, as três opções sugeridas pela versão final e a posição em que o código correto apareceu. A execução completa, com a interpretação do modelo, os capítulos escolhidos e o tempo de cada produto, está disponível no repositório do protótipo, no diretório `data/avaliacoes`.

Tabela 15 – Respostas da versão final no conjunto TESTE2

Nº	**Descrição cadastrada**	**NCM aceito(s)**	**Opções sugeridas (em ordem)**	**Acerto**
1	PNEU 175/70 R14	4011.10.00	4011.10.00 4011.20.90 4011.20.10	1º
2	FILTRO AR COND CABINE	8421.39.90	8421.39.90 8415.20.90 8415.82.10	1º
3	BRONZINA DE BIELA	8483.30.90, 8409.91.90	8483.30.29 8409.91.11 8483.10.11	não
4	CALOTA ARO 14	8708.70.90	4011.10.00 4011.90.10 4011.80.20	não
5	LAMPADA PINGO 12V 5W	8539.29.10	8539.29.10 8539.52.00 8539.32.30	1º
6	TAPETE AUTOMOTIVO BORRACHA JOGO	4016.91.00	4016.91.00 4016.10.10 4011.10.00	1º
7	FILTRO DE COMBUSTIVEL	8421.23.00	8421.23.00 8421.99.99 8421.29.30	1º
8	CHAVE DE RODA CRUZ	8204.11.00	8204.11.00 8204.12.00 8205.40.00	1º

Nº	Descrição cadastrada	NCM aceito(s)	Opções sugeridas (em ordem)	Acerto
9	TAMPA DO RADIADOR	8708.91.00	8708.91.00	1º
			8708.99.90	
			8708.29.12	
10	RETENTOR VIRABREQUIM	4016.93.00	4016.93.00	1º
11	PARAFUSO DE RODA	7318.15.00	7318.15.00	1º
			7318.14.00	
			7318.19.00	
12	MULTIMETRO DIGITAL	9030.31.00	9030.32.00	não
			9031.80.40	
			9031.90.90	
13	CERA AUTOMOTIVA PASTA	3405.30.00	3405.30.00	1º
			3407.00.90	
			3404.90.19	
14	BOMBA COMBUSTIVEL ELETRICA FLEX	8413.30.10	8413.30.10	1º
			8413.91.90	
			8413.81.00	
15	SOQUETE ENCAIXE 1/2 10MM	8204.20.00	8204.20.00	1º
			8204.11.00	
			8207.90.00	
16	CHAVE COMBINADA 13MM	8204.11.00	8204.11.00	1º
			8205.59.00	
			8204.12.00	
17	ARRUELA LISA ACO 10MM	7318.22.00	7318.22.00	1º
			7318.21.00	
			7325.99.10	
18	SONDA LAMBDA	9027.10.00	9027.10.00	1º
			9018.39.29	
			9014.80.10	
19	JAQUETA DE COURO	4203.10.00	6210.30.00	não
20	ENERGETICO LATA 250ML	2202.10.00,	2202.10.00	1º
		2202.99.00	2206.00.90	
			2206.00.10	

Nº	Descrição cadastrada	NCM aceito(s)	Opções sugeridas (em ordem)	Acerto
21	PREGO 17X27 1KG	7317.00.90	7317.00.90 7317.00.10 7323.10.00	1º
22	CARREGADOR DE CELULAR USB	8504.40.10, 8504.40.90	8504.40.10 8517.62.62 8517.14.32	1º
23	MESA DE JANTAR MADEIRA	9403.60.00	4419.90.00 4419.20.00 4419.19.00	não
24	FOGAO 4 BOCAS	7321.11.00	8516.60.00	não
25	BANANA PRATA KG	0803.90.00	0803.10.00 0803.90.00	2º
26	COLCHAO DE ESPUMA SOLTEIRO	9404.21.00	3402.90.90 3402.90.39 3405.10.00	não
27	MOCHILA ESCOLAR	4202.92.00	9605.00.00 9609.20.00 9616.20.00	não
28	PENDRIVE 32GB	8523.51.10, 8523.51.90	8471.70.40	não
29	APARELHO DE BARBEAR DESCARTAVEL	8212.10.20	8510.10.00 8510.90.11 8510.90.19	não
30	BOLA DE BASQUETE	9506.62.00	9506.61.00 9506.32.00 9504.90.10	não
31	VESTIDO MALHA ALGODAO	6104.42.00	6004.90.10 6006.22.00 6006.24.00	não
32	FITA ISOLANTE	3919.10.20	5906.10.00	não

Nº	Descrição cadastrada	NCM aceito(s)	Opções sugeridas (em ordem)	Acerto
33	BONECA DE PLASTICO	9503.00.22	9503.00.29 9503.00.22 9503.00.21	2º
34	ESMALTE DE UNHA	3304.30.00	3208.90.10 3207.30.00	não
35	ARGAMASSA 20KG	3824.50.00	3824.50.00 3824.99.52 3816.00.90	1º
36	SAL REFINADO 1KG	2501.00.20	2530.10.10 2530.90.90 2530.90.30	não
37	AMACIANTE ROUPA 2L	3809.91.90	3405.20.00	não
38	IMPRESSORA MULTIFUNCIONAL JATO DE TINTA	8443.31.11, 8443.31.19	8443.39.10 8443.31.11 8443.32.31	2º
39	TELHA FIBROCIMENTO	6811.82.00	6811.82.00 6810.19.00 6811.89.00	1º
40	ASPIRADOR DE PO	8508.11.00	8508.19.00 8509.80.90 8509.40.90	não
41	FERRO DE PASSAR	8516.40.00	8516.40.00	1º
42	FRANGO INTEIRO CONGELADO	0207.12.10, 0207.12.20	0207.27.00 0210.99.11	não
43	LENCOL CASAL ALGODAO	6302.21.00, 6302.31.00	5906.10.00 5911.10.00	não
44	TOMADA 2P+T	8536.69.90	8536.69.10 8536.69.90 8536.90.20	2º
45	DESINFETANTE 2L	3808.94.19	3808.94.29 3808.94.19 3808.94.22	2º

Nº	Descrição cadastrada	NCM aceito(s)	Opções sugeridas (em ordem)	Acerto
46	MOUSE SEM FIO	8471.60.53	8543.70.35 8544.49.00 8543.70.36	não
47	TECLADO USB	8471.60.52	8471.60.59 8471.60.53 8471.60.61	não
48	QUEIJO MUSSARELA FATIADO	0406.10.10	0406.10.10 0406.10.90 0406.90.30	1º
49	DESODORANTE AEROSOL MASC 150ML	3307.20.10, 3307.20.90	3307.20.10 3307.20.90 3307.49.00	1º
50	MAQUINA DE LAVAR ROUPAS	8450.11.00	8450.11.00 8450.12.00 8450.20.90	1º